NAMA : Fauzi Rizky Maulana

NIM : 20124087

KELAS : C3.24

1. Metode : regresi
   Data : housing dataset

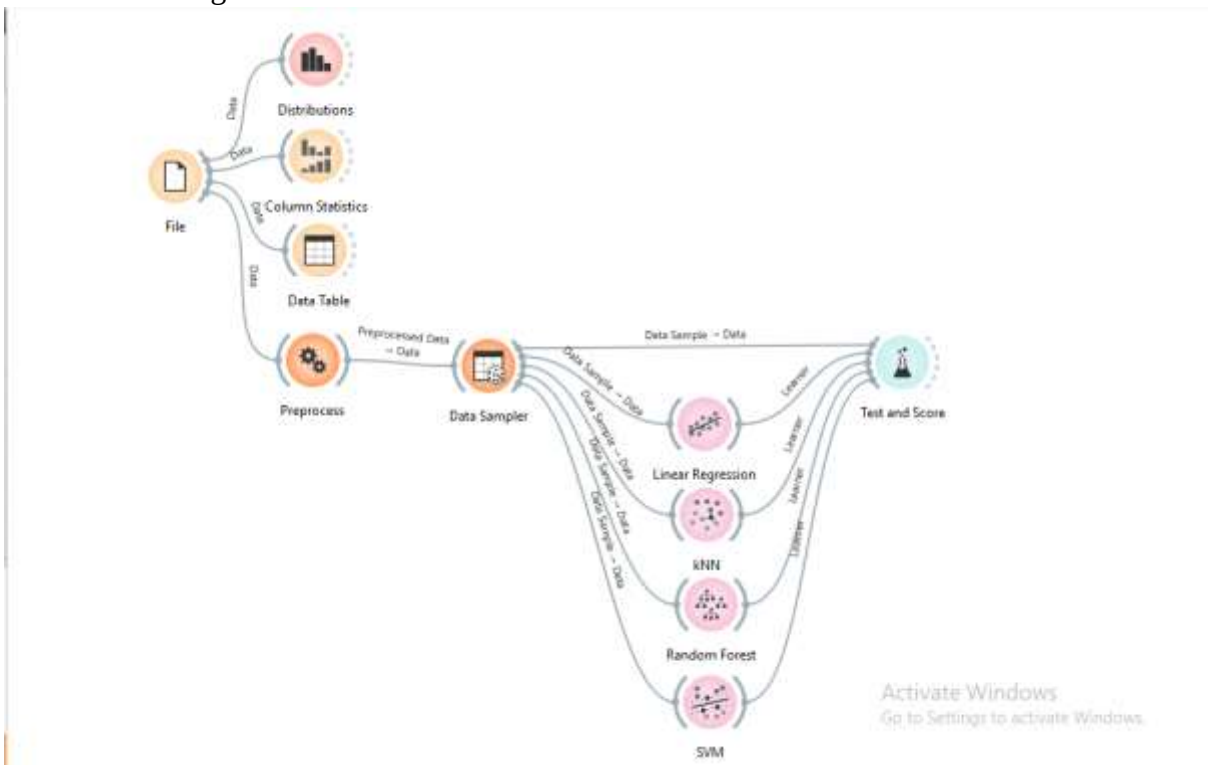

Penjelasan Workflow

• Data Sampler : Digunakan untuk membagi data menjadi data latih dan data uji agar model dapat dievaluasi secara objektif.

• Model Regresi: Melakukan pengujian pada empat algoritma utama: Linear Regression, kNN, Random Forest, dan SVM.

• Test and Score: Melakukan validasi silang (Cross Validation) dengan 5 fold untuk memastikan stabilitas hasil evaluasi model.

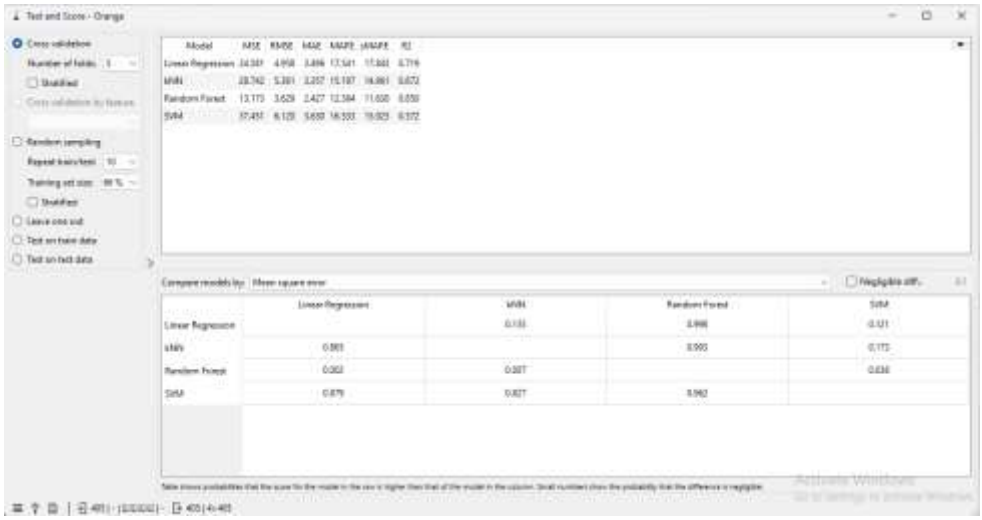

- Nilai error paling kecil (MSE, RMSE, MAE, MAPE, sMAPE)
- Nilai **R^2 paling tinggi (0.850)** → paling mampu menjelaskan variasi data

- **Linear Regression** cukup baik, tapi masih kalah dari Random Forest
- **kNN** performanya sedang (tidak buruk, tapi tidak terbaik)
- **SVM** adalah yang terburuk:

- Error paling besar
- R^2 paling rendah (0.572)

2. Metode : Klasifikasi
   Data : Titanic Dataset

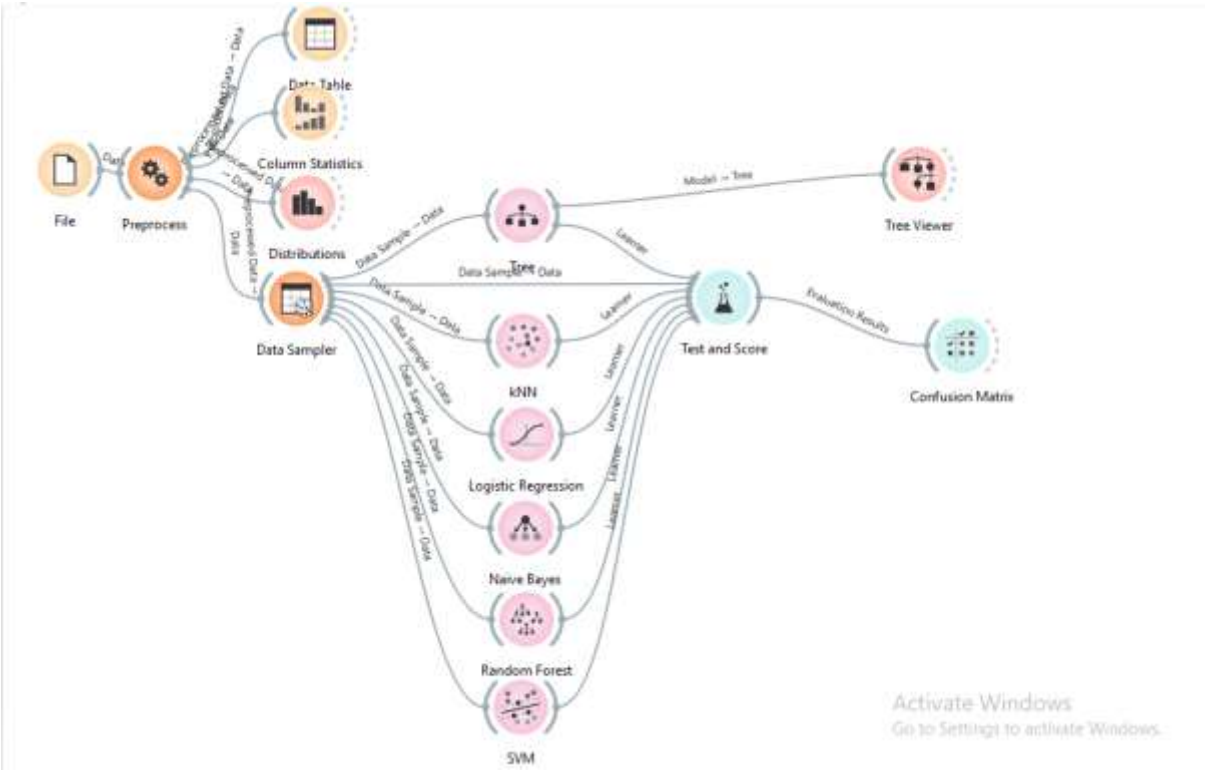

• Preprocess: Digunakan untuk melakukan normalisasi data atau pembersihan awal sebelum data diolah lebih lanjut.
• Data Sampler: Membagi dataset menjadi porsi tertentu (misalnya data latih dan data uji) untuk menguji keandalan model.
• Model Klasifikasi: Menguji berbagai algoritma sekaligus, yaitu Tree, kNN, Logistic Regression, Naive Bayes, Random Forest, dan SVM.
• Test and Score: Melakukan evaluasi performa seluruh model menggunakan teknik Cross Validation dengan 5 fold.
• Confusion Matrix: Memvisualisasikan perbandingan antara hasil prediksi model dengan data aktual untuk melihat tingkat kesalahan klasifikasi.

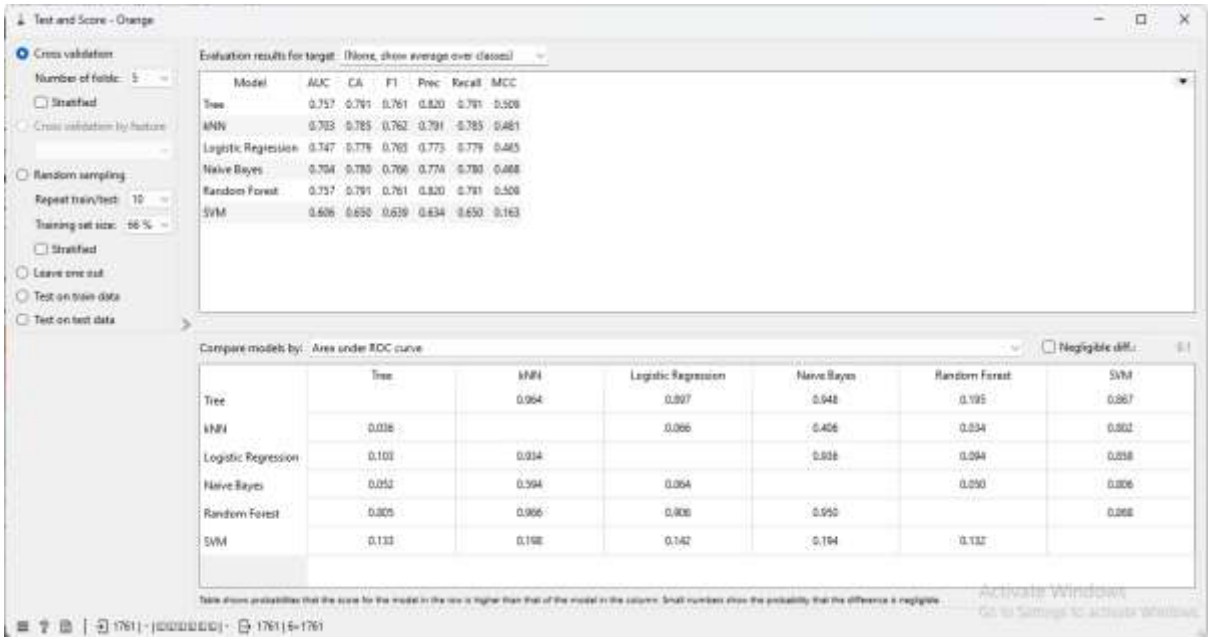

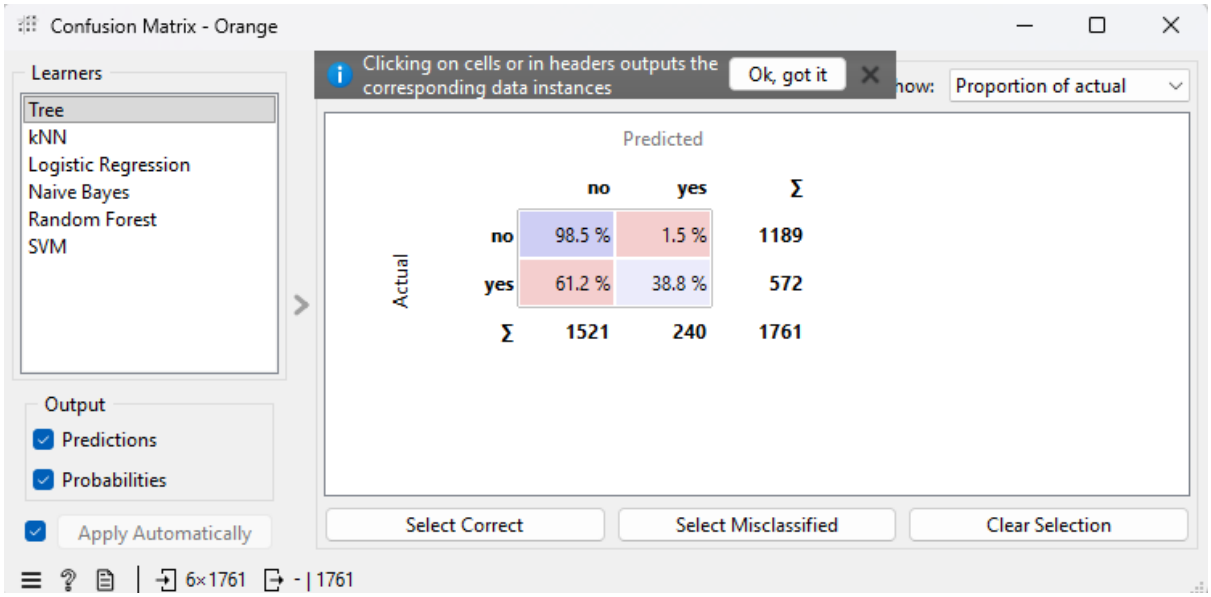

Nilai **AUC tertinggi (0.757)**
Accuracy tertinggi (0.791)
Precision, Recall, dan MCC juga paling tinggi

- **Naive Bayes**

Memiliki **F1-score tertinggi (0.766)** → cukup seimbang

- **Logistic Regression & kNN**

Performa cukup stabil, tapi tidak unggul

- **SVM**

Performa paling buruk di semua metrik

- **98.5% data "No" berhasil diprediksi dengan benar**

→ Ini menunjukkan model **sangat baik mengenali kelas "No"**

- **1.5% salah klasifikasi (False Positive)**

→ Data "No" diprediksi sebagai "Yes"

3. Metode : Clustering
   Data : Iris Dataset

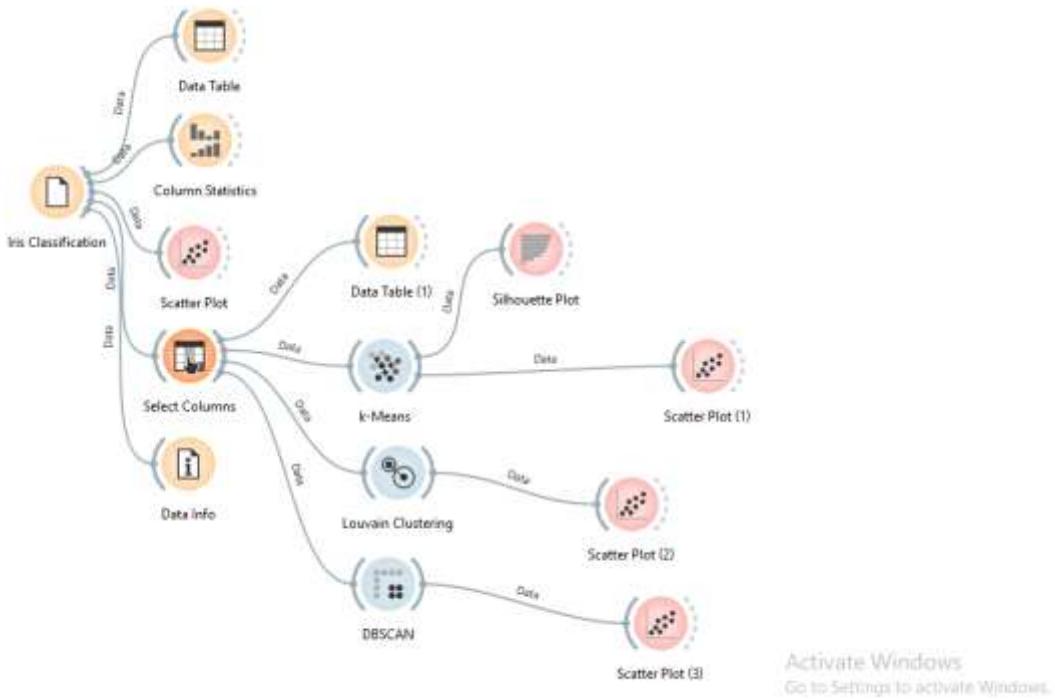

• Select Columns: Memilih fitur-fitur spesifik seperti panjang dan lebar petal/sepal untuk menentukan kemiripan antar objek.a
• Algoritma: Membandingkan tiga pendekatan berbeda: k-Means (berbasis jumlah cluster), Louvain (berbasis komunitas), dan DBSCAN (berbasis kepadatan/densitas).
• Silhouette Plot: Digunakan untuk memvalidasi seberapa kuat suatu objek berada di dalam kelompoknya.

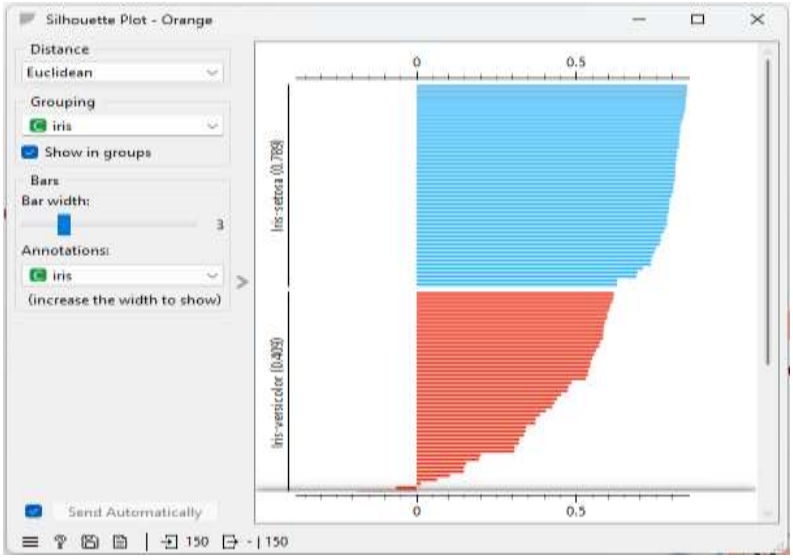

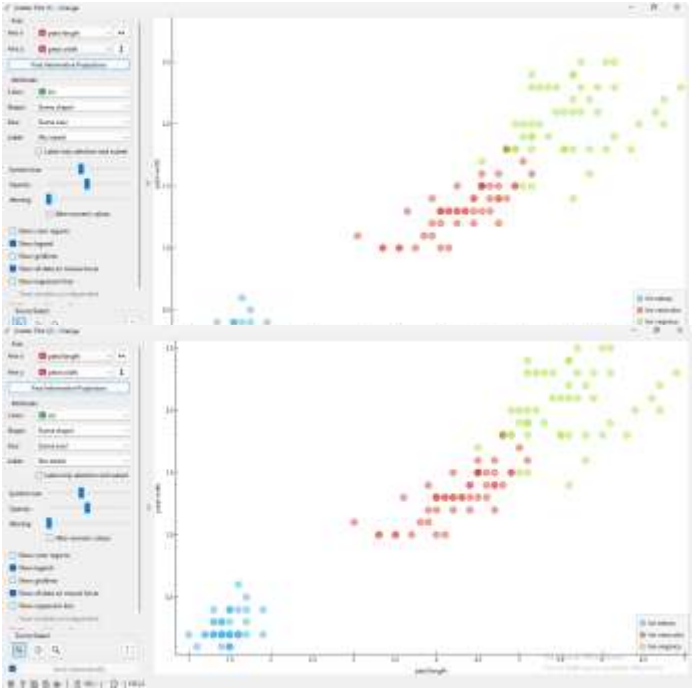

Visualisasi menggunakan scatter plot dilakukan dengan sumbu:

- **X-axis:** *petal length*
- **Y-axis:** *petal width*
- Warna menunjukkan kelas spesies bunga iris:
    - Biru: *Iris-setosa*
    - Merah: *Iris-versicolor*
    - Hijau: *Iris-virginica*

Berdasarkan scatter plot, terlihat beberapa pola penting:

1. Pemisahan Kelas yang Jelas

- **Iris-setosa** (biru):
    - Terletak di kiri bawah
    - Memiliki nilai *petal length* dan *petal width* paling kecil
    - **Terpisah sangat jelas** dari kelas lain
- **Iris-versicolor** (merah):
    - Berada di tengah
    - Nilai fitur sedang
    - Mulai ada sedikit tumpang tindih dengan *virginica*
- **Iris-virginica** (hijau):
    - Terletak di kanan atas
    - Memiliki nilai fitur terbesar
    - Sedikit overlap dengan versicolor

2. Hubungan Antar Variabel

- Terlihat adanya **korelasi positif**:
    - Semakin besar *petal length*, maka *petal width* juga meningkat
- Pola ini menunjukkan hubungan linear yang cukup kuat

3. Overlapping Data

- Overlap terjadi antara:
    - **Versicolor dan Virginica**
- Hal ini menjelaskan:
    - Mengapa beberapa model (seperti SVM) memiliki performa lebih rendah
    - Karena kedua kelas ini lebih sulit dipisahkan

Visualisasi ini mendukung hasil evaluasi sebelumnya:

- **Model Tree & Random Forest**
    - Mampu menangkap pola non-linear → performa tinggi
- **SVM**
    - Kurang optimal karena adanya overlap antar kelas
- **Naive Bayes**
    - Tetap cukup baik karena distribusi data masih terstruktur