Lailani Alifah

20124021

Pemrograman python *(Machine Learning)*

1. **Metode : Klasifikasi**

   Data : *Titanic.cvs*

CLASSIFICATION (Supervised)

(titanic.csv to train and test)

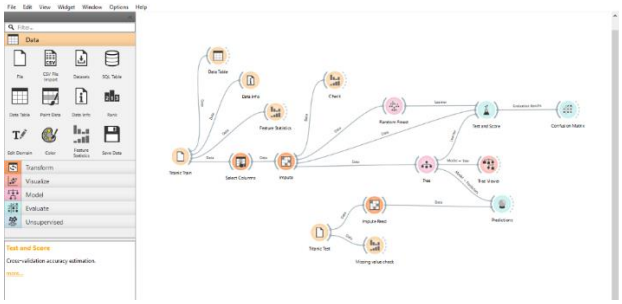

Penjelasan :

1. Workflow File (titanic.csv) Titanic train yang terhubung ke :
   - Titanic Train -> Data Table -> Feature Statistic -> Select Columns
   - Select Columns -> Impute -> Check (Feature Statistic) -> Random Forest & Tree -> Test And Score -> Confusion matrix
   - Tree – Tree Viewer & Predictions -> Impute (Read) -> Titanic.test -> Missing value Check
2. Model :
   - Random forest model untuk mengklasifikasikan data.
   - Tree Model ini belajar dari *Titanic Train* untuk memprediksi apakah penumpang selamat atau tidak.
   - Tree Model ini belajar dari *Titanic Train* untuk memprediksi apakah penumpang selamat atau tidak.

- Tree Viewer Menampilkan struktur pohon keputusan dari model *Tree*, Jadi secara keseluruhan kategori yang di ambil dari data itu dan terbagi-bagi:

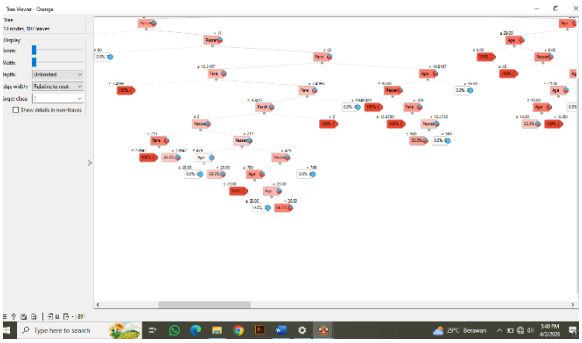

3. Hasil Akhir :

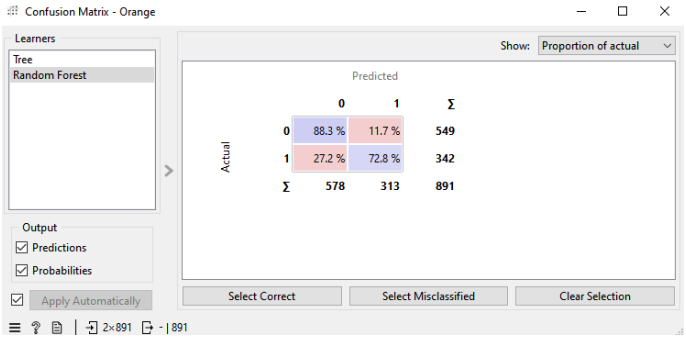

- Baris (Actual) = Data Asli
- Kolom (Predicted) = Hasil Prediksi model
- Jika biru maka True, Jika merah maka False

  Penjelasan:

  Actual = 0 (88.3% diprediksi 0 [True Positive], 11.7% diprediksi 1 [False Negative] maka actual 0 nilai akurasinya lebih tinggi)

  Actual = 1 (72,8% diprediksi 1 [True Positive], 27.2% diprediksi 0 [False Negative] sering error dibanding actual 0)

  Jadi kesimpulannya : Pada model klasifikasi menunjukan peforma yang cukup baik dengan tingkat prediksi True sebesar 88.3% pada actual 0 dan 72.8% pada Actual 1. Karena distribusinya tidak seimbang Total data adalah 891, Actual 0 = 549, sedangkan Actual 1 = 342 maka bisa mempengaruhi peforma model klasifikasi.

2. **Metode : Regression dan Clustering**

   Data : *Housing.cvs*

REGRESSION AND CLUSTERING (Supervised and Unsurvived)

(Housing.csv Regression)

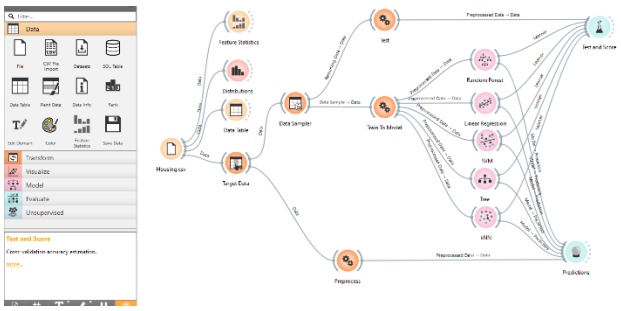

Penjelasan Regresi :

1. Workflow File (Housing.csv) yang terhubung ke :

   Feature Statistic -> Distribution -> Data Table -> Target Data (MEDV).

   Target Data -> Data Sampler -> Preprosess -> Predictions.

   Data Sample -> Test –> Train to model -> All model -> Test and Score.

2. Model yang digunakan :
   - Random Forest
   - Linear Regression
   - SVM
   - Tree
   - kNN

3. Hasil Akhir :

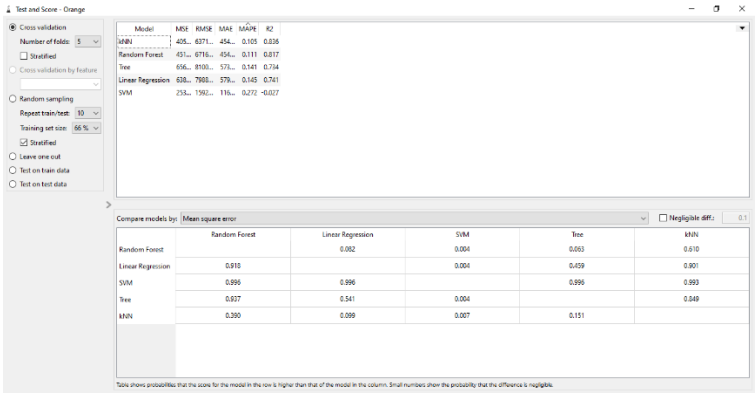

Test and Score - Orange

Cross validation
Number of folds: 5
Stratified
Cross validation by feature
Random sampling
Repeat train/test: 10
Training set size: 66 %
Stratified
Leave one out
Test on train data
Test on test data

Model	MSE	RMSE	MAE	MAPE	R2
kNN	405...	6371...	454...	0.105	0.836
Random Forest	451...	6716...	454...	0.111	0.817
Tree	656...	8100...	571...	0.141	0.734
Linear Regression	638...	7988...	579...	0.145	0.741
SVM	253...	1592...	116...	0.272	-0.027

Compare models by: Mean square error
Negligible diff.: 0.1

	Random Forest	Linear Regression	SVM	Tree	kNN
Random Forest		0.082	0.004	0.063	0.610
Linear Regression	0.910		0.004	0.459	0.901
SVM	0.996	0.996		0.996	0.993
Tree	0.937	0.541	0.004		0.849
kNN	0.390	0.099	0.007	0.151	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Kesimpulan : Pada model regresi data Housing.csv menggunakan model kNN merupakan model terbaik karena memiliki R^2 Tertinggi dan Error terendah sehingga prediksi akan akurat, Sedangkan model SVM menunjukan peforma paling buruk dengan R^2 yang negative maka tidak di rekomendasikan memakai model ini.

(Housing.csv Clustering)

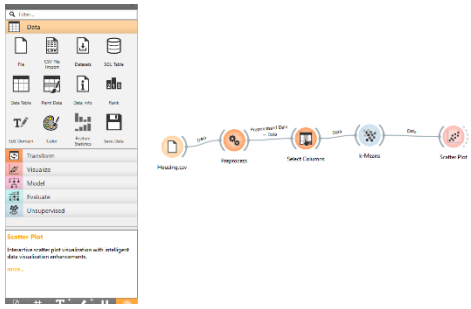

Penjelasan Clustering :

1. Workflow File (Housing.csv) yang terhubung ke :
   Housing.csv -> Preprosses -> Select columns (MEDV Tidak ditargetkan) -> K-Means -> Scatter plot.
2. Model :
   K-means = Menentukan jumlah clustering.
3. Hasil Akhir :

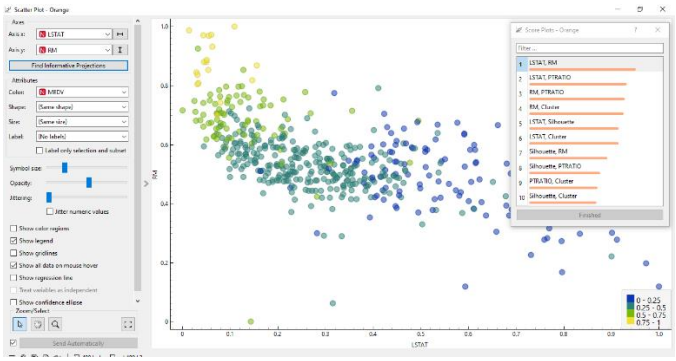

Penjelasan clustering:

Warna : Biru untuk cluster 1, Hijau cluster 2, Kuning cluster 3

Kesimpulannya :

Visualisasi dari scatter plot menunjukan bahwa data berhasil di kelompokan menjadi beberapa cluster berdasarkan kemiripan fitur.