TUGAS PEMOGRAMAN PYTON (ML)

Nama : Mendy Esa Agustina

NIM : 20124022

Kelas : C1 Informatika

1. Metode: Regresi
Data: Housing Dataset

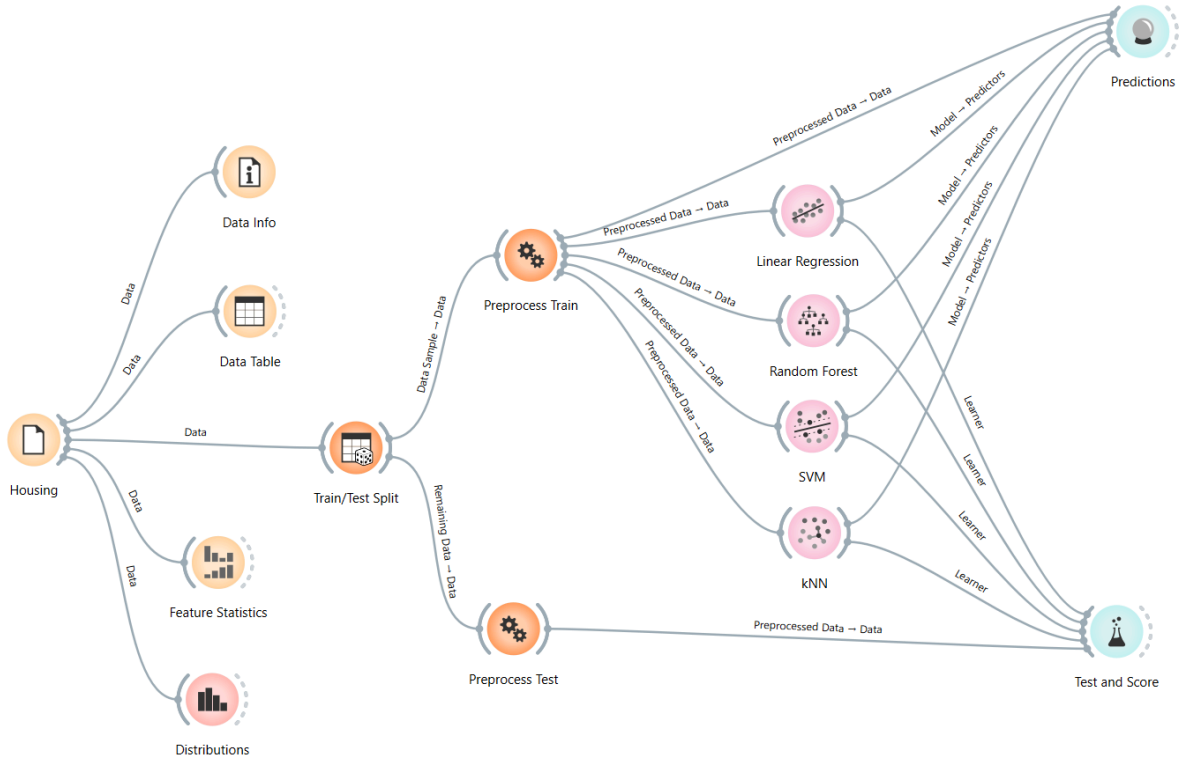

Gambar 1. Housing Workflow

1. **Input Data (Housing)**
   Dataset dimasukkan ke dalam sistem untuk dianalisis.
2. **Eksplorasi Data**
   - *Data Info*: melihat informasi umum dataset
   - *Data Table*: melihat isi data
   - *Feature Statistics*: statistik tiap fitur
   - *Distributions*: distribusi data
3. **Train/Test Split**
   Data dibagi menjadi data **training** dan **testing**.
4. **Preprocessing**
   - *Preprocess Train*: membersihkan/menyiapkan data latih

    - *Preprocess Test*: menyiapkan data uji
5. **Model Regresi yang Digunakan**
    - Linear Regression
    - Random Forest
    - SVM
    - k-NN
6. **Predictions & Test and Score**
    - *Predictions*: menghasilkan prediksi harga rumah
    - *Test and Score*: mengevaluasi performa model

workflow ini menunjukkan proses lengkap dari data mentah sampai evaluasi model.

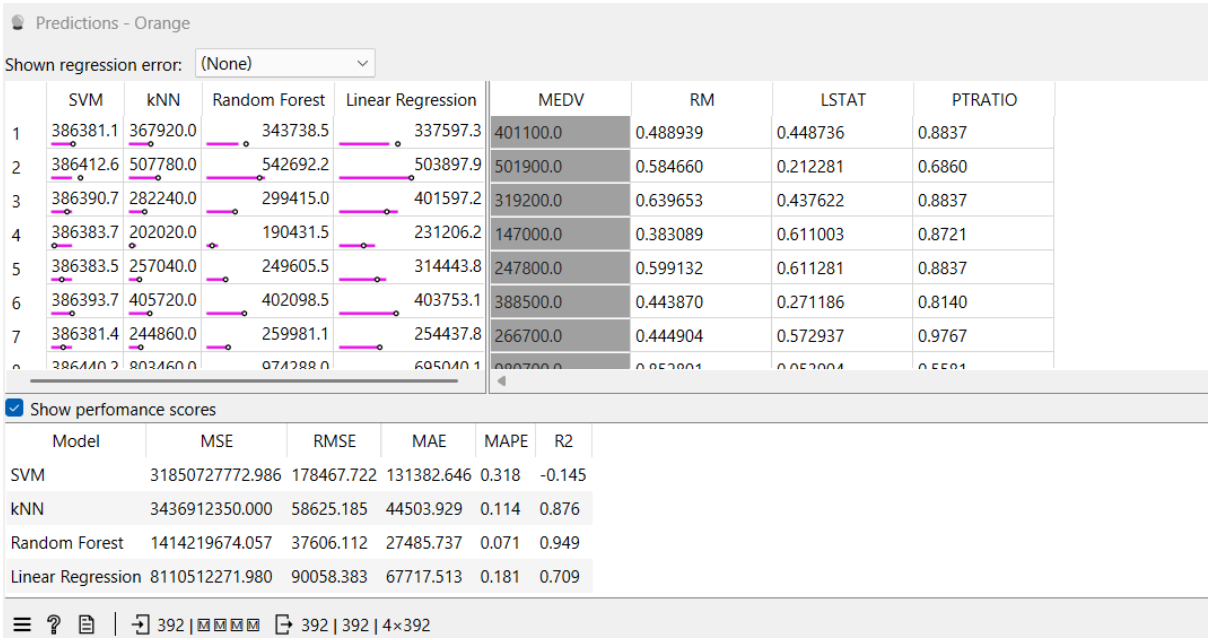

Predictions - Orange

Shown regression error: (None)

	SVM	kNN	Random Forest	Linear Regression	MEDV	RM	LSTAT	PTRATIO
1	386381.1	367920.0	343738.5	337597.3	401100.0	0.488939	0.448736	0.8837
2	386412.6	507780.0	542692.2	503897.9	501900.0	0.584660	0.212281	0.6860
3	386390.7	282240.0	299415.0	401597.2	319200.0	0.639653	0.437622	0.8837
4	386383.7	202020.0	190431.5	231206.2	147000.0	0.383089	0.611003	0.8721
5	386383.5	257040.0	249605.5	314443.8	247800.0	0.599132	0.611281	0.8837
6	386393.7	405720.0	402098.5	403753.1	388500.0	0.443870	0.271186	0.8140
7	386381.4	244860.0	259981.1	254437.8	266700.0	0.444904	0.572937	0.9767

Show perfomance scores

Model	MSE	RMSE	MAE	MAPE	R2
SVM	31850727772.986	178467.722	131382.646	0.318	-0.145
kNN	3436912350.000	58625.185	44503.929	0.114	0.876
Random Forest	1414219674.057	37606.112	27485.737	0.071	0.949
Linear Regression	8110512271.980	90058.383	67717.513	0.181	0.709

392 | 392 | 392 | 392 | 4×392

Gambar 2. Predictions Housing

1. Tabel atas menunjukkan hasil prediksi tiap model (SVM, kNN, Random Forest, Linear Regression).
2. Kolom seperti **MEDV, RM, LSTAT, PTRATIO** adalah fitur dari dataset.
3. Tabel bawah menunjukkan nilai evaluasi model, yaitu:
    - **MSE (Mean Squared Error)** → semakin kecil semakin baik
    - **RMSE** → akar dari MSE
    - **MAE (Mean Absolute Error)**
    - **MAPE** → persentase error
    - **R^2 (R-Square)** → semakin mendekati 1 semakin baik

Kesimpulan :

- **Random Forest** memiliki performa terbaik (R^2 paling tinggi 0.949, error kecil)
- **k-NN** cukup baik

- **Linear Regression** sedang
- **SVM** paling buruk (R^2 negatif → model tidak cocok)

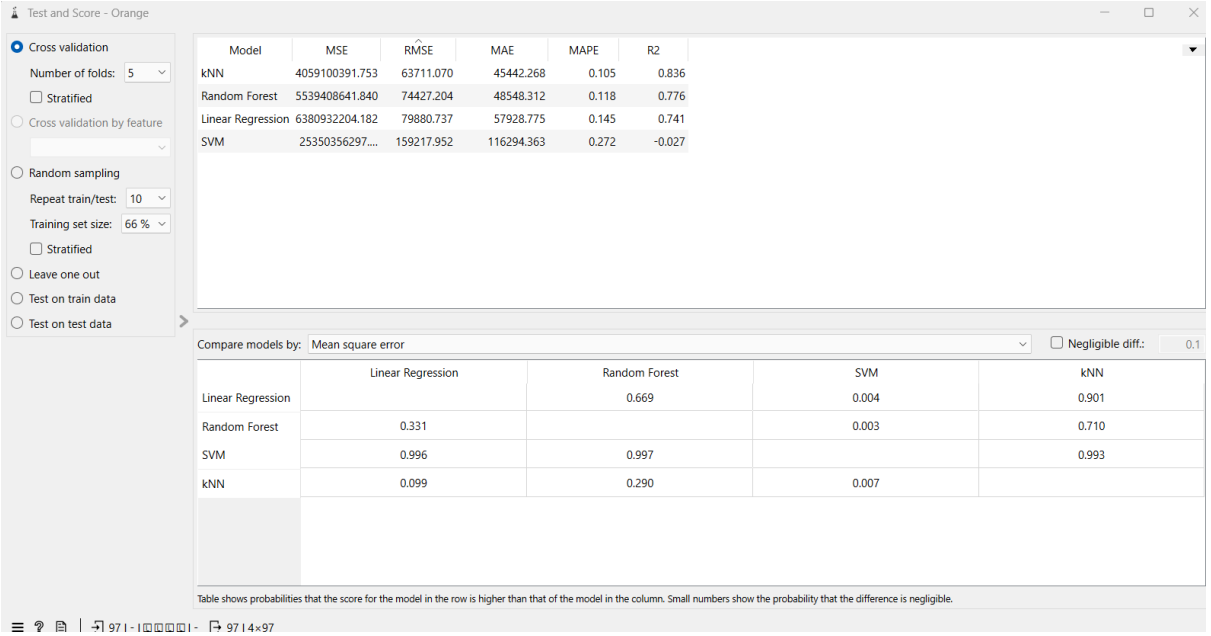

Model	MSE	RMSE	MAE	MAPE	R2
kNN	4059100391.753	63711.070	45442.268	0.105	0.836
Random Forest	5539408641.840	74427.204	48548.312	0.118	0.776
Linear Regression	6380932204.182	79880.737	57928.775	0.145	0.741
SVM	25350356297....	159217.952	116294.363	0.272	-0.027

	Linear Regression	Random Forest	SVM	kNN
Linear Regression		0.669	0.004	0.901
Random Forest	0.331		0.003	0.710
SVM	0.996	0.997		0.993
kNN	0.099	0.290	0.007	

Gambar . 3 Gambar Evaluation Test and Score Housing

1. Metode Evaluasi
   - Menggunakan **5-fold cross validation**
   - Data dibagi menjadi 5 bagian, lalu diuji bergantian
2. Hasil Evaluasi
   - **Random Forest** → performa terbaik (R^2 tinggi, error kecil, paling cocok)
   - **Linear Regression** → cukup baik
   - **k-NN** → menengah
   - **SVM** → performa paling rendah
3. Tabel Perbandingan menunjukkan perbandingan antar model berdasarkan error (MSE).

Random Forest paling konsisten dan akurat dalam memprediksi data. (model terbaik dan cocok).

2. Metode: Klasifikasi
Data: Titanic Dataset

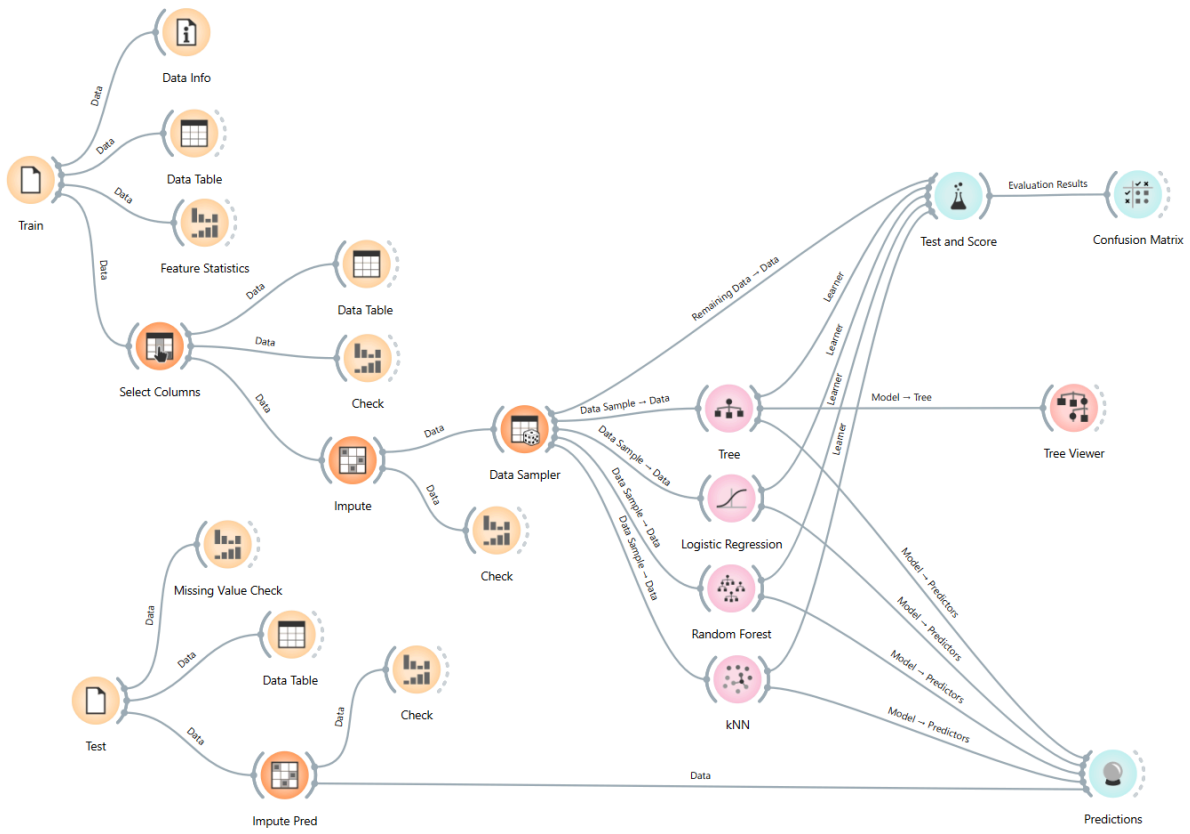

Gambar 4. Titanic Workflow

proses **klasifikasi data Titanic** dari awal sampai menghasilkan prediksi:

1. **Input Data (Train & Test)**
   - Data dibagi menjadi **data latih (train)** dan **data uji (test)**.
   - Data train digunakan untuk melatih model, sedangkan test untuk menguji hasil.
2. **Eksplorasi Data**
   - **Data Info, Data Table, Feature Statistics**
     Digunakan untuk melihat struktur data, isi dataset, dan statistik tiap fitur (umur, jenis kelamin, dll).
3. **Preprocessing**
   - **Select Columns** → memilih fitur penting (misalnya: age, sex, class).
   - **Impute** → mengisi data yang kosong (missing value).
   - **Data Sampler** → mengambil sampel data agar seimbang atau efisien.
4. **Modeling (Algoritma yang digunakan)**
   - **Decision Tree (Tree)**

    - **Logistic Regression**
    - **Random Forest**
    - **k-Nearest Neighbor (kNN)**
      Semua model dilatih menggunakan data yang sama untuk dibandingkan performanya.
5. **Evaluasi**
    - **Test & Score** → menghitung performa model.
    - **Confusion Matrix** → melihat hasil klasifikasi benar/salah.
6. **Output**
    - **Predictions** → hasil prediksi akhir dari model.

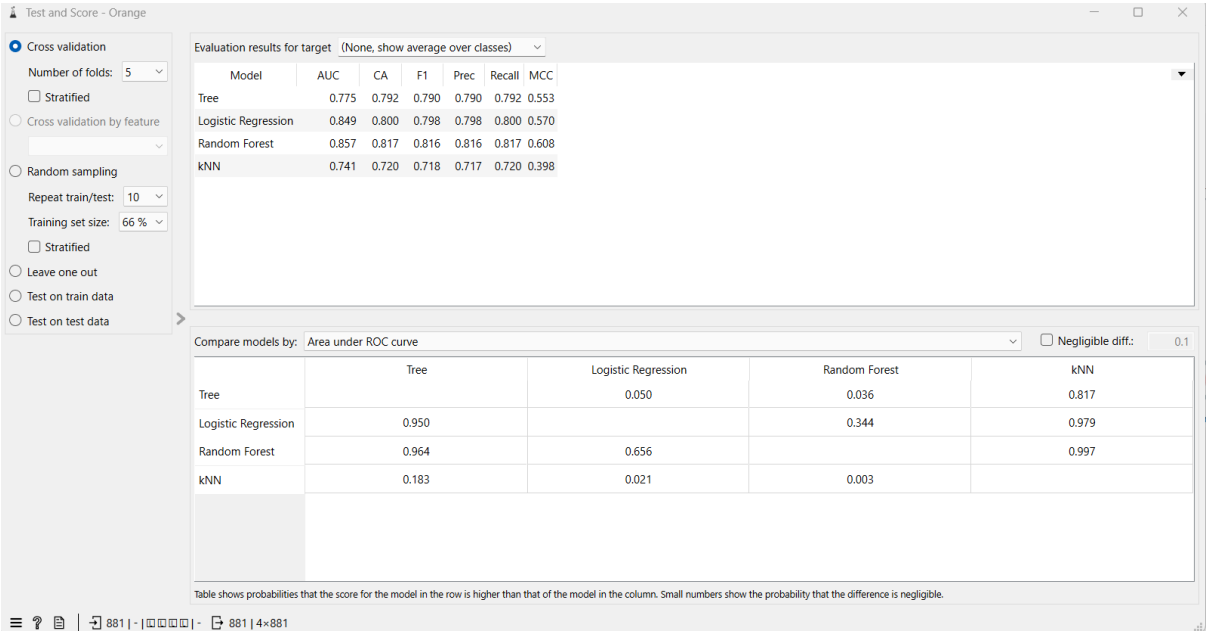

Gambar . 5 Evaluation Titanic

Hasil utama:

Terdapat beberapa metrik:

- **AUC (Area Under Curve)** → kemampuan model membedakan kelas
- **CA (Accuracy)** → tingkat akurasi
- **F1 Score** → keseimbangan precision & recall
- **Precision** → ketepatan prediksi positif
- **Recall** → kemampuan menangkap data positif
- **MCC** → korelasi prediksi vs aktual

Perbandingan model:

- **Random Forest** memiliki performa terbaik:
    - AUC = 0.857

    - Accuracy = 0.817
- **Logistic Regression** juga cukup baik
- **Tree** cukup stabil tapi di bawah RF
- **kNN** performanya paling rendah

Kesimpulan: **Random Forest adalah model terbaik** untuk dataset Titanic pada percobaan ini.

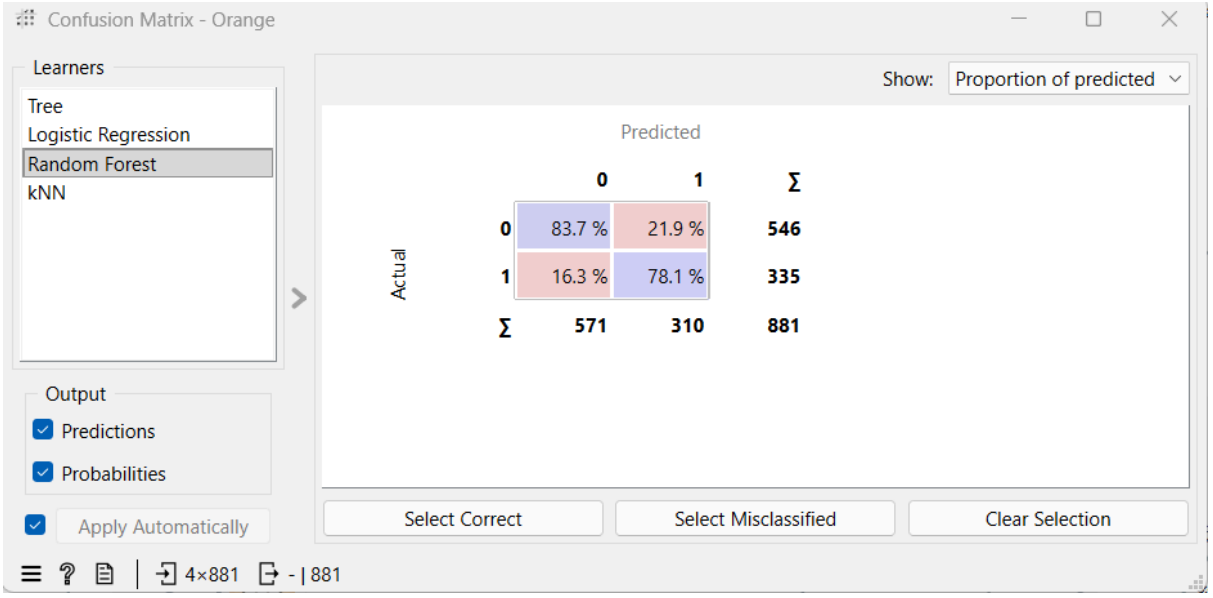

Gambar . 6 Model Evaluation Titanic Confusion Matrix

- **83.7% (True Negative)** Data yang memang tidak selamat diprediksi benar.
- **78.1% (True Positive)** Data yang selamat diprediksi benar.
- **21.9% (False Positive)** Diprediksi selamat padahal tidak.
- **16.3% (False Negative)** Diprediksi tidak selamat padahal sebenarnya selamat.

Total data:

- Total: **881 data**
- Prediksi:
    - Tidak selamat: 571
    - Selamat: 310

Kesimpulan: Model **Random Forest cukup baik**, karena:

- Akurasi tinggi
- Prediksi benar lebih dominan dibanding salah
- Kesalahan masih ada, tapi tidak terlalu besar.

3. Metode: Clustering
Data: Irish Dataset

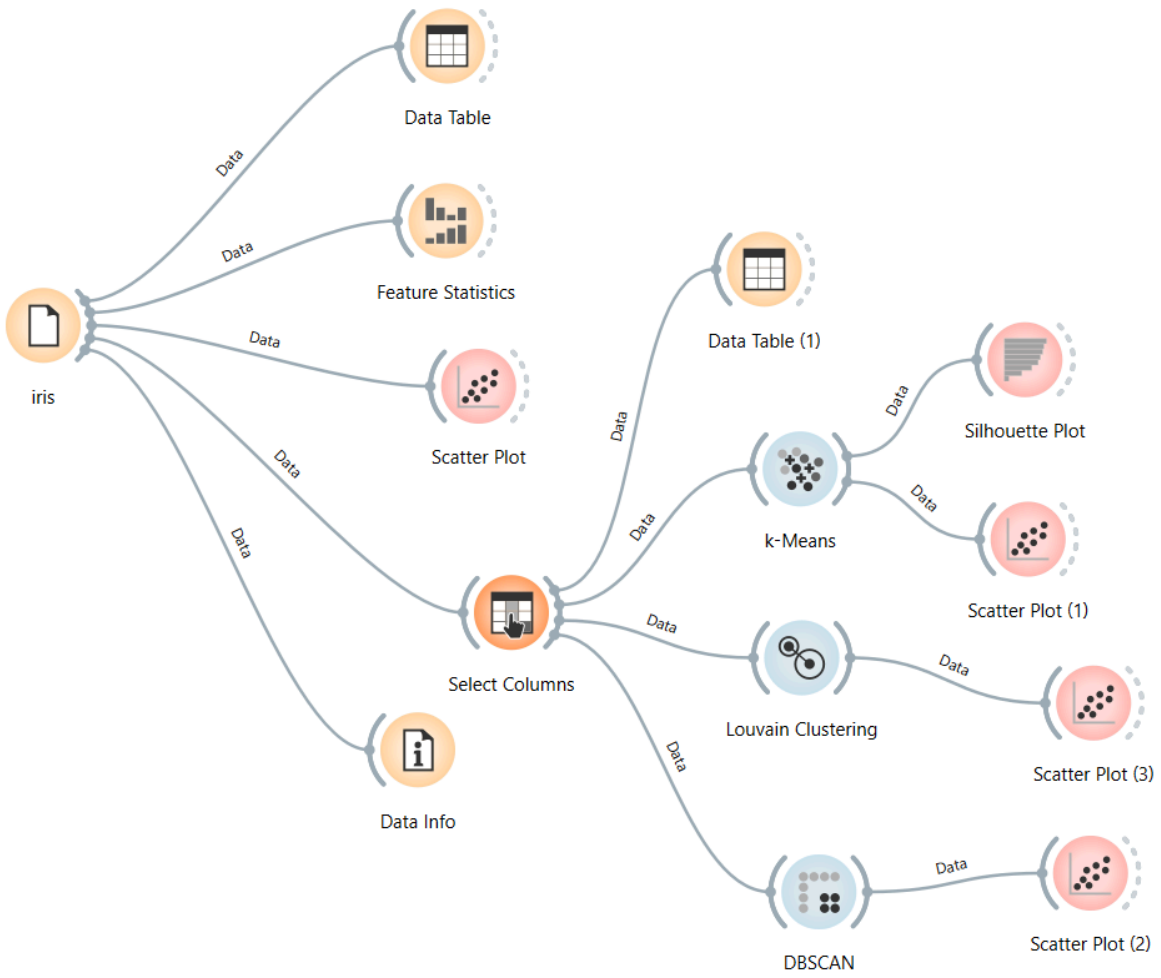

Gambar 7. iris Workflow

1. **Input Data (Iris)**
   Dataset iris dimasukkan sebagai data awal.
2. **Explorasi Data**
   - *Data Table*: melihat isi data.
   - *Feature Statistics*: melihat statistik tiap fitur.
   - *Scatter Plot*: visualisasi awal hubungan antar fitur.
3. **Select Columns**
   Memilih fitur yang digunakan (misalnya *petal width* dan *sepal length*).
4. **Proses Clustering**

- **K-Means** → membagi data ke dalam beberapa cluster berdasarkan jarak.
- **Louvain Clustering** → metode berbasis graph.
- **DBSCAN** → berbasis kepadatan data.

5. **Evaluasi & Visualisasi**
   - *Silhouette Plot* → mengevaluasi kualitas cluster.
   - *Scatter Plot* → melihat hasil pengelompokan secara visual.

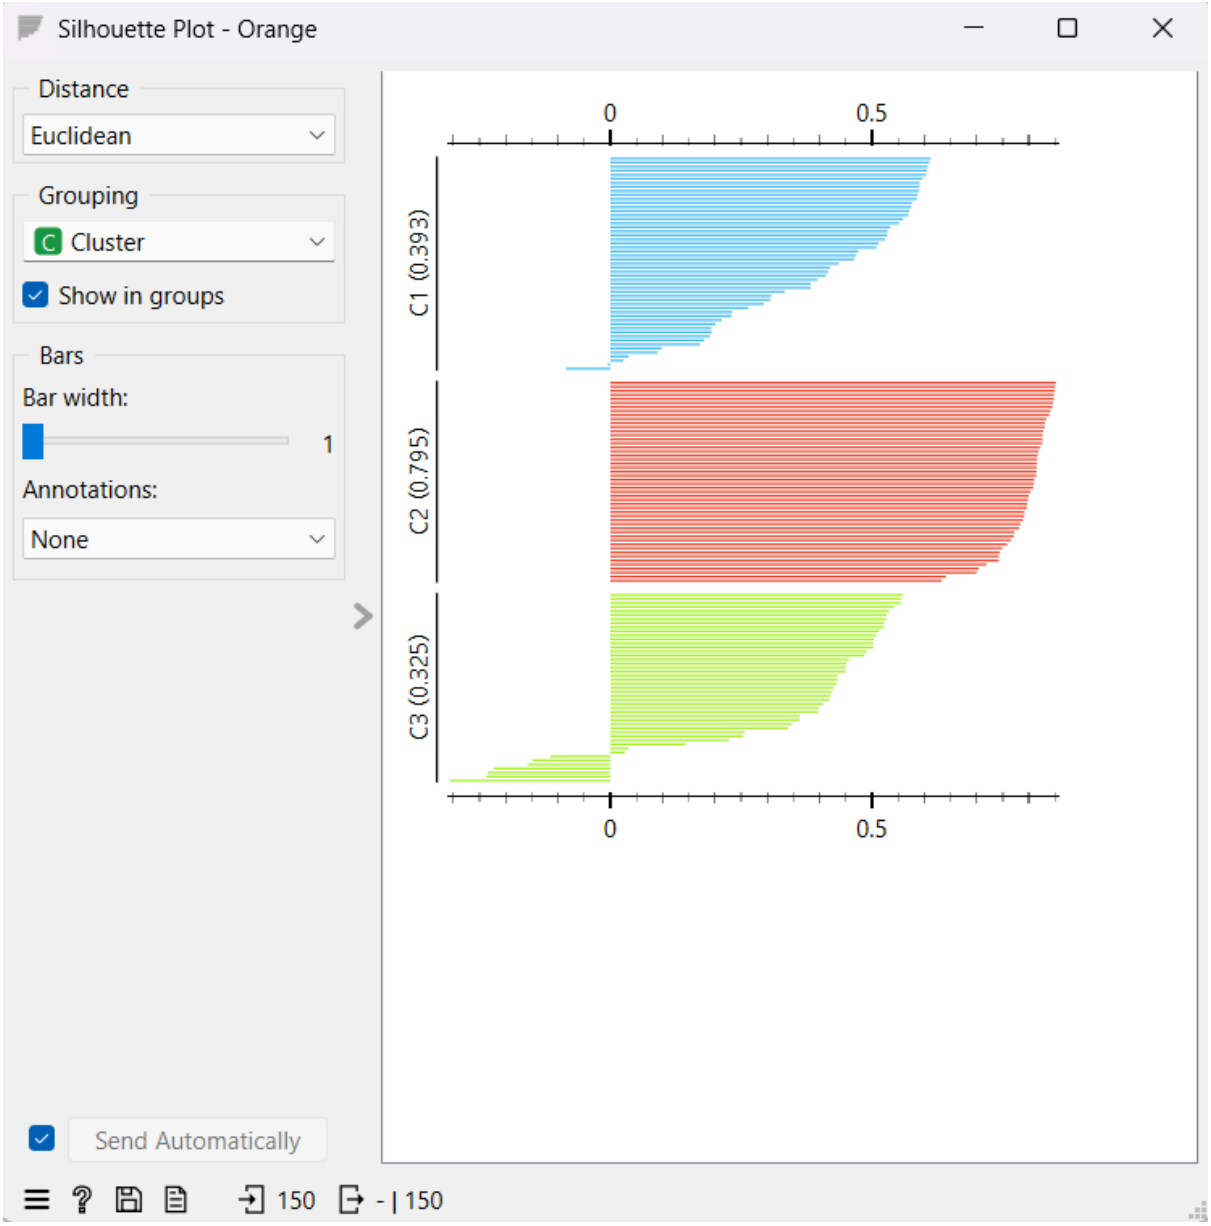

Gambar . 8 Silhouette Plot (Evaluasi K-Means)

- Menampilkan kualitas cluster menggunakan **silhouette score**.
- Terlihat 3 cluster (C1, C2, C3).
- Nilai mendekati **1** → cluster baik (data jelas terpisah).

- Nilai mendekati **0 atau negatif** → cluster kurang baik / tumpang tindih.

Interpretasi:

- Cluster C2 memiliki nilai tinggi → paling baik terpisah.
- Cluster C1 dan C3 masih ada overlap → pemisahan belum sempurna.

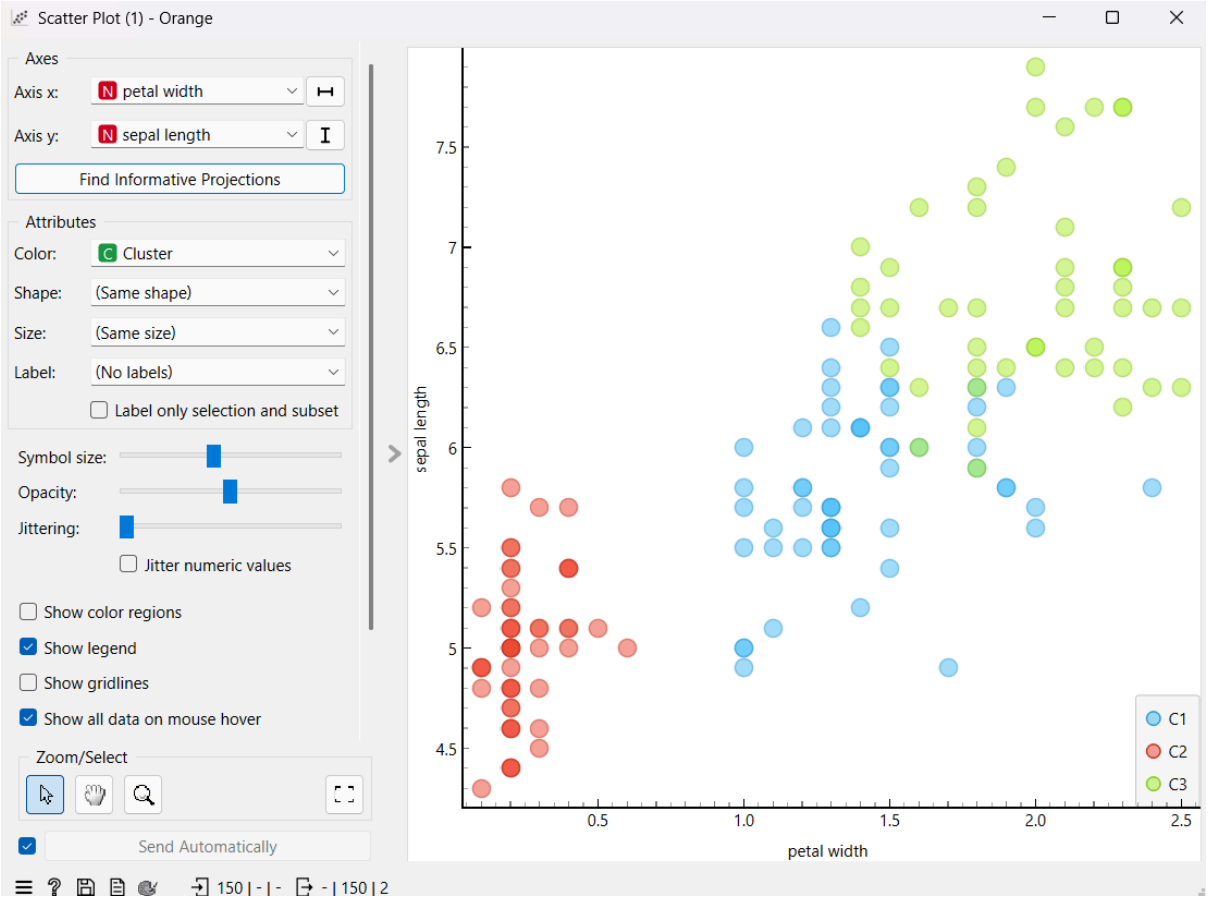

Gambar . 9 Scatter Plot (K-Means, 3 Cluster)

- Data dibagi menjadi 3 cluster (C1, C2, C3).
- Sumbu:
  - X: *petal width*
  - Y: *sepal length*

Interpretasi:

- Cluster C1 (biru) terpisah jelas → kemungkinan *setosa*.
- Cluster C2 dan C3 mulai terlihat overlap → mirip *versicolor* & *virginica*.
- K-Means cukup baik, tapi belum sempurna memisahkan semua kelas.

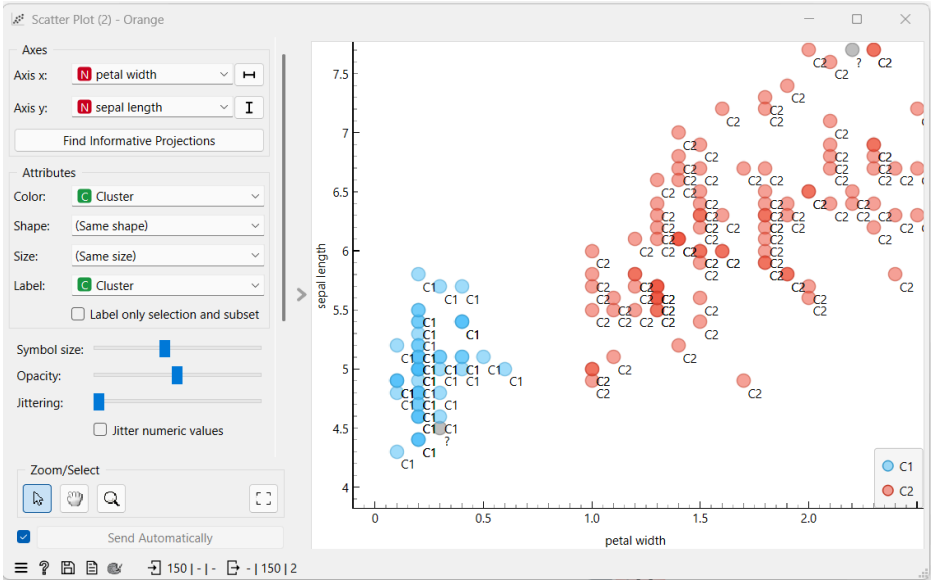

Gambar . 10 Scatter Plot (DBSCAN)

- DBSCAN menghasilkan **2 cluster (C1 dan C2)**.

Interpretasi:

- DBSCAN hanya mendeteksi dua kelompok besar.
- Data yang seharusnya 3 kelas digabung → kurang cocok untuk dataset iris.
- Cocok untuk data berbentuk cluster padat, tapi kurang optimal di sini.

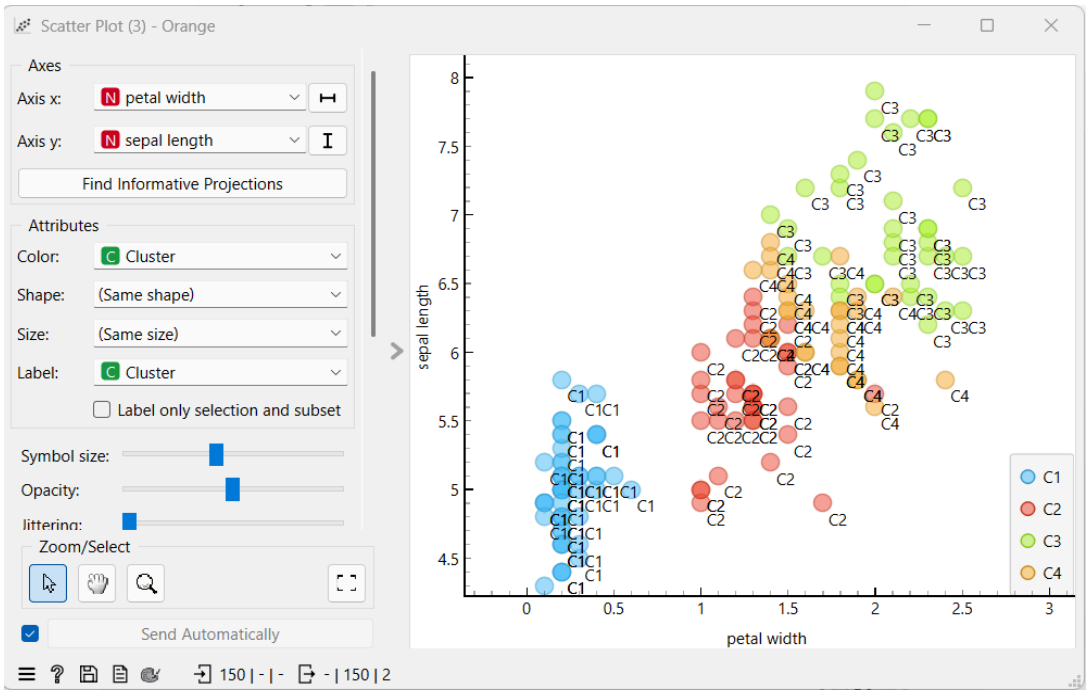

Gambar . 11 Scatter Plot (Louvain Clustering)

- Menghasilkan **4 cluster (C1, C2, C3, C4)**.

Interpretasi:

- Cluster lebih banyak dari jumlah asli (3 kelas).
- Beberapa cluster tampak terpecah (over-segmentation).
- Menunjukkan metode ini terlalu sensitif pada struktur data.

Kesimpulan Umum

- **K-Means** → paling mendekati struktur asli (3 kelas iris).
- **DBSCAN** → terlalu sederhana (hanya 2 cluster).
- **Louvain** → terlalu kompleks (menjadi 4 cluster).
- **Silhouette Plot** membantu menentukan kualitas clustering.