Tugas 1 Machine Learning

Nama: Muhafidz Ikram Ramadhan
Kelas: C1.24 Informatika
NPM: 20124025

Metode: Regresi
Data: Housing DataSet

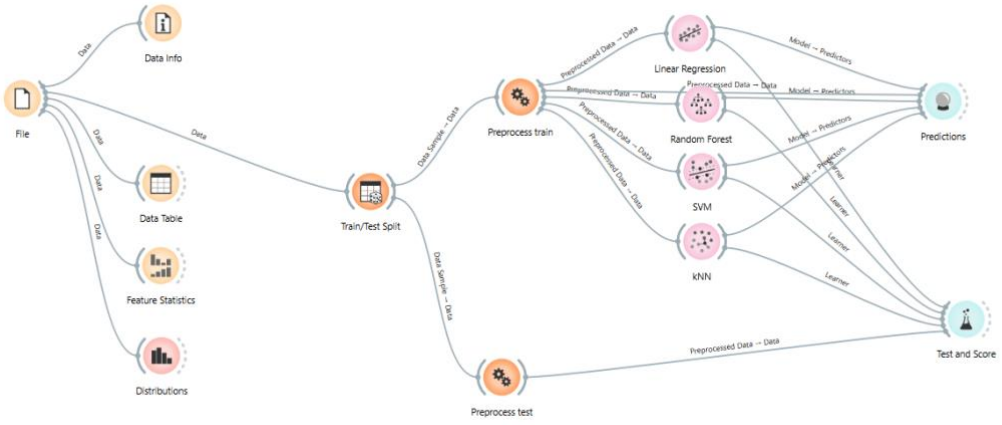

Gambar 1. Housing Workflow

- **File & Data Info:** Tahap input data. Di sini dataset perumahan dimasukkan dan dicek karakteristiknya (berapa jumlah baris, kolom, dan variabel targetnya).
- **Train/Test Split:** Data dibagi menjadi dua: data untuk melatih model (*training*) dan data untuk menguji akurasi model (*testing*). Ini penting supaya kita tahu apakah model benar-benar pintar atau cuma menghafal data.
- **Preprocess (Train & Test):** Proses pembersihan data, seperti menangani data yang hilang atau menormalkan skala angka agar model bekerja lebih optimal.
- **Model (LR, RF, SVM, kNN):** Empat algoritma berbeda digunakan untuk mencari pola hubungan antara fitur rumah (seperti jumlah kamar, lokasi) dengan harga rumah (**MEDV**).
- **Predictions & Test and Score:** Tahap evaluasi untuk melihat hasil angka prediksi dan statistik keakuratannya.

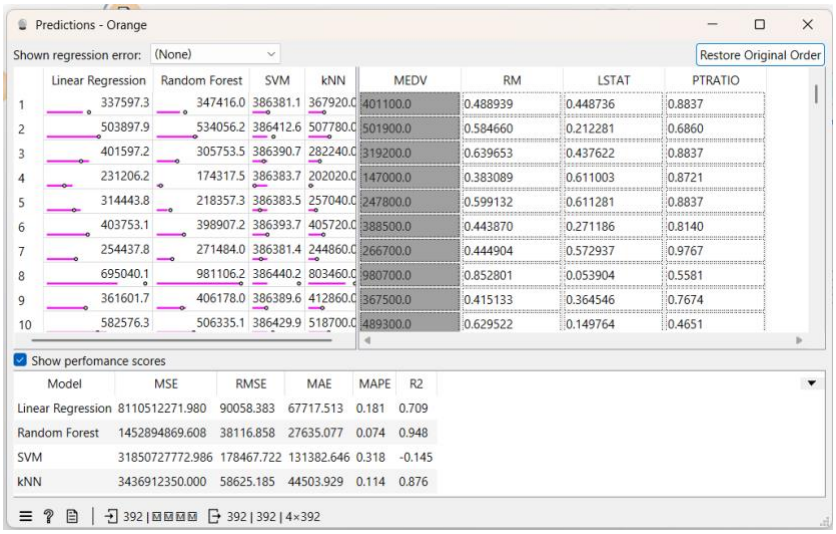

Predictions - Orange

Shown regression error: (None) | Restore Original Order

	Linear Regression	Random Forest	SVM	kNN	MEDV	RM	LSTAT	PTRATIO
1	337597.3	347416.0	386381.1	367920.0	401100.0	0.488939	0.448736	0.8837
2	503897.9	534056.2	386412.6	507780.0	501900.0	0.584660	0.212281	0.6860
3	401597.2	305753.5	386390.7	282240.0	319200.0	0.639653	0.437622	0.8837
4	231206.2	174317.5	386383.7	202020.0	147000.0	0.383089	0.611003	0.8721
5	314443.8	218357.3	386383.5	257040.0	247800.0	0.599132	0.611281	0.8837
6	403753.1	398907.2	386393.7	405720.0	388500.0	0.443870	0.271186	0.8140
7	254437.8	271484.0	386381.4	244860.0	266700.0	0.444904	0.572937	0.9767
8	695040.1	981106.2	386440.2	803460.0	980700.0	0.852801	0.053904	0.5581
9	361601.7	406178.0	386389.6	412860.0	367500.0	0.415133	0.364546	0.7674
10	582576.3	506335.1	386429.9	518700.0	489300.0	0.629522	0.149764	0.4651

Show perfomance scores

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	8110512271.980	90058.383	67717.513	0.181	0.709
Random Forest	1452894869.608	38116.858	27635.077	0.074	0.948
SVM	31850727772.986	178467.722	131382.646	0.318	-0.145
kNN	3436912350.000	58625.185	44503.929	0.114	0.876

392 | 392 | 392 | 4×392

Gambar 2. Predictions

- **Kolom MEDV (Abu-abu):** Ini adalah **Harga Asli** rumah dalam dataset.
- **Kolom Linear Regression s/d kNN:** Ini adalah **Harga Tebakan** dari masing-masing model.
- **Analisis Visual:** Kamu bisa lihat di baris 8, harga asli adalah **980.700**.
    - **Random Forest** menebak **981.106** (sangat mirip/akurat).
    - **SVM** menebak **386.440** (sangat jauh/tidak akurat).
- **Garis Pink:** Menunjukkan margin error. Semakin pendek garisnya terhadap titik, semakin akurat prediksinya.

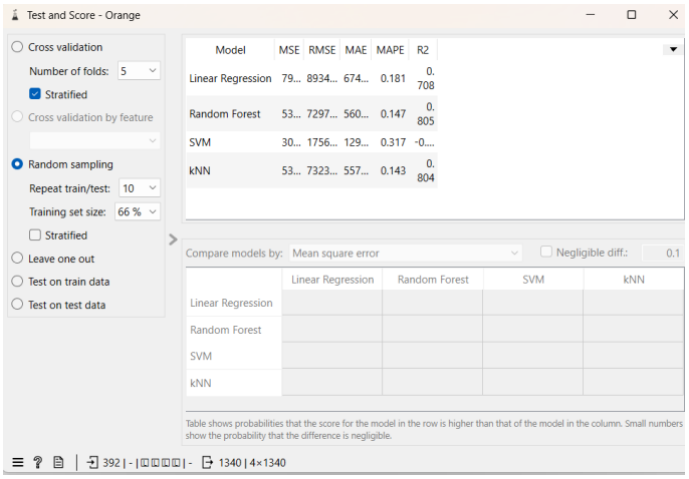

Test and Score - Orange

Cross validation
Number of folds: 5
Stratified
Cross validation by feature
Random sampling
Repeat train/test: 10
Training set size: 66 %
Stratified
Leave one out
Test on train data
Test on test data

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	79...	8934...	674...	0.181	0.708
Random Forest	53...	7297...	560...	0.147	0.805
SVM	30...	1756...	129...	0.317	-0....
kNN	53...	7323...	557...	0.143	0.804

Compare models by: Mean square error | Negligible diff.: 0.1

	Linear Regression	Random Forest	SVM	kNN
Linear Regression				
Random Forest				
SVM				
kNN				

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

392 | - | - | 1340 | 4×1340

Gambar 3 .Test and Score (Statistik Performa)

- **R^2 (R-Squared):** Nilai paling penting. Skor 1.0 berarti sempurna.
    - **Random Forest (0.805 atau 0.948 di gambar lain):** Menunjukkan performa tertinggi. Model ini mampu menjelaskan pola data dengan sangat baik.
    - **SVM (-0.145):** Nilai minus berarti model ini "gagal total" karena hasil prediksinya lebih buruk daripada sekadar menebak rata-rata.

- **MAE (Mean Absolute Error):** Rata-rata kesalahan dalam satuan harga.
- **RMSE (Root Mean Square Error):** Mirip dengan MAE, tapi memberikan "hukuman" lebih berat untuk kesalahan prediksi yang besar.
- **MAPE (Mean Absolute Percentage Error):** Kesalahan dalam bentuk persentase.

Metode: Klasifikasi

Data: Titanic DataSet

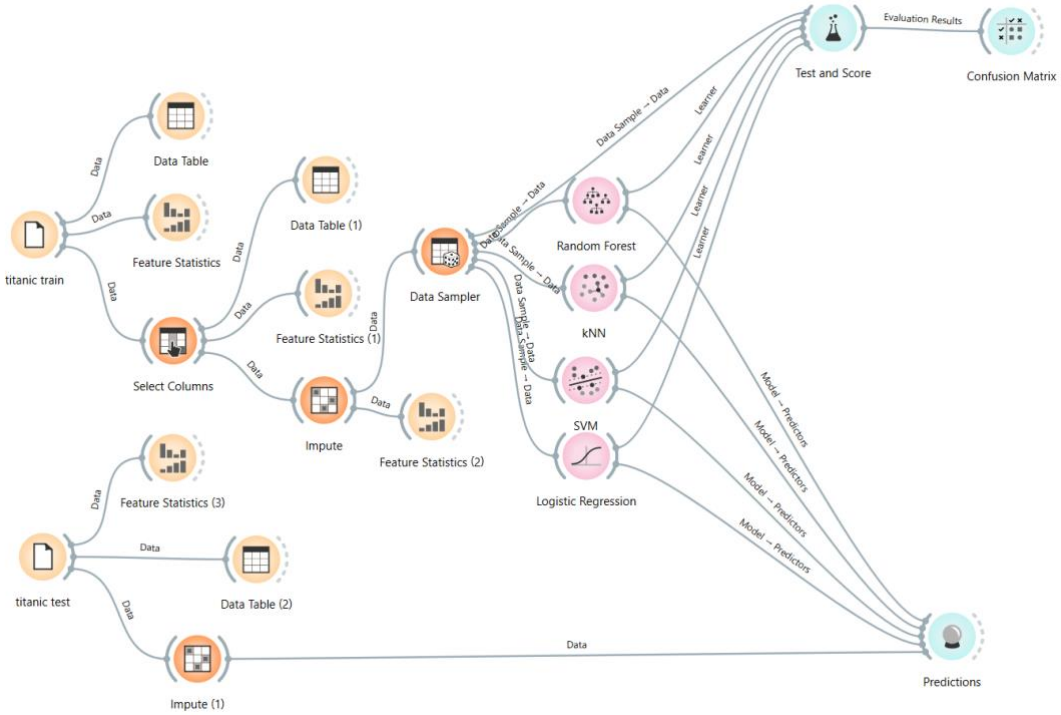

Gambar 1. Titanic WorkFlow

- **Data Sampler:** Digunakan untuk membagi data menjadi set pelatihan dan set pengujian.
- **Impute:** Ini bagian penting! Dataset Titanic banyak memiliki data kosong (misal: usia penumpang yang tidak tercatat). *Impute* berfungsi mengisi data kosong tersebut secara otomatis agar model tidak error.
- **Model (Random Forest, kNN, SVM, Logistic Regression):** Kamu mengadu empat algoritma klasifikasi untuk melihat mana yang paling akurat menebak nasib penumpang.
- **Confusion Matrix:** Widget tambahan untuk melihat detail salah tebak model (mana yang harusnya selamat tapi ditebak tidak, dan sebaliknya)

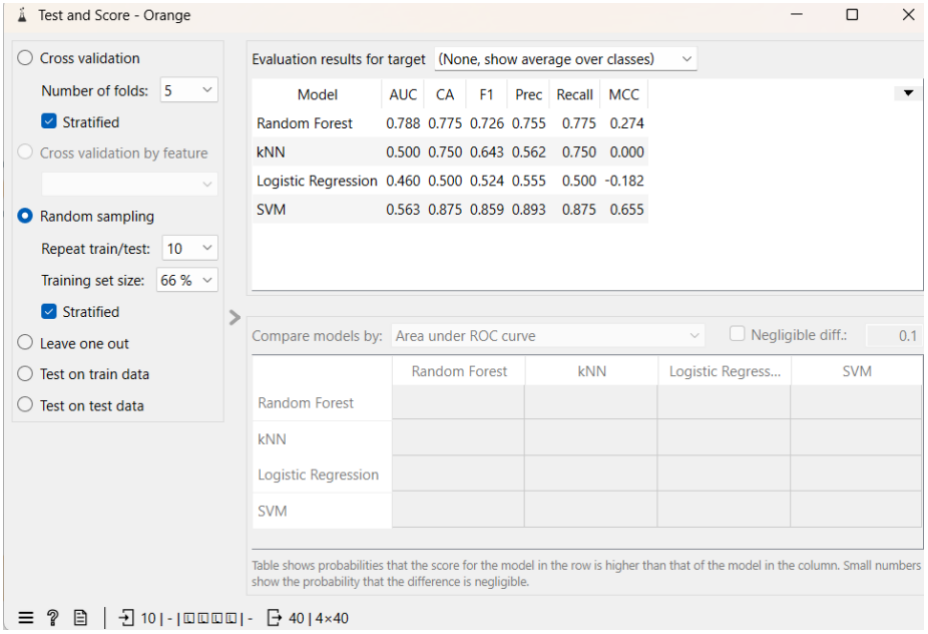

Gambar 2 Test and Score

- **AUC (Area Under ROC):** Semakin mendekati **1**, semakin bagus model membedakan antara yang selamat dan tidak. **Random Forest (0.788)** memimpin di sini.
- **CA (Classification Accuracy):** Persentase tebakan yang benar secara keseluruhan.
- **Random Forest (0.725)** artinya sekitar 72.5% penumpang berhasil ditebak nasibnya dengan benar.
- **F1, Precision, & Recall:** Metrik untuk melihat seberapa stabil model dalam menebak kelas spesifik (terutama kelas "Selamat"). Secara umum, Random Forest menunjukkan performa paling stabil dibanding Logistic Regression atau SVM yang nilainya lebih rendah

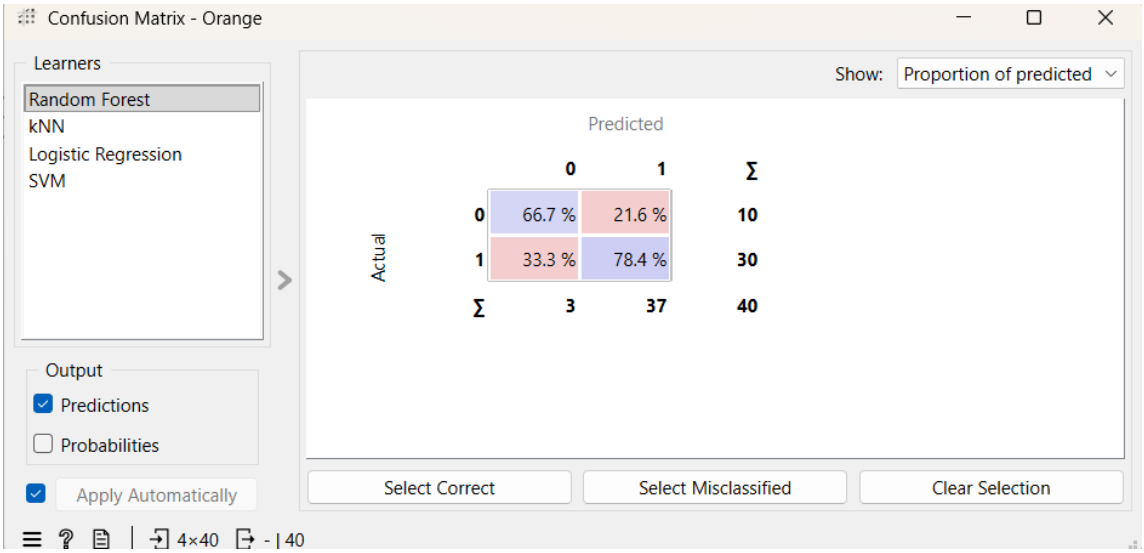

Gambar 3. Confusion Matrix

- **Angka 78.4% (Baris 1, Kolom 1):** Artinya model berhasil menebak dengan benar penumpang yang memang **Selamat**.
- **Angka 66.7% (Baris 0, Kolom 0):** Artinya model benar menebak penumpang yang **Tidak Selamat**.
- **Diagonal Salah (21.6% dan 33.3%):** Ini adalah tingkat *error* atau salah tebak model. Misalnya, ada penumpang yang aslinya tidak selamat, tapi model mengira dia selamat

Metode: Clustering

Data: Iris DataSet

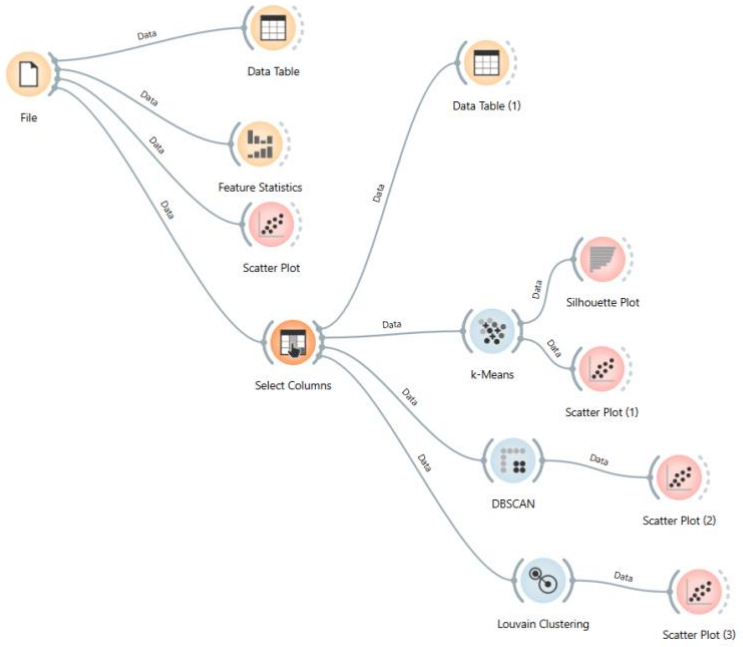

Gambar 1 Clustering WorkFlow

- **File & Select Columns:** Mengambil data Iris dan memilih fitur yang akan digunakan (biasanya panjang/lebar kelopak dan sepal).
- **K-Means, DBSCAN, & Louvain Clustering:** Kamu menggunakan tiga algoritma clustering yang berbeda untuk melihat bagaimana masing-masing mengelompokkan data.
- **Silhouette Plot:** Digunakan untuk mengevaluasi seberapa bagus kualitas pengelompokannya. Semakin tinggi nilainya, berarti data dalam satu kelompok sudah sangat mirip dan terpisah jauh dari kelompok lain.
- **Scatter Plot (1, 2, 3):** Digunakan untuk memvisualisasikan hasil pengelompokan dari masing-masing algoritma dalam bentuk titik koordinat.

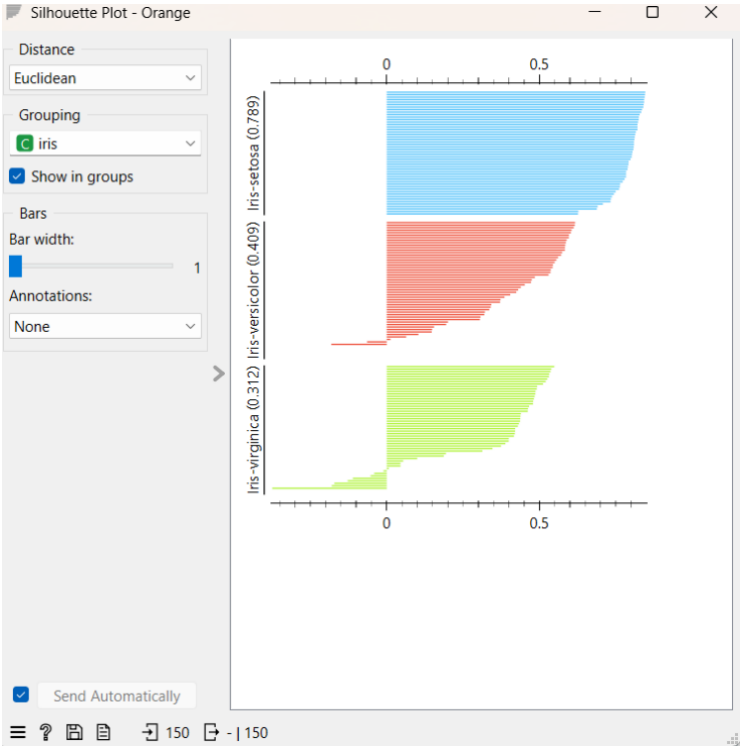

Gambar 2. Silhouette Plot (Iris Dataset)

Grafik ini mengukur seberapa tepat data masuk ke kelompoknya (**Cluster**). Skor berkisar dari **-1 hingga 1**.

- **Skor mendekati 1:** Data sudah berada di kelompok yang sangat tepat.
- **Skor mendekati 0 / Negatif:** Data berada di perbatasan atau salah masuk kelompok.

Hasil Analisis:

1. **Iris-setosa (Biru - 0.789):** Kelompok paling sempurna. Semua data terpisah sangat jelas dari jenis lainnya.
2. **Iris-versicolor (Merah - 0.409):** Cukup baik, namun ada sedikit tumpang tindih dengan kelompok lain.
3. **Iris-virginica (Hijau - 0.312):** Paling sulit dibedakan. Banyak data yang mirip dengan *versicolor* sehingga skornya paling rendah.

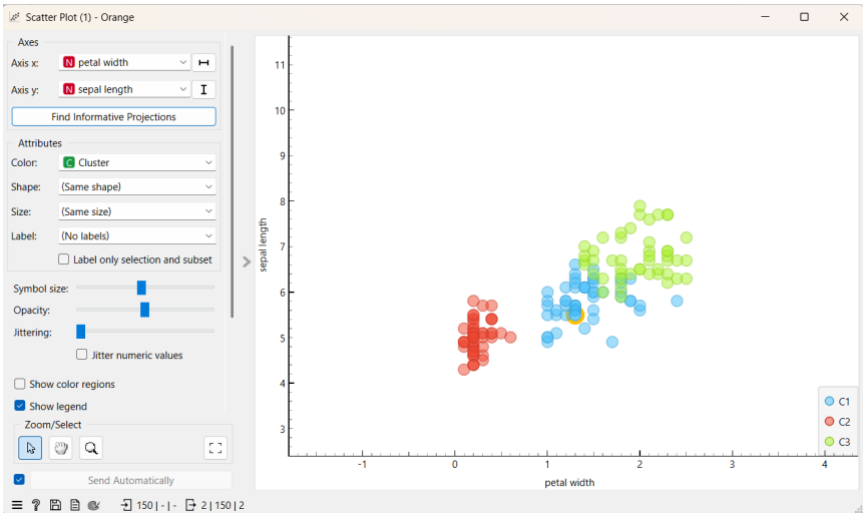

Gambar 3. Scatter Plot

(Warna Merah, Biru, Hijau):
Ini kemungkinan hasil dari **K-Means** dengan k=3.

- Pengelompokannya terlihat sangat rapi dan terbagi jelas menjadi tiga area. Kelompok merah terpisah jauh (biasanya ini Iris-Setosa), sementara biru dan hijau agak berdekatan tapi tetap terpisah.

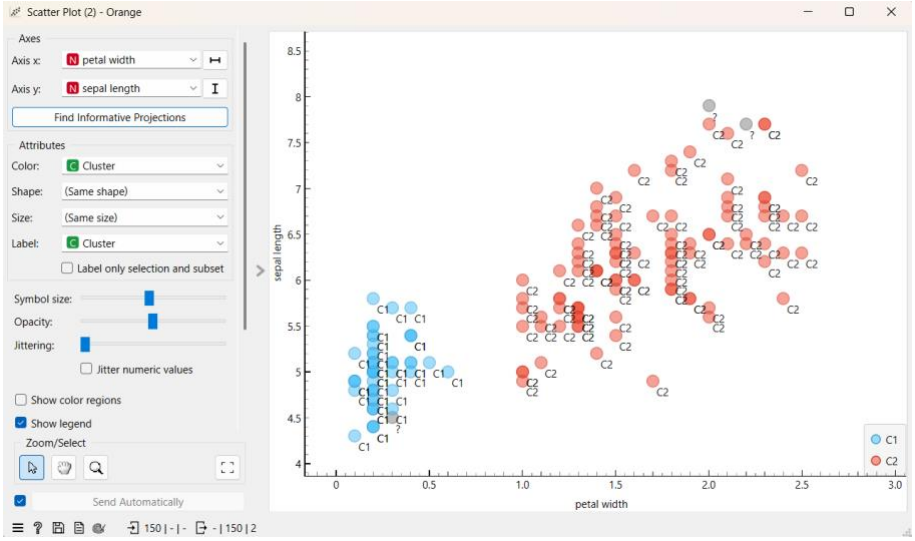

Gambar 3. scatter Plot 2

(Warna Biru & Merah): Di sini hanya terlihat dua warna utama (C1 dan C2).

- Ini berarti algoritma tersebut menganggap data Iris lebih cocok dibagi menjadi 2 kelompok saja, atau parameter jumlah *cluster*-nya diatur ke 2.

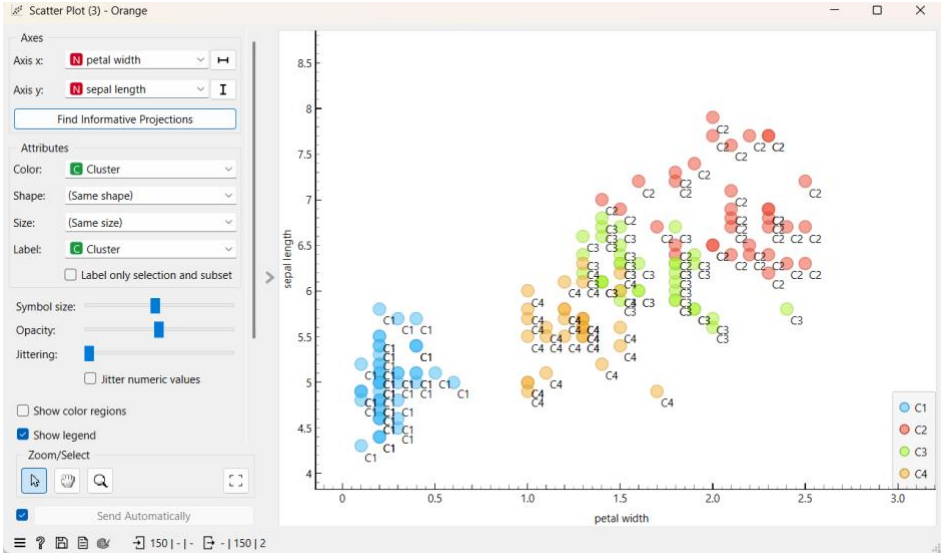

Gambar 4. Scatter Plot

(Warna-warni Banyak Titik): Terlihat lebih banyak warna (C1 sampai C4 atau lebih).

- Ini bisa terjadi jika menggunakan algoritma seperti **DBSCAN** dengan parameter tertentu, atau **Louvain** yang mencoba menemukan sub-kelompok yang lebih detail. Titik-titik yang warnanya berbeda di area yang sama menunjukkan algoritma ini lebih "sensitif" terhadap kepadatan data.