Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

Metode: Klasifikasi
Data: Titanic Dataset

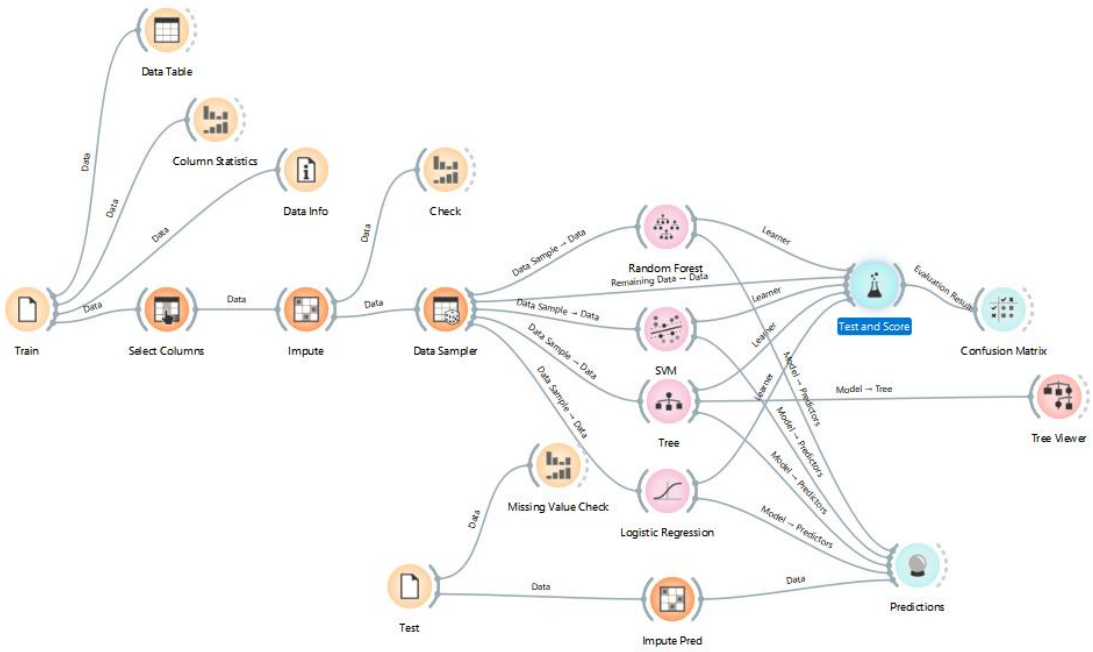

Gambar 1. Titanic Workflow

1. **Persiapan (Data Prep):** Mengambil data penumpang (**Train & Test**), mengecek kualitasnya, memilih info penting saja (seperti umur/gender), dan menambal data yang bolong-bolong (**Impute**).
2. **Latihan (Sampling):** Membagi data latihan menjadi dua bagian (**Data Sampler**) untuk simulasi ujian kecil agar model tidak cuma menghafal.
3. **Belajar (Modeling):** Mengadu 4 jenis "otak" buatan (**Random Forest, SVM, Tree, Logistic Regression**) untuk mempelajari pola siapa yang selamat dan siapa yang tidak.
4. **Ujian (Evaluation):** Mengukur kecerdasan tiap model (**Test and Score**) dan melihat detail kesalahan tebakannya (**Confusion Matrix**).
5. **Hasil (Prediction):** Menggunakan model terbaik untuk menebak nasib penumpang baru di data ujian yang sebenarnya.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

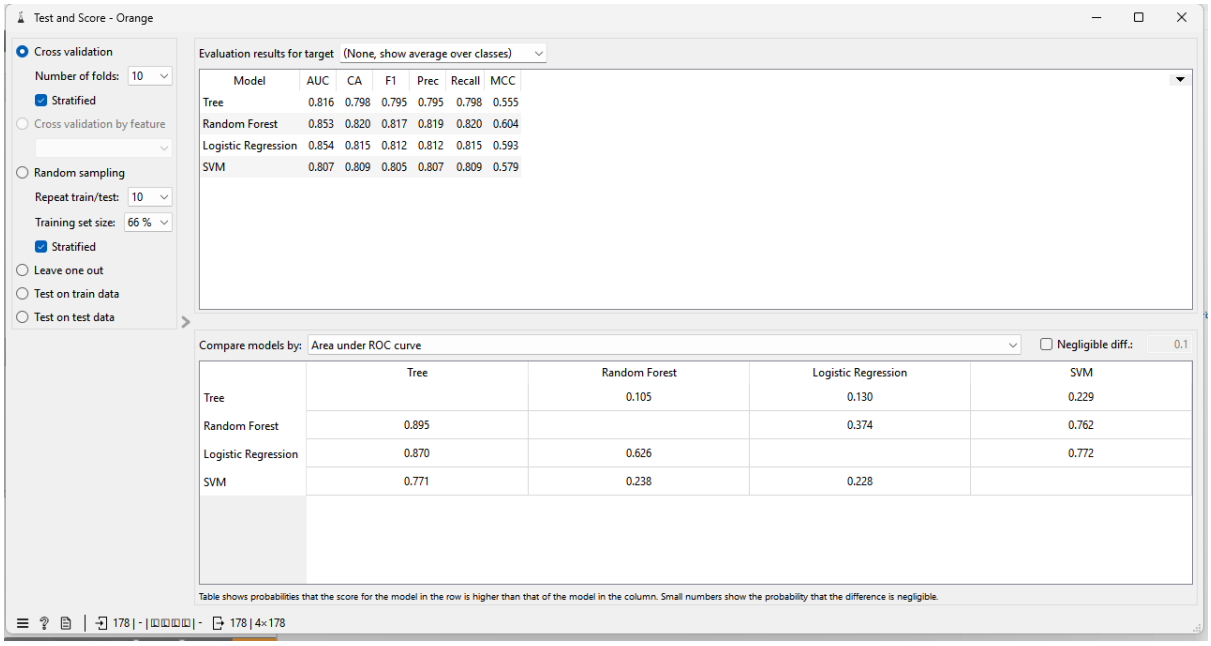

Gambar 1.2 Test And Score Titanic

Berdasarkan data tersebut, **Random Forest** dan **Logistic Regression** adalah kandidat terkuatnya.

- **CA (Classification Accuracy):** Ini adalah skor akurasi (persentase tebakan yang benar).
    - **Random Forest** paling tinggi dengan **0.820** (82% tebakannya benar).
    - **Logistic Regression** menyusul tipis di **0.815** (81,5% benar).
    - **Tree** paling rendah dengan **0.798** (sekitar 79% benar).
- **AUC (Area Under ROC):** Ini mengukur seberapa bagus model membedakan antara yang "Selamat" dan "Meninggal". Makin mendekati 1.0, makin bagus.
    - **Logistic Regression (0.854)** dan **Random Forest (0.853)** hampir kembar prestasinya di sini.

2. Apa Arti Kolom

- **F1 Score:** Keseimbangan antara akurasi dan presisi. **Random Forest** memimpin di sini (**0.817**).
- **Prec (Precision):** Seberapa akurat model saat menebak orang itu "Selamat".
- **Recall:** Seberapa banyak orang yang "Selamat" yang berhasil ditemukan oleh model.

3. Tabel Perbandingan

Tabel ini membandingkan satu model dengan model lainnya untuk melihat apakah perbedaannya signifikan atau cuma kebetulan.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

- Kalau kamu lihat baris **Random Forest** dibandingkan dengan **Tree**, angkanya menunjukkan **0.895**. Ini artinya ada kemungkinan besar Random Forest memang lebih superior dibanding Tree biasa untuk data ini.

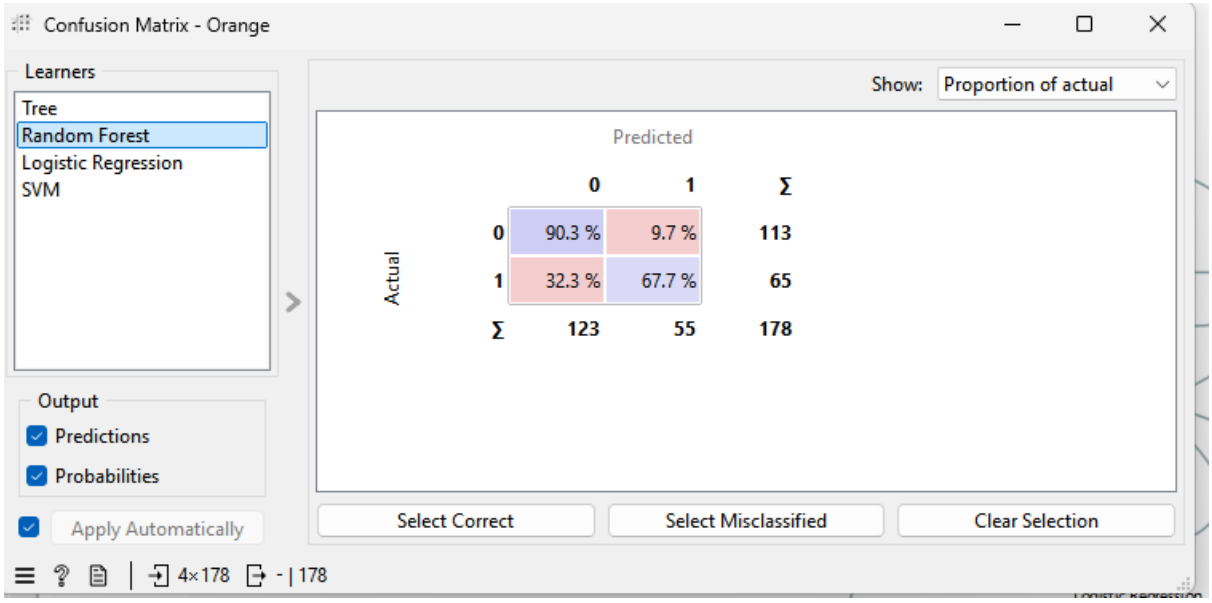

Gambar 1.3 Evaluation confusion matrix Titanic

Ini adalah **Confusion Matrix** untuk model **Random Forest** kamu. Singkatnya, ini adalah tabel "kejujuran" yang menunjukkan di mana model kamu sudah pintar dan di mana dia masih sering terkecoh.

Mari kita bedah angkanya (kita asumsikan **0 = Meninggal** dan **1 = Selamat**):

1. Tebakan yang Benar (Warna Biru)

- **90.3% (Kiri Atas):** Ini adalah orang yang aslinya **Meninggal**, dan model kamu dengan sukses menebak mereka **Meninggal**. Model kamu sangat jago mengenali penumpang yang tidak selamat.
- **67.7% (Kanan Bawah):** Ini adalah orang yang aslinya **Selamat**, dan model kamu berhasil menebak mereka **Selamat**.

2. Tebakan yang Salah (Warna Merah)

- **9.7% (Kanan Atas):** Model kamu "sok optimis". Penumpang ini aslinya **Meninggal**, tapi model malah menebak mereka **Selamat**.
- **32.3% (Kiri Bawah):** Ini kesalahan paling besar modelmu. Penumpang ini aslinya **Selamat**, tapi model kamu malah mengira mereka **Meninggal**.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

Model **Random Forest** kamu ini tipe yang **"Pesimis tapi Teliti"**.

- Dia hebat banget kalau disuruh nyari siapa yang bakal meninggal (akurasinya sampai 90% lebih).
- Tapi, dia agak kesulitan mengenali orang yang selamat. Masih ada sekitar 32% orang yang harusnya selamat, malah dianggap "lewat" sama model ini.

Data Total: Ada **178 orang** yang dites. Sebanyak **113 orang** aslinya meninggal, dan **65 orang** aslinya selamat.

[*Penjelasan Evaluation*]

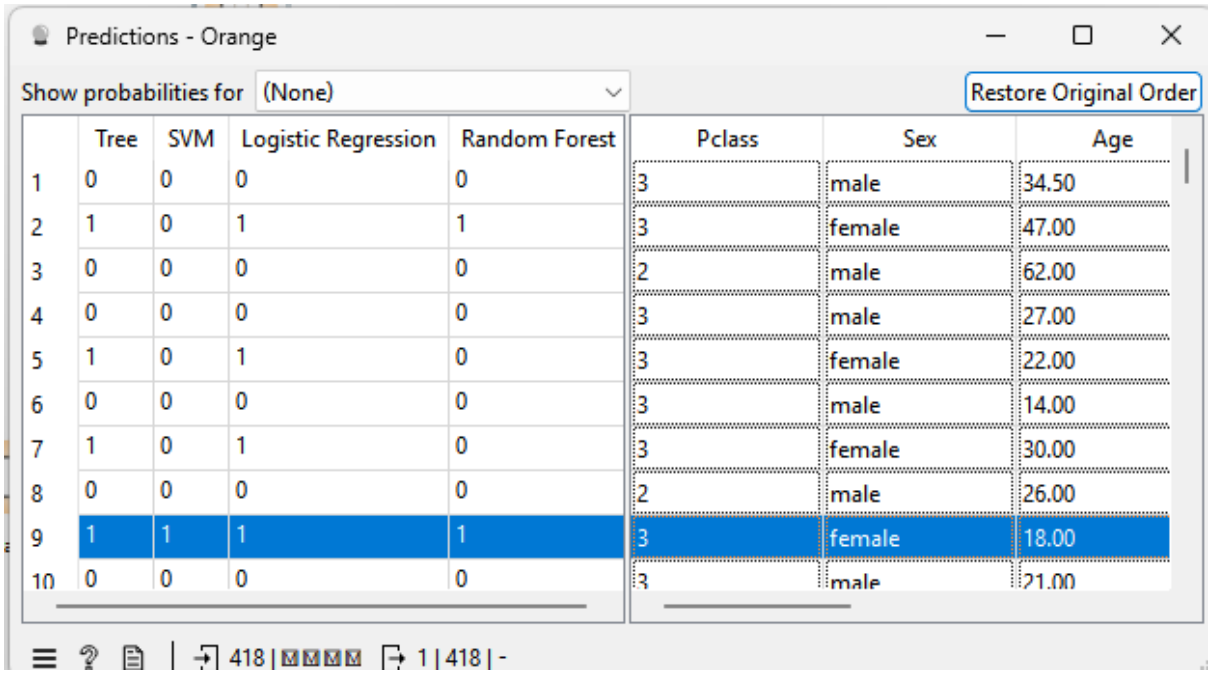

	Tree	SVM	Logistic Regression	Random Forest	Pclass	Sex	Age
1	0	0	0	0	3	male	34.50
2	1	0	1	1	3	female	47.00
3	0	0	0	0	2	male	62.00
4	0	0	0	0	3	male	27.00
5	1	0	1	0	3	female	22.00
6	0	0	0	0	3	male	14.00
7	1	0	1	0	3	female	30.00
8	0	0	0	0	2	male	26.00
9	1	1	1	1	3	female	18.00
10	0	0	0	0	3	male	21.00

Gambar 1.4 Predictions Titanic

1. Panel Model Prediksi (Sisi Kiri)

Kolom-kolom ini menunjukkan hasil prediksi dari empat algoritma yang berbeda terhadap data penumpang:

- **Tree (Decision Tree):** Model pohon keputusan.
- **SVM (Support Vector Machine):** Model klasifikasi berbasis margin.
- **Logistic Regression:** Model statistik untuk klasifikasi biner.
- **Random Forest:** Ansambel dari banyak pohon keputusan.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

Arti Angka:

- **0:** Prediksi bahwa penumpang **tidak selamat** (perished).
- **1:** Prediksi bahwa penumpang **selamat** (survived).

2. Panel Data Input/Fitur (Sisi Kanan)

Bagian ini menunjukkan karakteristik penumpang yang digunakan sebagai dasar prediksi:

- **Pclass:** Kelas tiket (1, 2, atau 3).
- **Sex:** Jenis kelamin (male/female).
- **Age:** Usia penumpang.

3. Analisis Baris yang Soroti (Baris ke-9)

Baris ke-9 sedang dipilih (berwarna biru). Mari kita bedah:

- **Data Penumpang:** Seorang **perempuan** (female), berusia **18 tahun**, di kelas **3**.
- **Konsensus Model:** Keempat model (**Tree, SVM, Logistic Regression, dan Random Forest**) kompak memberikan nilai **1**.
- **Kesimpulan:** Semua model memprediksi bahwa penumpang ini akan **selamat**.

4. Perbedaan Prediksi (Contoh Inkonsistensi)

Jika Anda melihat baris ke-5 dan ke-7:

- **Tree** dan **Logistic Regression** memprediksi penumpang tersebut **selamat (1)**.
- **SVM** dan **Random Forest** memprediksi penumpang tersebut **tidak selamat (0)**.
- Ini menunjukkan adanya perbedaan cara kerja algoritma dalam menangani data yang "ambigu" (misalnya perempuan di kelas 3 dengan usia tertentu).

Ringkasan Fitur Navigasi

- **Show probabilities for:** Saat ini disetel ke *(None)*. Jika diubah, tabel akan menampilkan persentase keyakinan model (misalnya 0.85 untuk selamat), bukan sekadar angka 0 atau 1.
- **Restore Original Order:** Tombol untuk mengembalikan urutan data ke posisi semula jika sebelumnya sempat diurutkan berdasarkan kolom tertentu.
- **Bar Status (Bawah):** Menunjukkan ada **418 data** yang sedang diproses.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

Metode:Regresi
Data: Housing

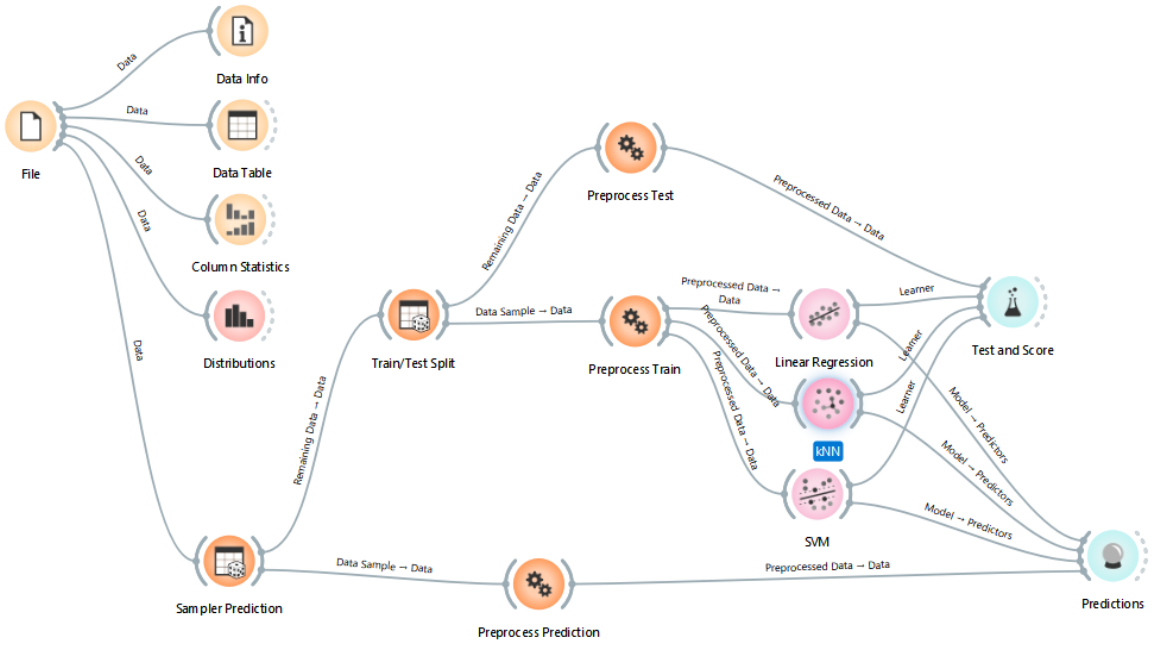

Gambar 2.2 Housing Workflow

1. Eksplorasi Data Awal (Sisi Kiri Atas)

Data dari widget **File** dihubungkan ke empat widget untuk memahami karakteristik dataset perumahan:

- **Data Info:** Melihat jumlah baris, kolom, dan tipe data.
- **Data Table:** Melihat data mentah dalam bentuk tabel.
- **Column Statistics:** Melihat statistik (rata-rata, standar deviasi, nilai min/max) dari fitur seperti jumlah kamar atau luas tanah.
- **Distributions:** Melihat persebaran nilai, misalnya distribusi harga rumah.

2. Pembagian Data (Data Splitting)

Workflow ini membagi data menjadi dua jalur besar untuk memastikan model diuji secara adil:

- **Train/Test Split:** Membagi data menjadi **Data Training** (untuk belajar) dan **Remaining Data** (untuk pengujian performa).
- **Sampler Prediction:** Mengambil sebagian kecil data terpisah yang akan digunakan untuk simulasi prediksi nyata di akhir alur.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

3. Preprocessing (Widget Roda Gigi)

Terdapat tiga widget **Preprocess** yang berfungsi untuk membersihkan data sebelum masuk ke model, seperti:

- Menangani nilai yang hilang (*missing values*).
- Normalisasi data (menyamakan skala angka) agar model seperti kNN dan SVM bekerja lebih akurat.

4. Pelatihan Model & Evaluasi (Test and Score)

Tiga algoritma regresi digunakan untuk membandingkan mana yang paling akurat dalam memprediksi harga rumah:

1. **Linear Regression:** Model garis lurus sederhana.
2. **kNN (k-Nearest Neighbors):** Memprediksi harga berdasarkan kemiripan dengan rumah lain di sekitarnya.
3. **SVM (Support Vector Machine):** Mencari fungsi regresi yang optimal di ruang dimensi tinggi.

Hasil dari ketiga model ini masuk ke widget **Test and Score**. Di sini Anda bisa melihat metrik error seperti **MSE** (*Mean Squared Error*) atau **R2 Score** untuk menentukan model mana yang terbaik.

5. Prediksi Akhir (Predictions)

Jalur paling bawah menghubungkan data baru (dari *Preprocess Prediction*) ke widget **Predictions**. Widget ini menggabungkan data tersebut dengan model yang sudah "pintar" (telah dilatih). Hasil akhirnya adalah tabel yang menunjukkan estimasi harga rumah berdasarkan prediksi masing-masing model (Linear Regression, kNN, dan SVM).

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

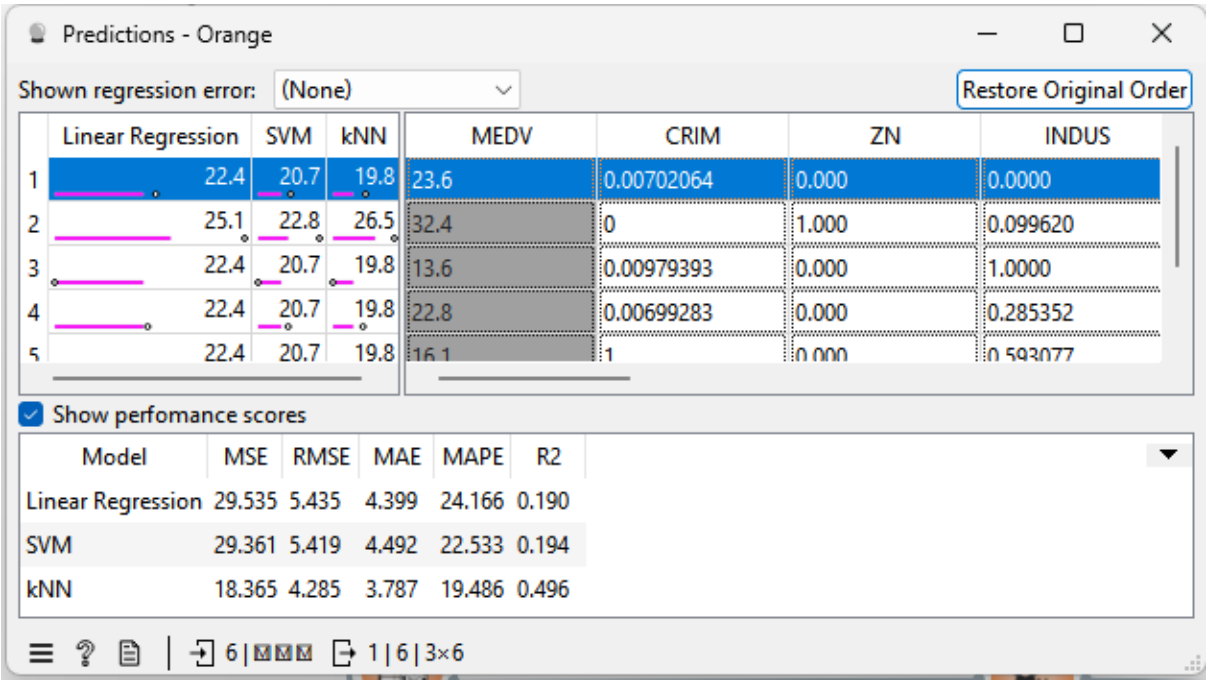

	Linear Regression	SVM	kNN	MEDV	CRIM	ZN	INDUS
1	22.4	20.7	19.8	23.6	0.00702064	0.000	0.0000
2	25.1	22.8	26.5	32.4	0	1.000	0.099620
3	22.4	20.7	19.8	13.6	0.00979393	0.000	1.0000
4	22.4	20.7	19.8	22.8	0.00699283	0.000	0.285352
5	22.4	20.7	19.8	16.1	1	0.000	0.593077

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	29.535	5.435	4.399	24.166	0.190
SVM	29.361	5.419	4.492	22.533	0.194
kNN	18.365	4.285	3.787	19.486	0.496

Gambar 2.3 Predictions Housing

1. Perbandingan Nilai Prediksi (Atas)

Tabel bagian atas membandingkan harga rumah asli dengan hasil prediksi dari tiga model:

- **MEDV:** Nilai asli rumah (dalam ribuan USD). Contoh baris 1: Harga asli adalah **23.6**.
- **Linear Regression, SVM, kNN:** Adalah hasil taksiran masing-masing model. Terlihat kNN memprediksi **19.8** untuk baris pertama.
- **Fitur (CRIM, ZN, INDUS):** Data karakteristik lingkungan (seperti tingkat kriminalitas) yang digunakan model untuk menghitung prediksi tersebut.

2. Skor Performa Model (Bawah)

Bagian ini menunjukkan seberapa akurat model-model tersebut secara keseluruhan:

- **MSE & RMSE:** Semakin **rendah** nilainya, semakin kecil kesalahan model.
- **R2 (R-Squared):** Semakin mendekati **1.0**, semakin baik model tersebut menjelaskan data.
- **Kesimpulan dari Tabel:** Dalam kasus ini, **kNN adalah model terbaik** karena memiliki nilai error terkecil (**RMSE 4.285**) dan nilai **R2 tertinggi (0.496)** dibandingkan Linear Regression dan SVM.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

3. Visualisasi Error (Garis Merah Muda)

Garis merah muda di bawah angka prediksi menunjukkan seberapa jauh penyimpangan (*error*) hasil prediksi terhadap nilai aslinya secara visual. Semakin panjang garisnya, semakin besar melesetnya prediksi tersebut.

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	27.978	5.289	3.859	21.151	0.702
kNN	33.652	5.801	4.037	20.257	0.641
SVM	59.009	7.682	5.049	24.872	0.371

Compare models by: Mean square error Negligible diff.: 0.1

	Linear Regression	kNN	SVM
Linear Regression		0.373	0.152
kNN	0.627		0.061
SVM	0.848	0.939	

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

1. Tabel Evaluasi Model (Atas)

Tabel ini merangkum tingkat akurasi dari tiga model (**Linear Regression, kNN, dan SVM**):

- **Model Terbaik:** Dalam pengujian ini, **Linear Regression** adalah pemenangnya.
- **Alasannya:** Ia memiliki nilai error terkecil (**RMSE: 5.289**) dan tingkat kecocokan data tertinggi (**R2: 0.702**).
- **Model Terburuk: SVM** memiliki performa paling rendah dengan error tertinggi (**RMSE: 7.682**) dan R^2 hanya **0.371**.

2. Perbandingan Statistik (Bawah)

Bagian **Compare models by: Mean square error** adalah tabel perbandingan berpasangan (*pairwise comparison*):

- Tabel ini menunjukkan probabilitas apakah satu model secara statistik "lebih baik" atau "lebih buruk" daripada model lainnya berdasarkan skor MSE.
- Angka-angka di dalam sel menunjukkan tingkat keyakinan perbedaan performa antar model tersebut.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

Kesimpulan

Secara keseluruhan, untuk dataset ini, **Linear Regression** jauh lebih efektif dan akurat dalam memprediksi nilai dibandingkan kNN maupun SVM.

Metode: Clustering
Data: Iris

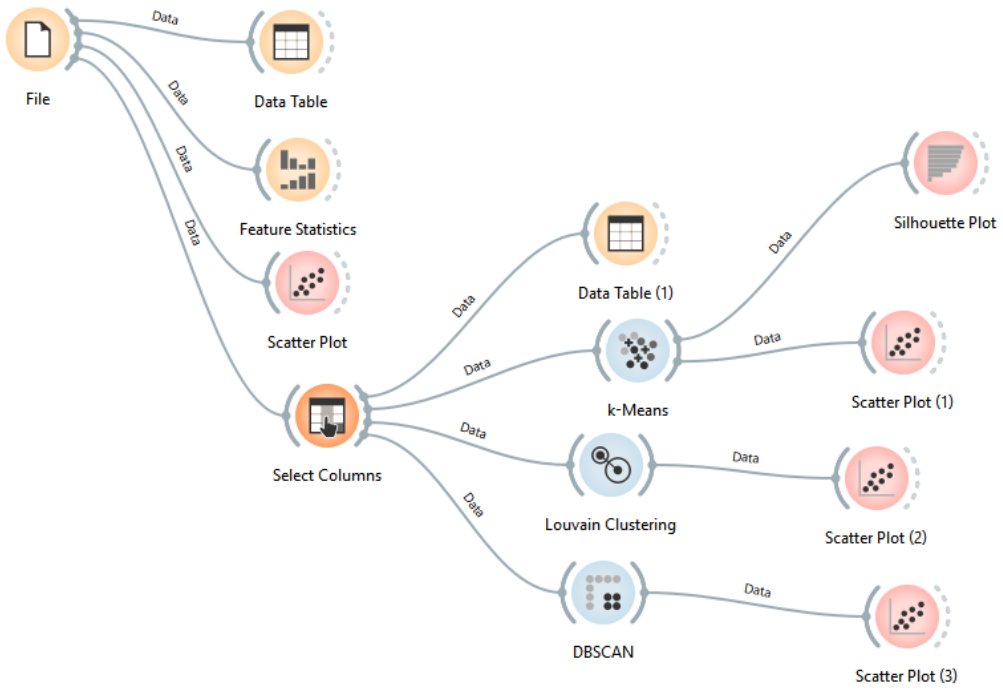

Gambar 3.1 Workflow Clustering

1. **Input & Seleksi:** Data dimuat via **File** dan fitur yang relevan dipilih melalui **Select Columns**.
2. **Proses Clustering:** Data diolah menggunakan tiga algoritma berbeda: **k-Means** (berbasis jarak), **Louvain** (berbasis struktur), dan **DBSCAN** (berbasis kepadatan).
3. **Evaluasi:** Kualitas pengelompokan diukur dengan **Silhouette Plot** (khusus k-Means).
4. **Visualisasi:** Hasil akhir dilihat melalui **Scatter Plot** untuk membandingkan bagaimana tiap algoritma membagi data ke dalam kelompok-kelompok warna.

Intinya: Mencari pola pengelompokan otomatis dan membandingkan hasil dari tiga metode berbeda.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

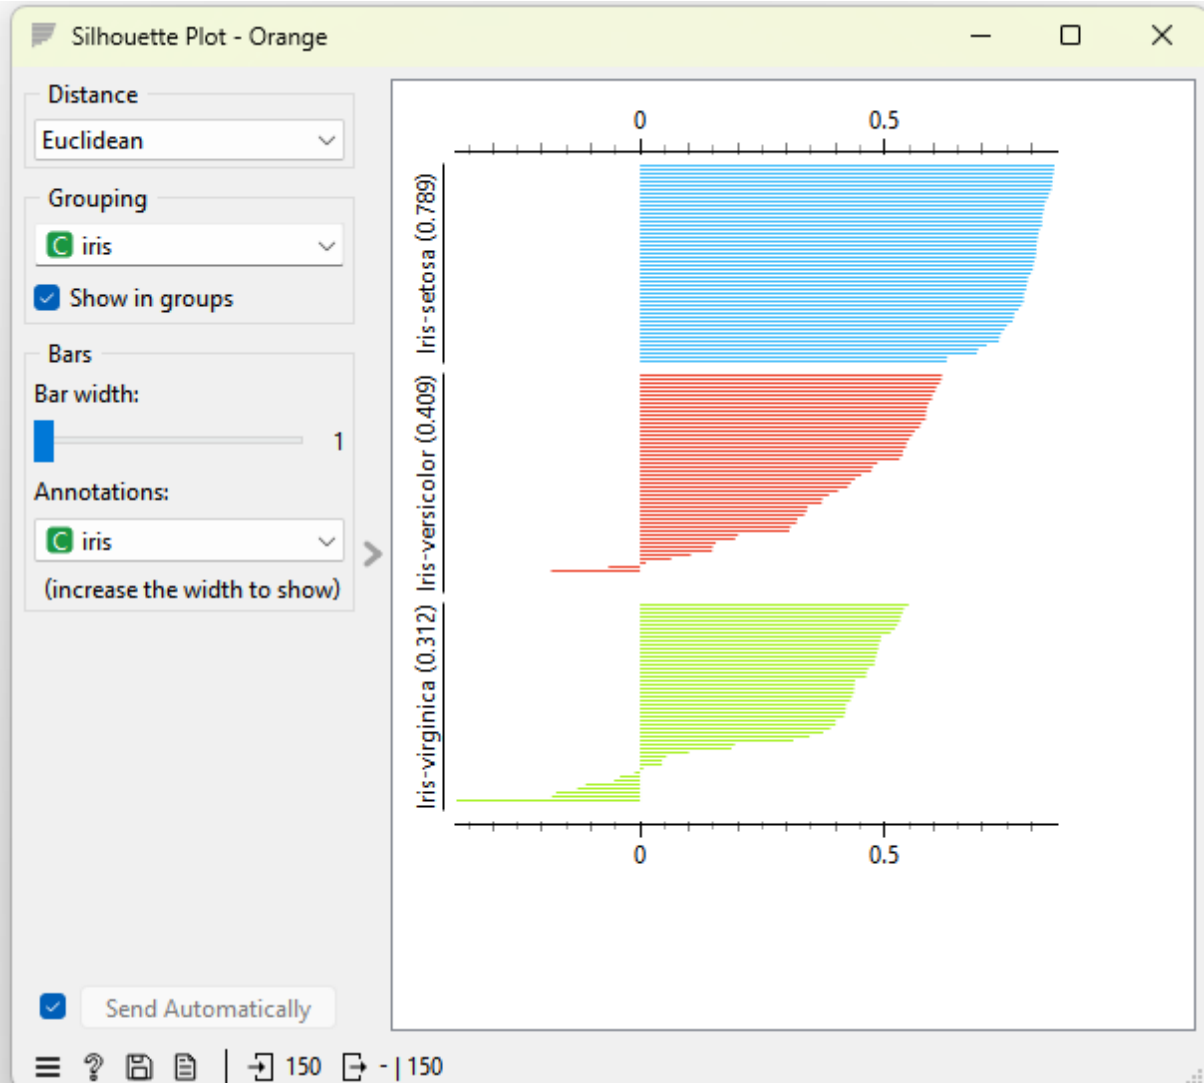

Gambar 3.2 Silhoutte Plot Clustering

Gambar ini menampilkan **Silhouette Plot** untuk dataset **Iris**, yang berfungsi mengukur seberapa baik data dikelompokkan. Berikut penjelasan ringkasnya:

---

1. Membaca Grafik

- **Panjang Bar (Koefisien Silhouette):** Semakin panjang bar ke arah kanan (mendekati **1.0**), semakin baik data tersebut masuk ke kelompoknya dan jauh dari kelompok lain.
- **Nilai Negatif (Bar ke kiri angka 0):** Menunjukkan data tersebut kemungkinan salah masuk kelompok (*misplaced*).

2. Analisis Kelompok

- **Iris-setosa (Biru):** Memiliki skor tertinggi (**0.789**). Artinya, kelompok ini sangat solid, terpisah jelas, dan hampir tidak ada kesalahan pengelompokan.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

- **Iris-versicolor (Merah):** Skor menengah (**0.409**). Terlihat beberapa bar sangat pendek, menandakan adanya tumpang tindih dengan kelompok lain.
- **Iris-virginica (Hijau):** Skor terendah (**0.312**). Ada beberapa bar yang menyeberang ke arah negatif, artinya beberapa sampel lebih mirip dengan kelompok tetangga daripada kelompoknya sendiri.

Kesimpulan

Secara keseluruhan, algoritma clustering berhasil memisahkan **Setosa** dengan sempurna, namun masih kesulitan memisahkan **Versicolor** dan **Virginica** secara tegas karena karakteristik keduanya yang mirip.

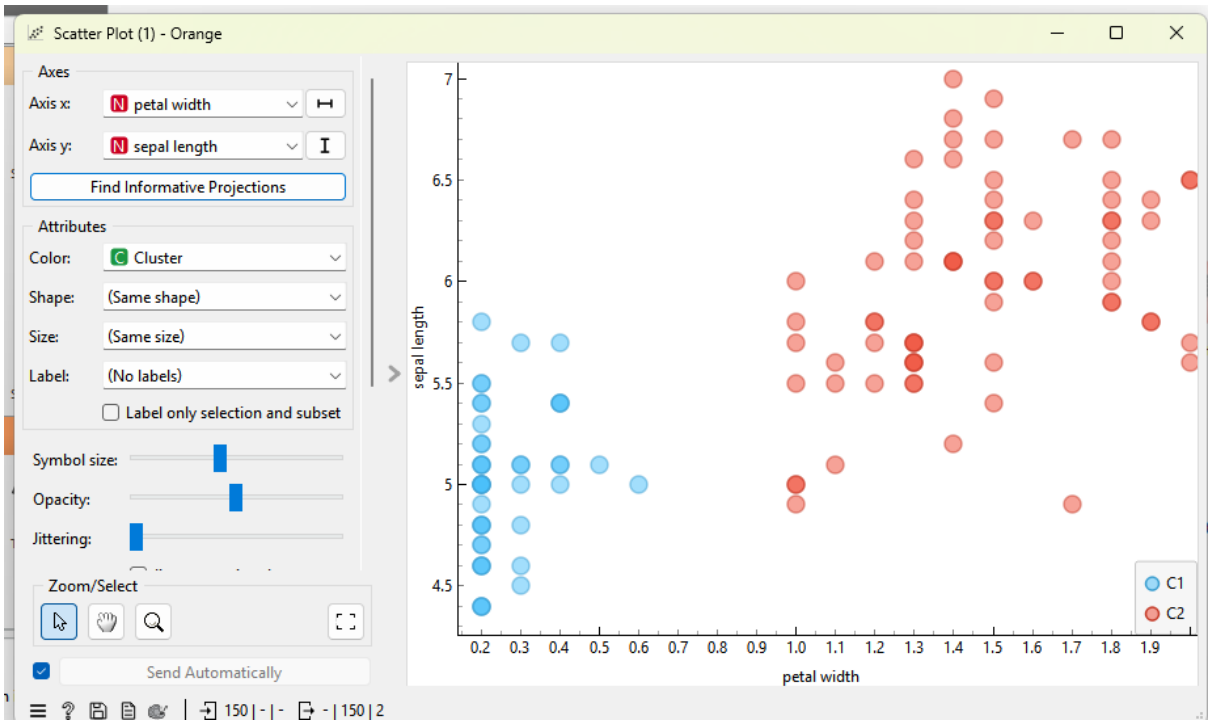

Gambar : 3.3 Scatter Plot Clustering

Gambar ini menampilkan **Scatter Plot** yang memvisualisasikan hasil clustering pada dataset Iris. Berikut penjelasan ringkasnya:

1. Sumbu Grafis

- **Sumbu X (petal width):** Lebar kelopak bunga.
- **Sumbu Y (sepal length):** Panjang kelopak bunga.

2. Hasil Clustering

Algoritma membagi data menjadi dua kelompok utama (**C1** dan **C2**):

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

- **Cluster 1 (Biru - C1):** Terletak di sisi kiri bawah (lebar kelopak kecil, panjang kelopak pendek). Ini menunjukkan kelompok bunga yang sangat seragam dan terpisah jelas.
- **Cluster 2 (Merah - C2):** Terletak di sisi kanan (lebar kelopak lebih besar). Kelompok ini lebih menyebar, yang mencerminkan variasi data yang lebih tinggi pada spesies tersebut.

3. Kesimpulan Visual

Visualisasi ini menunjukkan bahwa **petal width** (lebar kelopak) adalah fitur yang sangat kuat untuk membedakan kelompok **C1** dari kelompok lainnya, karena terdapat celah kosong (jarak pemisah) yang lebar di antara kedua kelompok tersebut pada nilai 0.6 hingga 1.0.

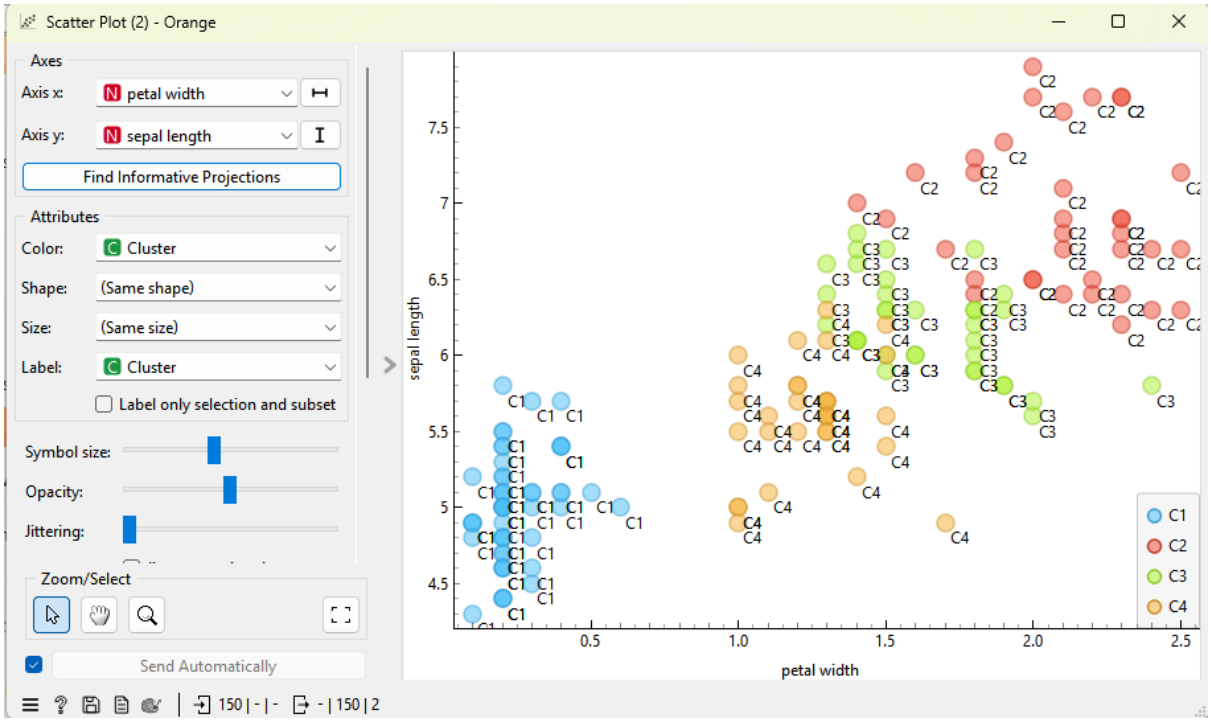

Gambar 3.4 scatter plot 2 clustering

Berikut adalah penjelasan ringkasnya:

- **Tujuan:** Visualisasi pengelompokan data Iris ke dalam **4 Cluster** (C1, C2, C3, C4).
- **Variabel:** Menggunakan **petal width** (sumbu X) dan **sepal length** (sumbu Y) sebagai penentu posisi.
- **Hasil:**
  - **C1 (Biru):** Terpisah sempurna di kiri (kelopak paling kecil).
  - **C2, C3, C4:** Saling berdekatan dan sedikit umpeng tindih di kanan, menunjukkan kemiripan ciri fisik pada kelompok-kelompok tersebut.

Nama: Rahma Aulia Dini
NIM: 20124033
Kelas:C1.24

- **Kesimpulan:** Semakin banyak cluster yang dibuat, pembagian kelompok pada area kanan menjadi lebih detail namun batas antarkelompoknya menjadi lebih tipis.

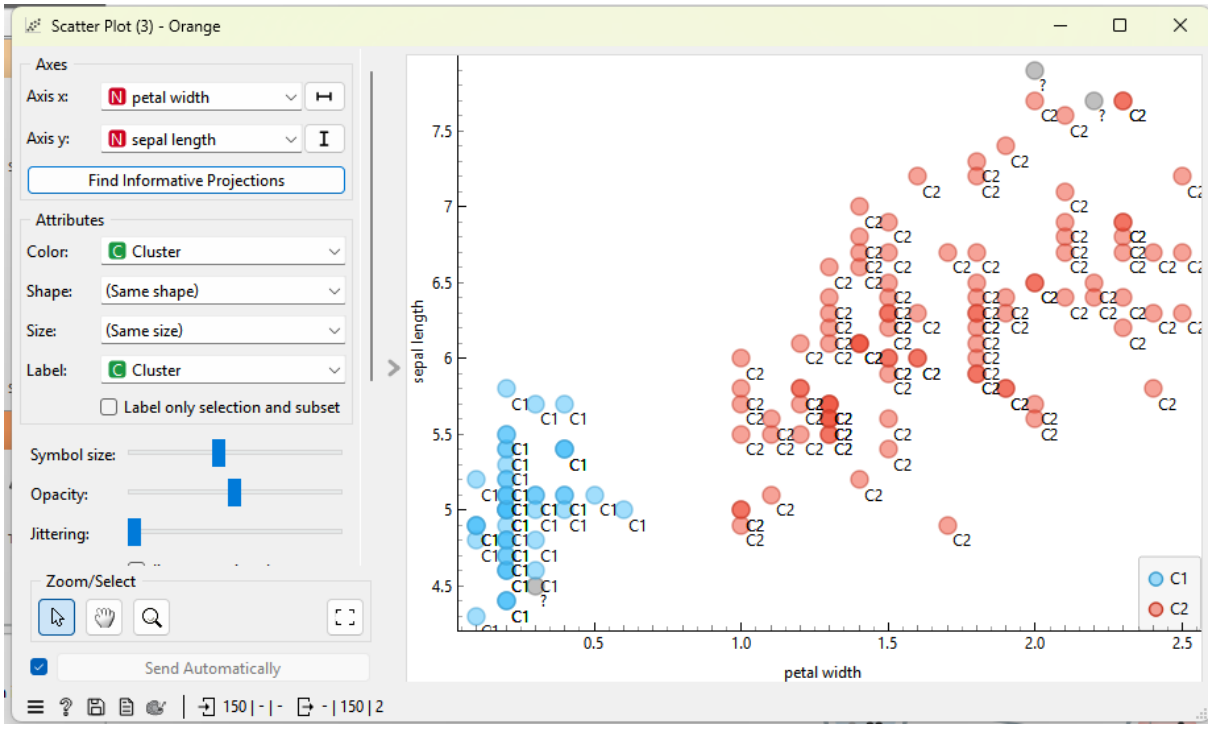

Gambar 3.5 Scatter Plot 3 Clustering

Gambar ini menampilkan **Scatter Plot** hasil clustering menggunakan algoritma **DBSCAN**. Berikut ringkasannya:

- **Dua Cluster Utama:** Data dikelompokkan menjadi **C1 (Biru)** dan **C2 (Merah)** berdasarkan kepadatan titik.
- **Identifikasi Outlier (Titik Abu-abu/?):** Berbeda dengan k-Means, DBSCAN berhasil mendeteksi titik-titik yang dianggap sebagai **noise atau outlier** (simbol tanda tanya berwarna abu-abu). Titik ini dianggap tidak masuk ke kelompok mana pun karena posisinya terlalu terisolasi.
- **Karakteristik:**
    - **C1:** Sangat padat dan terpusat di area lebar kelopak (*petal width*) kecil.
    - **C2:** Lebih menyebar di area lebar kelopak yang lebih besar.
- **Kesimpulan:** DBSCAN efektif untuk memisahkan kelompok sekaligus menyaring data yang "tidak lazim" dalam dataset ini.