Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

1. Metode: Klasifikasi
Data: Titanic Dataset

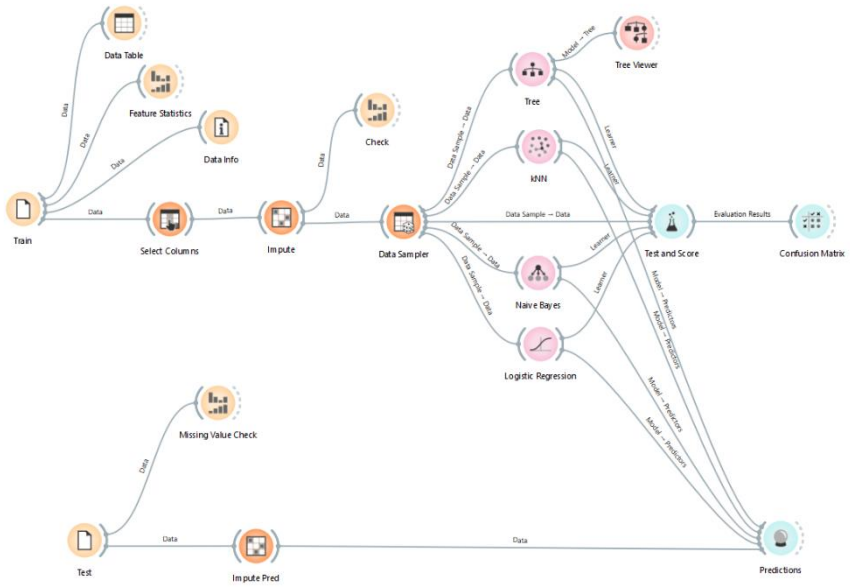

Gambar 1. Titanic Workflow

1. Tahap Pelatihan (Bagian Atas)

- **Train**: Merepresentasikan dataset awal yang berisi data riwayat penumpang (misalnya dataset Titanic). Data ini memuat berbagai variabel (fitur) dan sudah memiliki label target (misalnya status keselamatan penumpang).
- **Select Columns & Impute**: Ini adalah tahap Pra-pemrosesan Data (*Data Preprocessing*). *Select Columns* digunakan untuk memilih variabel yang relevan dan membuang yang tidak diperlukan. *Impute* berfungsi untuk menangani *Missing Values* (data kosong) dengan cara mengisinya menggunakan metode statistik tertentu (seperti nilai rata-rata atau modus).
- **Data Sampler**: Membagi atau mengirimkan data yang sudah diproses ke berbagai algoritma pembelajaran.
- **Model Pembelajaran (Tree, kNN, Naive Bayes, Logistic Regression)**: Ini adalah empat algoritma klasifikasi (*Classification Algorithms*) yang berbeda. Keempatnya menerima data pelatihan untuk membangun sebuah model prediktif.
- **Test and Score**: Ini adalah widget untuk Evaluasi Model. Widget ini menggunakan metode tertentu (biasanya *Cross-Validation*) untuk mengukur seberapa baik kinerja keempat model klasifikasi tersebut berdasarkan data pelatihan.
- **Confusion Matrix**: Matriks kebingungan ini menjabarkan secara rinci perbandingan antara prediksi yang dibuat oleh model dengan nilai sebenarnya. Ini membantu kita melihat jenis kesalahan prediksi yang dilakukan model.

Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

2. Tahap Pengujian/Prediksi (Bagian Bawah)

- **Test**: Merepresentasikan dataset baru yang tidak memiliki label target (misalnya daftar penumpang baru yang belum diketahui status keselamatannya).
- **Impute Pred**: Melakukan pra-pemrosesan pada data uji untuk menangani nilai yang kosong, sama seperti pada tahap pelatihan.
- **Predictions**: Menggunakan model klasifikasi yang telah dilatih (dari bagian atas) untuk memprediksi label atau target dari data uji (Test).

4. Jawaban

a. **Logistic Regression : 0.843**
b. **Logistic Regression : 0.796**
c. Iya keduanya menggunakan model **Logistic Regression,** karna keduanya sama saya akan menggunakan **Logistic Regression** saja.
d. 61

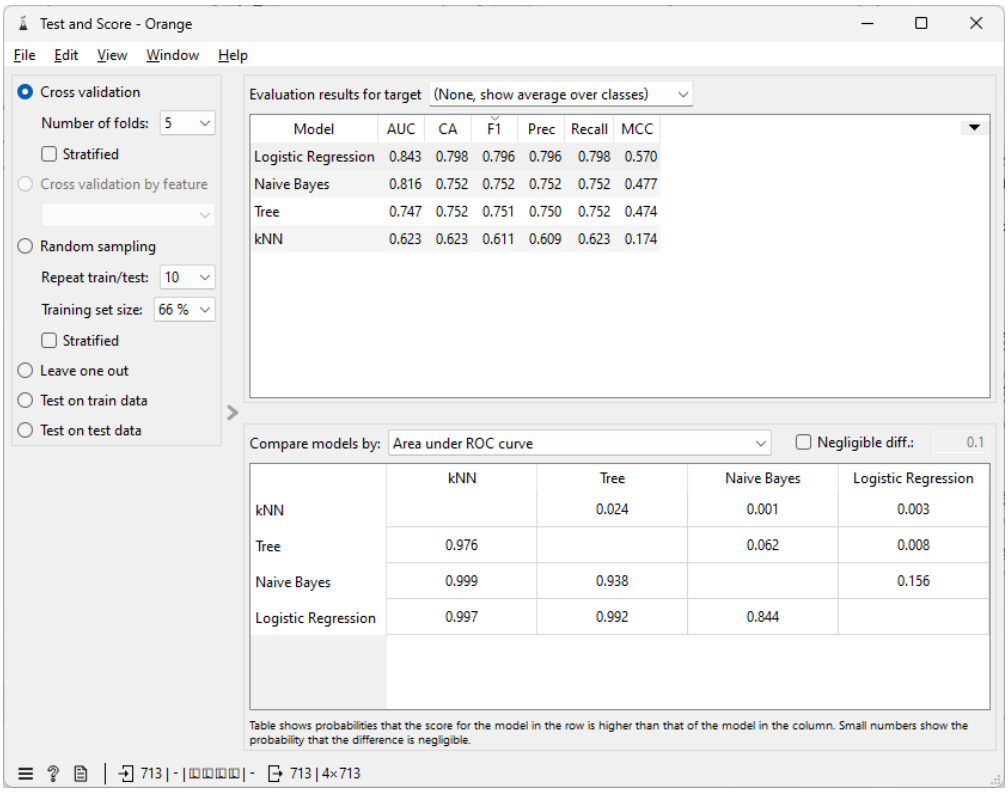

Model	AUC	CA	F1	Prec	Recall	MCC
Logistic Regression	0.843	0.798	0.796	0.796	0.798	0.570
Naive Bayes	0.816	0.752	0.752	0.752	0.752	0.477
Tree	0.747	0.752	0.751	0.750	0.752	0.474
kNN	0.623	0.623	0.611	0.609	0.623	0.174

	kNN	Tree	Naive Bayes	Logistic Regression
kNN		0.024	0.001	0.003
Tree	0.976		0.062	0.008
Naive Bayes	0.999	0.938		0.156
Logistic Regression	0.997	0.992	0.844	

Gambar 2. Titanic Test and Score

Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

2. Metode: Regresi
Data: Housing Dataset

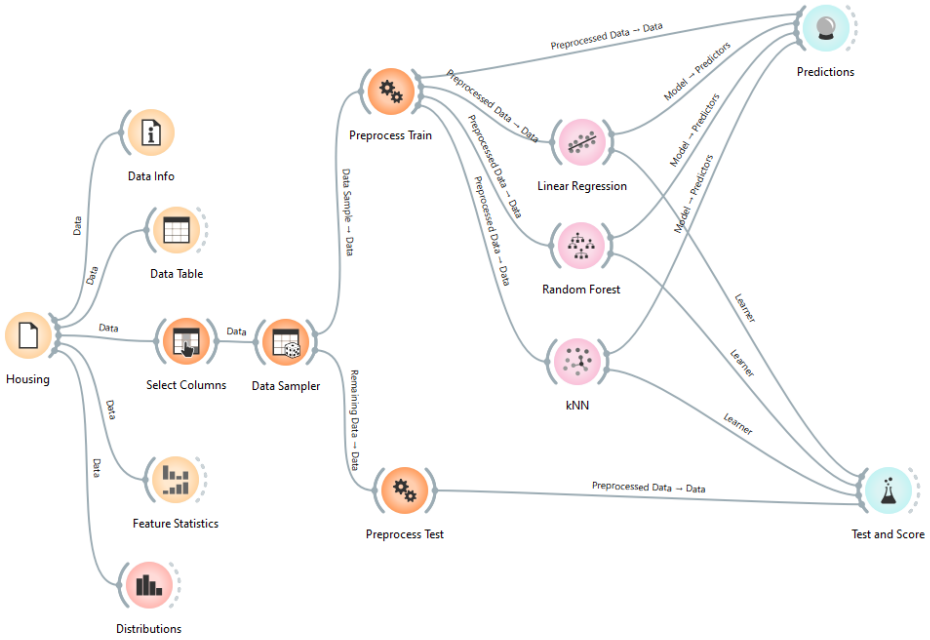

Gambar 3. Housing Workflow

1. Eksplorasi Data (Sisi Kiri)

- **Housing:** Merepresentasikan dataset mentah awal yang memuat data terkait perumahan untuk dianalisis.
- **Data Info, Data Table, Feature Statistics, Distributions:** Rangkaian widget ini digunakan untuk tahap analisis deskriptif. Fungsinya untuk memeriksa informasi umum dataset, melihat tabel data, mengecek statistik dasar setiap variabel, dan mengamati distribusi sebaran datanya.

2. Pembagian Data (Tengah - Kiri)

- **Select Columns:** Digunakan untuk memisahkan variabel. Anda memilih variabel mana yang akan menjadi *Features* (faktor penentu) dan variabel mana yang menjadi *Target* (nilai angka yang ingin diprediksi, misalnya harga rumah).
- **Data Sampler:** Membagi dataset secara acak menjadi dua bagian, yaitu Data Latih (*Data Sample*) yang akan dikirim ke model untuk belajar, dan Data Uji (*Remaining Data*) yang akan disimpan untuk menguji model nantinya.

Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

3. Pra-pemrosesan & Pemodelan (Tengah - Kanan)

- **Preprocess Train & Preprocess Test:** Ini adalah tahap Pra-pemrosesan Data (*Data Preprocessing*). Data Latih dan Data Uji diproses secara terpisah untuk menangani nilai kosong, normalisasi skala angka, atau penyesuaian tipe data sebelum masuk ke tahap pemodelan.
- **Model Pembelajaran (Linear Regression, Random Forest, kNN):** Ini adalah tiga algoritma regresi yang berbeda. Ketiganya menerima data latih (dari *Preprocess Train*) untuk "belajar" mengenali pola harga rumah dan membangun model prediktif.

4. Evaluasi & Prediksi (Sisi Kanan)

- **Test and Score:** Ini adalah widget untuk Evaluasi Model. Widget ini menerima algoritma dari ketiga model dan mengujinya menggunakan Data Uji (dari *Preprocess Test*). Tujuannya untuk mengukur seberapa akurat model memprediksi harga dengan melihat metrik kesalahan (seperti RMSE atau MAE).
- **Predictions:** Menampilkan perbandingan langsung antara hasil tebakan angka dari model dengan data aktual dalam bentuk tabel data.

4. Jawaban

a.

- **Model dengan MAE terendah: kNN** dengan nilai **45442.268**.
- **Seberapa besar selisihnya (*By how much*):** Jika dibandingkan dengan model terbaik kedua (Random Forest dengan MAE 47916.399), kNN lebih rendah (lebih baik) sebesar **2474.131**. Jika dibandingkan dengan model terburuk (Linear Regression dengan MAE57928.775), selisihnya adalah **12486.507**.

b. **kNN :** 0.836

c.

- **Predicted (Prediksi kNN): 682500.0**
- **Actual (Nilai Asli / kolom MEDV): 520800.0**
- **Error atau selisihnya adalah 161700.0**

d.

- **Analisis:** Pada kasus di baris pertama ini, model menebak harga (682.500) yang jauh lebih mahal daripada harga aslinya (520.800). Ini disebut **Overestimasi (*Overprediction*)**.
- **Kesimpulan:** Hal ini menunjukkan bahwa model kesulitan dan "terkecoh" oleh kombinasi fitur tertentu. Rumah tersebut kemungkinan memiliki variabel (seperti jumlah kamar, rasio pajak, dll.) yang secara statistik mirip dengan rumah-rumah mahal, sehingga model memprediksi harganya tinggi. Namun, model gagal menangkap faktor-faktor lain (atau anomali) yang pada kenyataannya membuat harga asli rumah tersebut jauh lebih murah.

Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

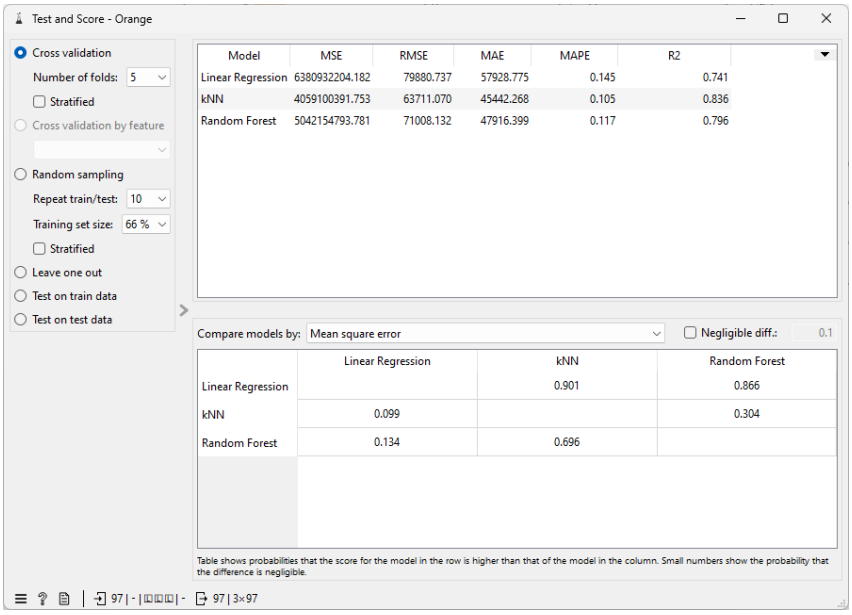

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	6380932204.182	79880.737	57928.775	0.145	0.741
kNN	4059100391.753	63711.070	45442.268	0.105	0.836
Random Forest	5042154793.781	71008.132	47916.399	0.117	0.796

	Linear Regression	kNN	Random Forest
Linear Regression		0.901	0.866
kNN	0.099		0.304
Random Forest	0.134	0.696	

Gambar 4. Housing Test and Score

Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

3. Metode: Clustering
Data: Zoo Dataset

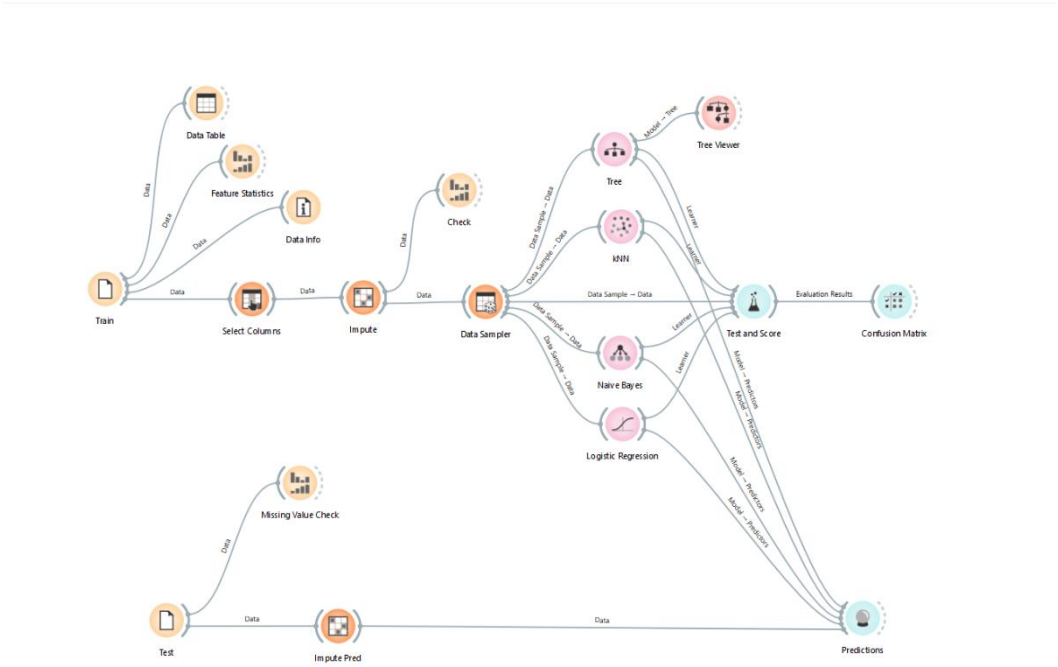

Gambar 5. Zoo Workflow

1. Tahap Eksplorasi Data (Sisi Kiri)

- **zoo:** Merepresentasikan dataset mentah awal yang memuat data terkait ciri-ciri biologis berbagai hewan.
- **Data Info, Data Table, Feature Statistics, Scatter Plot:** Rangkaian widget ini digunakan untuk tahap analisis deskriptif awal. Fungsinya untuk memeriksa informasi umum dataset, melihat keseluruhan isi data dalam bentuk tabel, mengecek statistik dasar setiap variabel, serta melihat visualisasi persebaran data mentah sebelum diproses.

2. Tahap Pra-pemrosesan (Tengah)

- **Select Columns:** Digunakan untuk memanipulasi variabel yang akan digunakan. Dalam konteks *clustering* (pembelajaran tanpa pengawasan), widget ini berfungsi untuk membuang atau mengabaikan (*ignore*) kolom seperti 'nama' dan 'tipe' asli hewan, sehingga algoritma murni mengelompokkan hewan berdasarkan ciri-ciri fisiknya saja tanpa mengetahui label aslinya.

3. Tahap Pemodelan / Clustering (Tengah - Kanan)

- **k-Means:** Ini adalah algoritma *Unsupervised Learning* (pembelajaran tanpa pengawasan). Algoritma ini menerima data dari *Select Columns* untuk mencari pola

kemiripan antar hewan, lalu mengelompokkan mereka ke dalam sejumlah klaster (*clusters*) tertentu berdasarkan jarak kedekatan ciri fisiknya.

4. Tahap Evaluasi & Visualisasi (Sisi Kanan)

- **Cluster Data Table:** Menampilkan hasil akhir pengelompokan dalam bentuk tabel data. Pada tahap ini, setiap baris data hewan telah mendapatkan label klaster barunya (misalnya: C1, C2, C3).
- **Silhouette Plot:** Ini adalah widget untuk Evaluasi Model *Clustering*. Widget ini berfungsi untuk mengukur dan memvisualisasikan seberapa rapi dan tepat pengelompokan yang telah dilakukan oleh algoritma k-Means.
- **Cluster Scatter Plot:** Menampilkan visualisasi hasil prediksi. Widget ini memproyeksikan titik-titik data hewan ke dalam grafik dua dimensi, di mana setiap titik kini diberi warna yang berbeda-beda sesuai dengan klasternya masing-masing untuk memudahkan analisis visual.

5. Jawaban

a. **K-5: 0.399**
b. Berdasarkan nilai biner (1 = ya, 0 = tidak) dan angka pada fitur atribut biologisnya, berikut adalah kesamaan yang ditemukan pada masing-masing klaster:
   - **Cluster 1 (C1):** Seluruhnya bertelur (eggs = 1), bersifat predator (predator = 1), tidak memiliki rambut (hair = 0), tidak berbulu burung (feathers = 0), dan tidak menyusui (milk = 0). Jumlah kaki bervariasi (4, 6, 8, atau 0).
   - **Cluster 2 (C2):** Mayoritas memiliki bulu burung (feathers = 1), bertelur (eggs = 1), bertulang belakang (backbone = 1), bernapas dengan udara (breathes = 1), tidak memiliki gigi (toothed = 0), dan memiliki 2 kaki (legs = 2).
   - **Cluster 3 (C3):** Seluruhnya memiliki rambut (hair = 1), menyusui/memproduksi susu (milk = 1), memiliki gigi (toothed = 1), bertulang belakang (backbone = 1), dan bernapas dengan udara (breathes = 1).
   - **Cluster 4 (C4):** Seluruhnya hidup di air (aquatic = 1), memiliki sirip (fins = 1), berekor (tail = 1), bertulang belakang (backbone = 1), bergigi (toothed = 1), tidak bernapas dengan udara/paru-paru (breathes = 0), dan tidak memiliki kaki (legs = 0).
   - **Cluster 5 (C5):** Seluruhnya bertelur (eggs = 1), tidak bertulang belakang (backbone = 0), tidak memiliki gigi (toothed = 0), tidak berekor (tail = 0), bernapas dengan udara (breathes = 1), dan mayoritas memiliki 6 kaki (legs = 6) atau tidak berkaki (0).
c. Berdasarkan kesamaan ciri biologis di atas, nama yang paling merepresentasikan masing-masing kelompok adalah:

   - **Cluster C1:** Kelompok Reptil, Amfibi & Arthropoda (Hewan Darat/Air Non-Mamalia Predator)
   - **Cluster C2:** Kelompok Burung
   - **Cluster C3:** Kelompok Mamalia
   - **Cluster C4:** Kelompok Ikan

Nama: Andhika Bayu
NIM: 20124026
Kelas: C1.24 S1 Informatika

- **Cluster C5:** Kelompok Serangga & Invertebrata

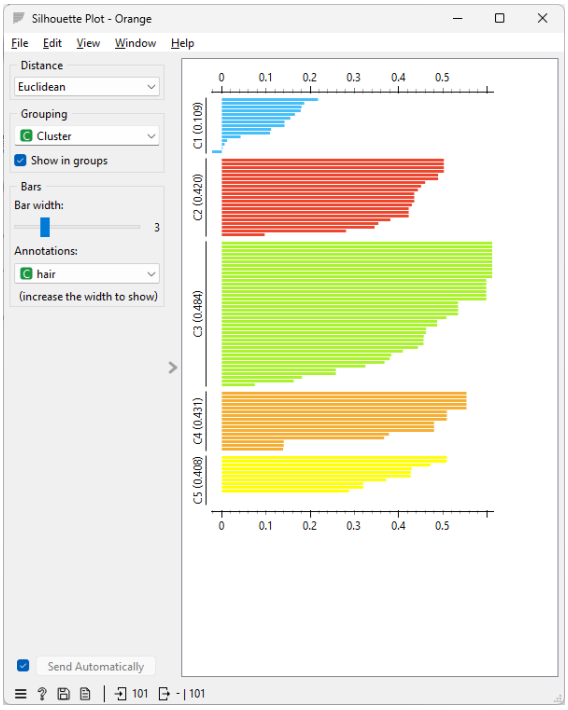

Gambar 6. Silhoutte Plot

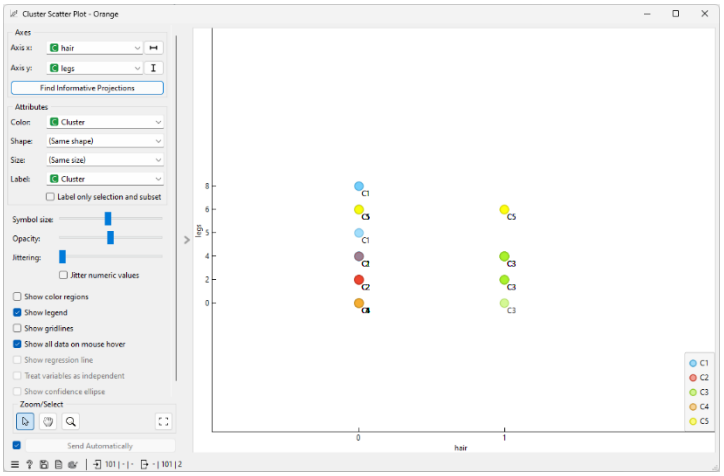

Gambar 7. Silhoutte Plot