Nama : Akmal Zaki Alfadly
NPM : 20124078
Kelas : C3.24 Informatika

Metode : Klasifikasi
Data : Titanic Dataset

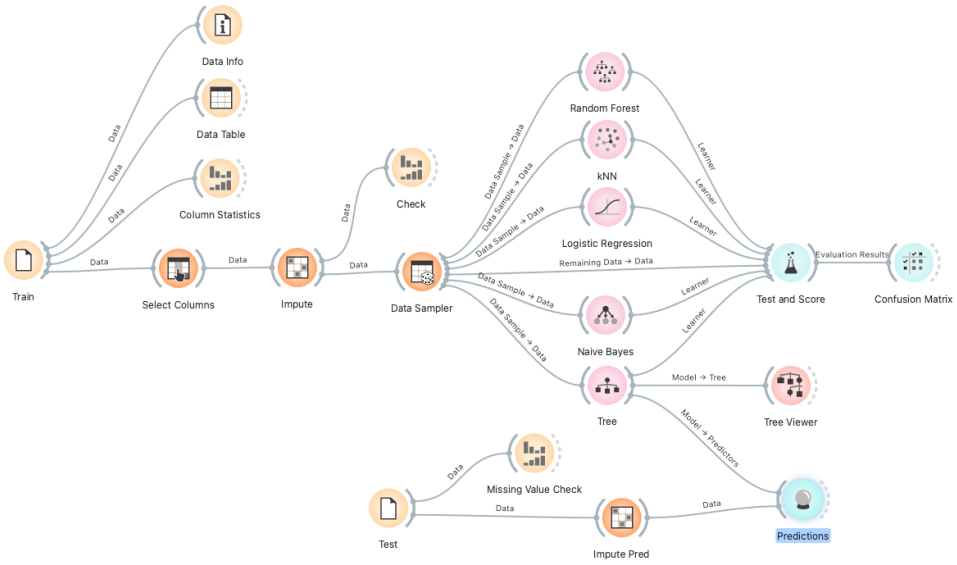

Gambar 1. Titanic workflow

Penjelasan Workflow Klasifikasi

Workflow ini digunakan untuk melakukan proses klasifikasi data menggunakan beberapa tahapan utama.

Pertama, data dipilih dan disesuaikan menggunakan Select Columns untuk menentukan fitur dan target yang akan digunakan. Selanjutnya, dilakukan penanganan data yang hilang melalui Impute agar dataset menjadi lengkap dan siap diproses.

Setelah itu, data dibagi menjadi data latih dan data uji menggunakan Data Sampler dengan perbandingan tertentu (misalnya 80% data latih dan 20% data uji). Data latih digunakan untuk membangun model klasifikasi menggunakan algoritma Naive Bayes, sedangkan data uji digunakan untuk mengukur performa model.

Evaluasi dilakukan melalui Test & Score untuk mendapatkan metrik seperti akurasi, dan hasilnya divisualisasikan menggunakan Confusion Matrix untuk melihat perbandingan antara prediksi dan data aktual.

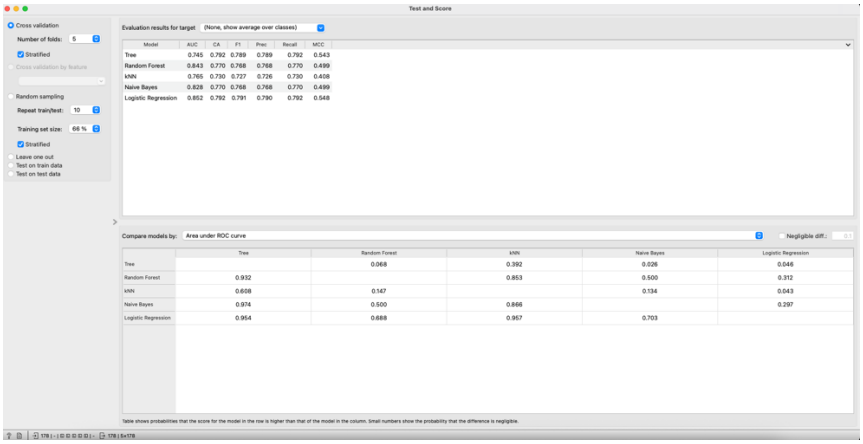

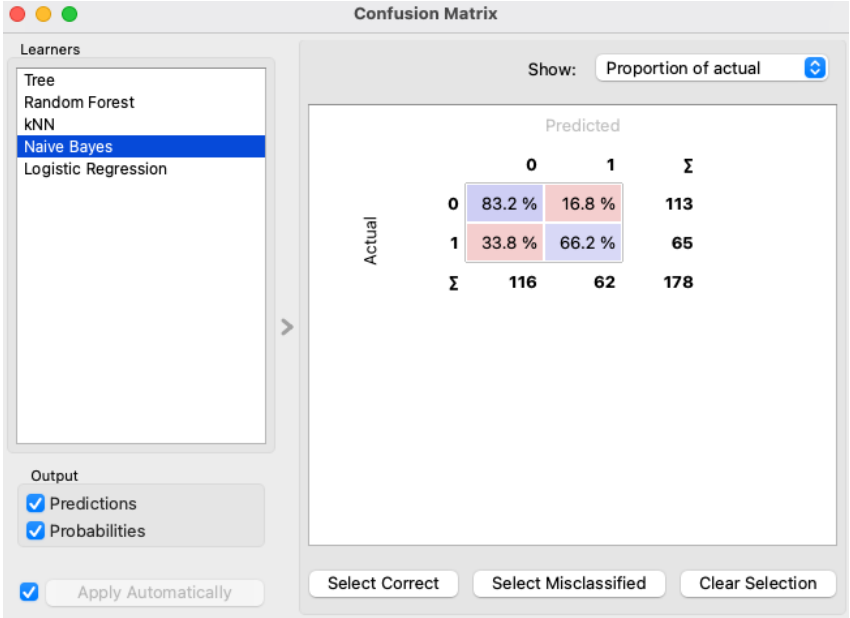

Gambar 2. Model evaluation (Naïve Bayes)

Berdasarkan hasil pengujian pada widget Confusion Matrix, model Naive Bayes menunjukkan performa yang lebih stabil dalam mengidentifikasi Kelas 0 dengan tingkat keberhasilan sebesar 83,2%, namun mengalami kesulitan pada Kelas 1 karena hanya mampu memprediksi 66,2% data dengan benar. Tingginya tingkat kesalahan pada Kelas 1, di mana 33,8% data aktual salah terklasifikasi sebagai Kelas 0, mengindikasikan adanya potensi False Negative yang signifikan. Oleh karena itu, evaluasi model tidak boleh hanya bersandar pada nilai Accuracy semata, melainkan harus diinspeksi bersama dengan Confusion Matrix untuk memahami secara detail di mana model mengalami kegagalan prediksi.

Metode: Regression
Data: Boston Housing Dataset

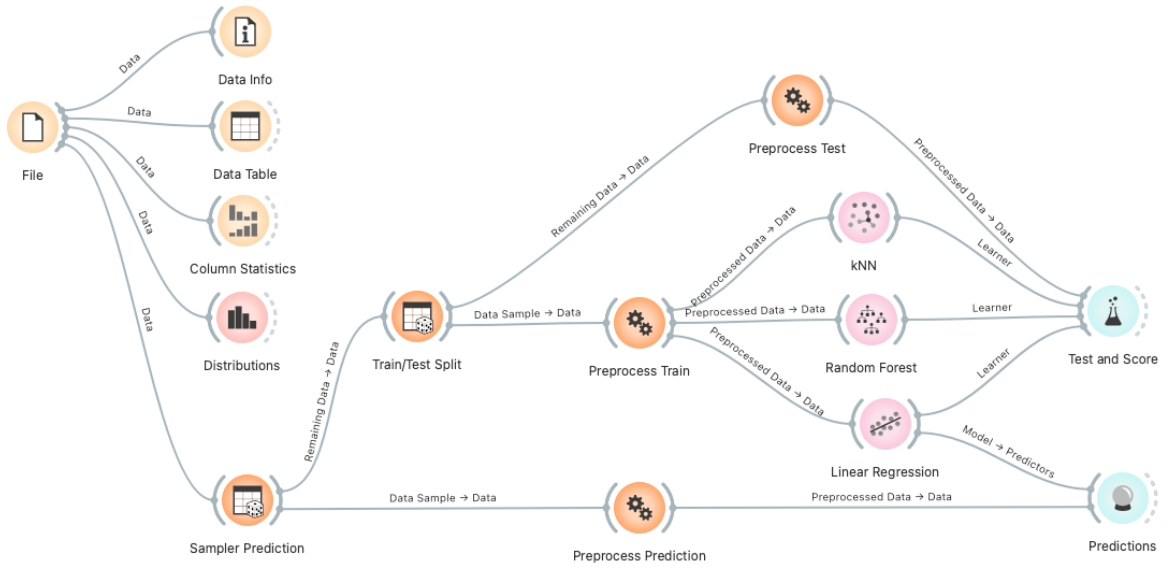

Gambar 3. Regression Workflow

Penjelasan workflow

- Pemuatan dan Eksplorasi Data: Data dimuat melalui widget File, kemudian diperiksa karakteristiknya menggunakan Data Info, Data Table, dan Column Statistics, serta dilihat sebaran nilainya melalui widget Distributions.

- Pembagian Data (*Split*): Data dibagi menjadi dua bagian utama menggunakan widget Data Sampler (dalam gambar dinamai *Train/Test Split*), yaitu set pelatihan untuk membangun model dan set pengujian untuk mengevaluasi performa.

- Pra-pemrosesan (*Preprocessing*): Terdapat proses pembersihan atau transformasi data pada widget Preprocess (Train, Test, dan Prediction) untuk memastikan data siap digunakan oleh algoritma regresi.

- Pelatihan Model: Tiga algoritma digunakan secara bersamaan untuk mempelajari pola data, yaitu kNN, Random Forest, dan Linear Regression, di mana ketiganya mencoba memprediksi nilai kontinu (angka) seperti harga rumah.

 Evaluasi dan Prediksi: Performa ketiga model dibandingkan pada widget Test and Score menggunakan metrik regresi (seperti MAE atau R2), sementara widget Predictions digunakan untuk melihat perbandingan langsung antara nilai aktual dan hasil prediksi pada data baru.

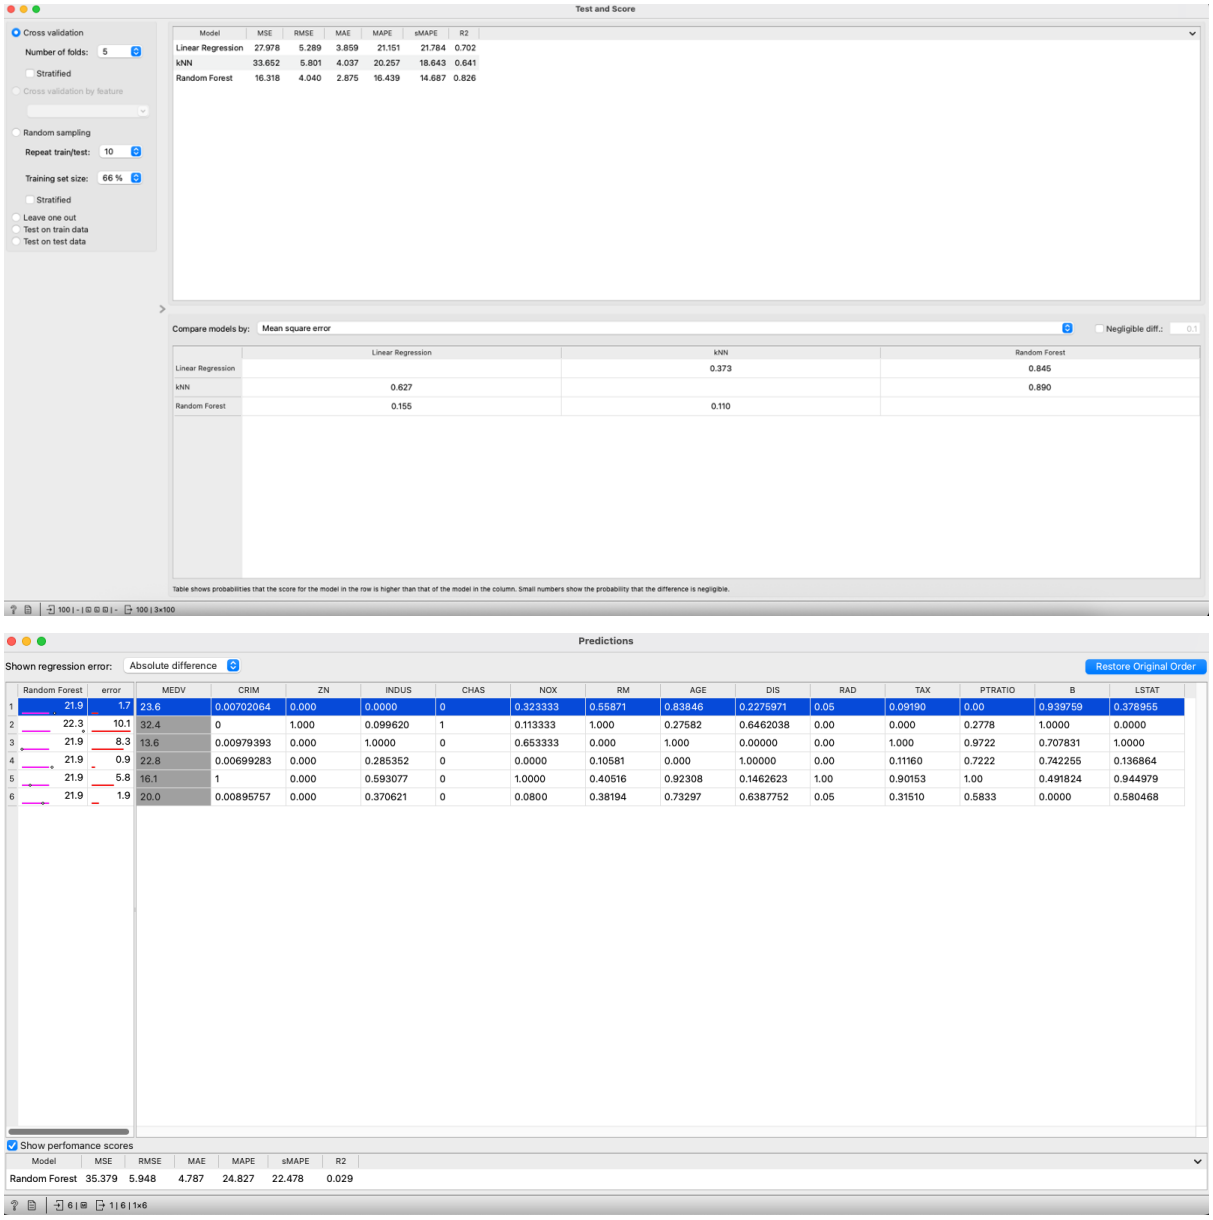

Gambar 4. Model evaluation (Random Forest)

- Perbandingan Model: Berdasarkan metrik evaluasi, model Random Forest merupakan model terbaik dibandingkan Linear Regression dan kNN. Model ini memiliki nilai R2 sebesar 0.826, yang berarti model mampu menjelaskan sekitar 82,6% variasi pada data harga rumah.
- Analisis Kesalahan (Error): Random Forest memiliki tingkat kesalahan paling rendah dengan nilai MAE (Mean Absolute Error) sebesar 2.875 dan RMSE sebesar 4.040. Ini menunjukkan

bahwa rata-rata selisih antara prediksi harga rumah dengan harga aktual adalah sekitar 2.875 unit.

- Akurasi Prediksi: Pada widget *Predictions*, terlihat sebagian besar hasil prediksi Random Forest mendekati nilai aktual (MEDV). Sebagai contoh, pada baris pertama, nilai aktual adalah 23.6 dan diprediksi sebesar 21.9 (selisih tipis sebesar 1.7).
- Kelemahan Model: Meskipun secara umum baik, terdapat beberapa *outlier* atau kasus sulit di mana model meleset cukup jauh, seperti pada baris kedua dengan selisih (*error*) mencapai 10.1.

Kesimpulan: Model Random Forest direkomendasikan untuk digunakan pada dataset ini karena memiliki tingkat presisi paling tinggi dan reliabilitas yang lebih baik dalam memprediksi nilai kontinu harga rumah dibandingkan algoritma lainnya.

Metode: Clustering

Data: Zoo Dataset

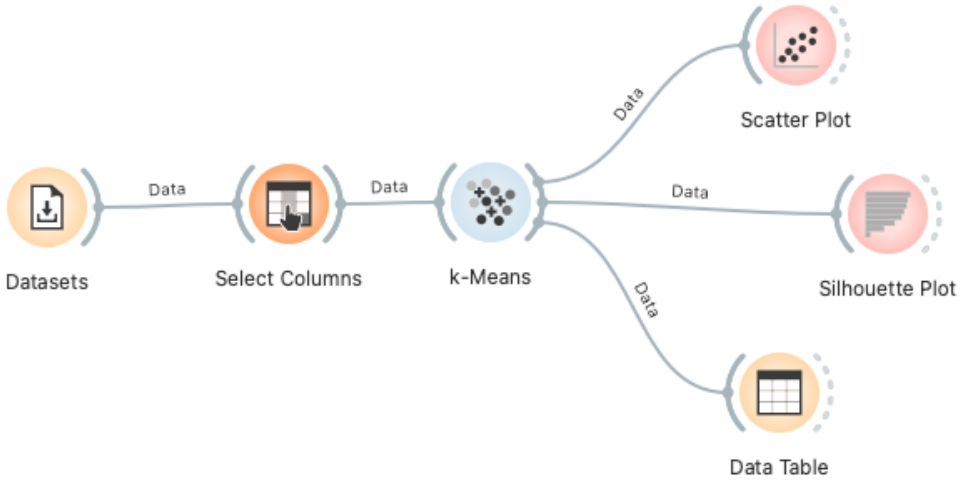

Gambar 5. Clustering Workflow

1. Persiapan Data

- Datasets: Langkah awal adalah memuat dataset Zoo yang berisi 101 hewan dengan berbagai fitur biologis.
- Select Columns: Pada tahap ini, kolom identitas seperti 'name' dan 'type' harus dipindahkan ke bagian *ignored*. Hal ini dilakukan agar algoritma melakukan pengelompokan murni berdasarkan fitur fisik, bukan berdasarkan label yang sudah ada.

2. Proses Clustering

- k-Means: Widget ini membagi data ke dalam sejumlah k kelompok (cluster) yang ditentukan oleh pengguna. Algoritma ini akan mencari pola tersembunyi dan memberikan label baru (seperti C1, C2) pada setiap baris data secara otomatis.

3. Evaluasi dan Visualisasi

- Scatter Plot: Digunakan untuk memvisualisasikan hasil pengelompokan secara grafis, biasanya dengan mengatur warna berdasarkan cluster yang terbentuk.
- Silhouette Plot: Widget krusial untuk mengevaluasi kualitas cluster. Skor yang lebih tinggi menunjukkan bahwa hewan-hewan telah terkelompokkan dengan baik dan terpisah secara jelas dari kelompok lain.
- Data Table: Digunakan untuk memeriksa detail setiap hewan di dalam setiap cluster, sehingga Anda dapat memberikan nama deskriptif bagi setiap kelompok tersebut

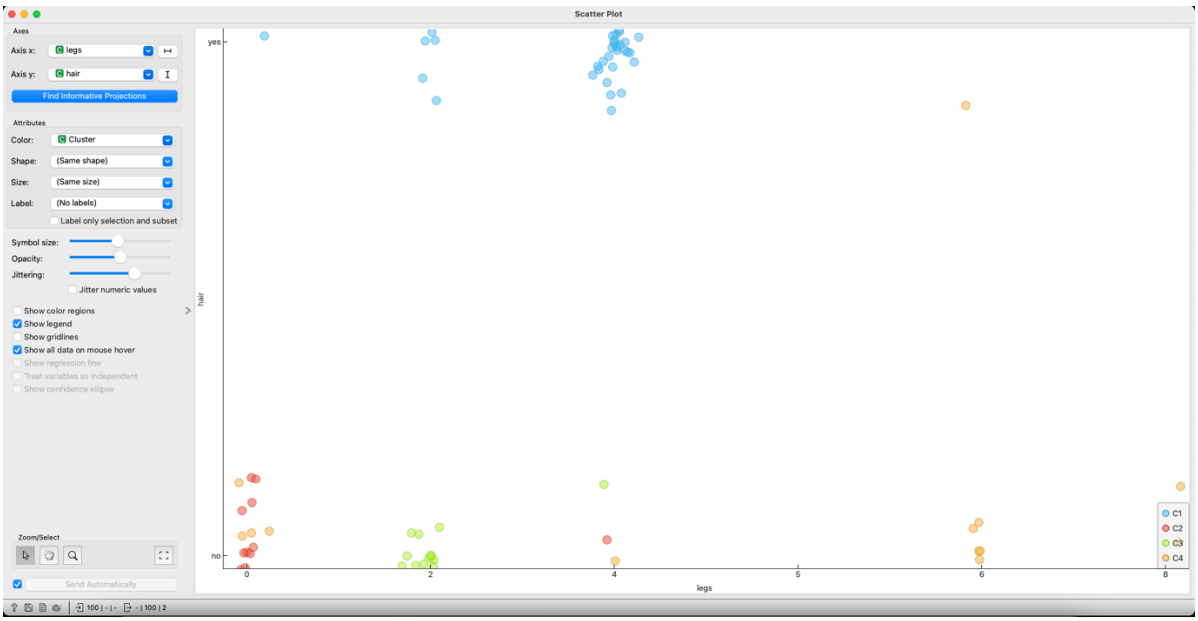

Gambar 6. Model Evaluation Scatter Plot & Silhouette Plot

1. Analisis Scatter Plot

- Pemisahan Berdasarkan Fitur: Grafik menunjukkan pengelompokan hewan berdasarkan jumlah kaki (legs) dan keberadaan rambut (hair).
- Identifikasi Cluster:
    - C1 (Biru): Mendominasi bagian atas grafik, mewakili hewan berkaki 2 hingga 4 yang memiliki rambut (seperti mamalia).
    - C2 (Merah) dan C3 (Hijau): Terkonsentrasi di bagian bawah (tidak berambut) dengan variasi jumlah kaki 0 dan 2.
    - C4 (Oranye): Tersebar pada jumlah kaki yang lebih banyak, kemungkinan besar mewakili kelompok serangga atau krustasea.

2. Analisis Silhouette Plot

- Kualitas Pengelompokan: *Silhouette plot* mengevaluasi seberapa cocok setiap hewan dalam clusternya.
- Skor Rata-rata:

    - C1 (0.479) dan C3 (0.451) memiliki skor tertinggi, yang berarti hewan-hewan di dalamnya sangat mirip satu sama lain dan terpisah dengan baik dari kelompok lain.
    - C4 (0.252) memiliki skor terendah, menunjukkan bahwa pengelompokan di cluster ini kurang konsisten atau anggotanya memiliki kemiripan yang lemah.
- Kesimpulan Keseluruhan: Karena sebagian besar batang berada di sisi positif (ke arah 0.5+), hasil clustering ini dianggap cukup baik karena tidak ada nilai negatif yang signifikan (yang biasanya berarti hewan salah masuk kelompok)