PEMROGRAMAN PHYTON

Nama : Tiara Aulia Septiani
NPM : 20124082
Kelas : C3-Informatika

1. **Metode: Regresi**
   Data : Housing Dataset

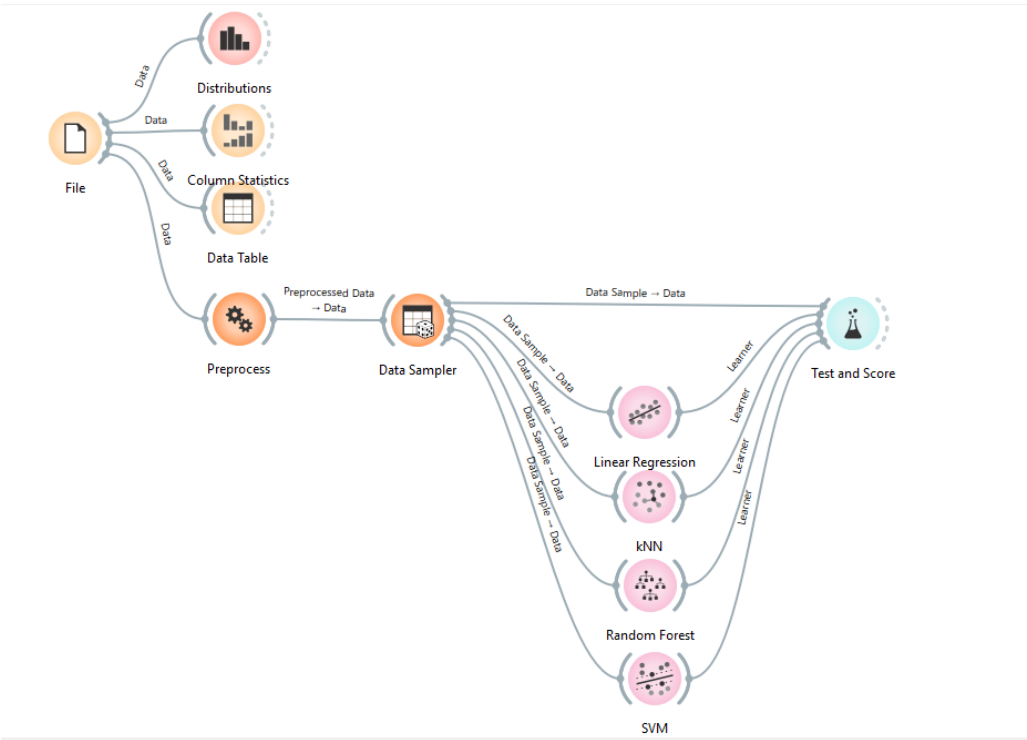

Gambar 1. 1Regresi Workflow

Penjelasan Workflow

- **Data Sampler** : Digunakan untuk membagi data menjadi data latih dan data uji agar model dapat dievaluasi secara objektif.
- **Model Regresi**: Melakukan pengujian pada empat algoritma utama: *Linear Regression*, *kNN*, *Random Forest*, dan *SVM*.
- **Test and Score**: Melakukan validasi silang (*Cross Validation*) dengan 5 *fold* untuk memastikan stabilitas hasil evaluasi model.

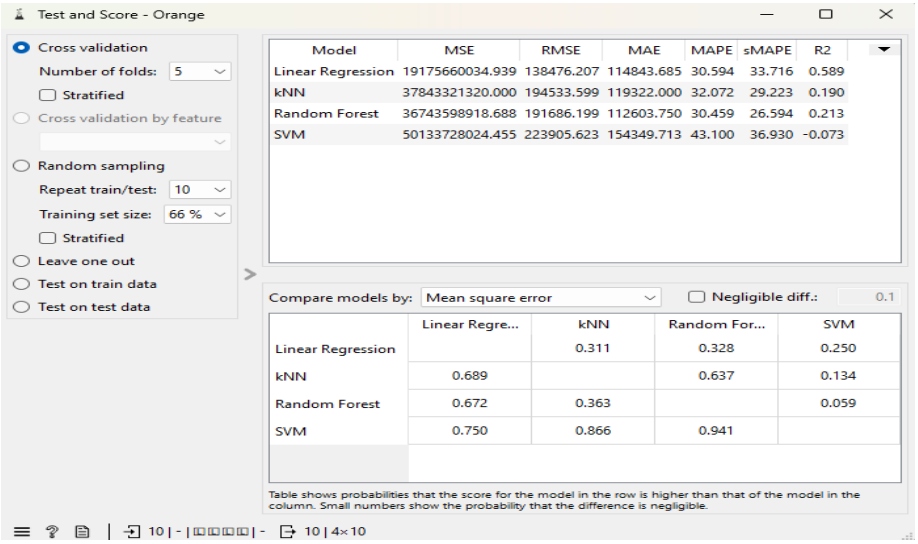

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	19175660034.939	138476.207	114843.685	30.594	33.716	0.589
kNN	37843321320.000	194533.599	119322.000	32.072	29.223	0.190
Random Forest	36743598918.688	191686.199	112603.750	30.459	26.594	0.213
SVM	50133728024.455	223905.623	154349.713	43.100	36.930	-0.073

	Linear Regre...	kNN	Random For...	SVM
Linear Regression		0.311	0.328	0.250
kNN	0.689		0.637	0.134
Random Forest	0.672	0.363		0.059
SVM	0.750	0.866	0.941	

Gambar 1. 2 Test and Score Regresi

Hasil Evaluasi Model Regresi

- **Hasil Perbandingan**: *Linear Regression* memberikan performa terbaik dengan nilai R^2 sebesar **0.589** dan RMSE **138476.207**.
- **Analisis Akurasi**: Nilai R^2 0.589 menunjukkan model mampu menjelaskan **58,9%** variasi harga pada dataset.
- **Kesimpulan**: Model *SVM* terbukti paling tidak sesuai untuk dataset ini karena menghasilkan nilai R^2 negatif (**-0.073**). *Linear Regression* dipilih sebagai model final.

2. Metode : Klasifikasi
Data : Titanic Dataset

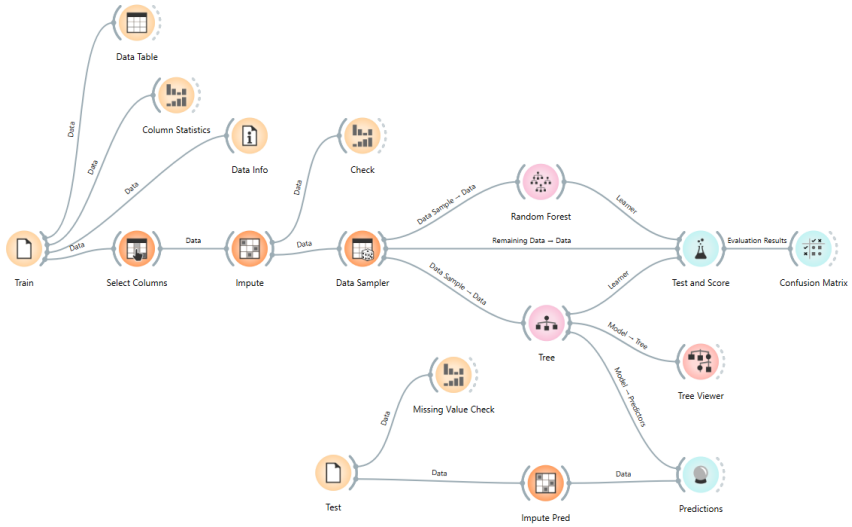

Gambar 1. 3 Klasifikasi Workflow

Penjelasan Workflow

- **Select Columns**: Memilih variabel atau fitur yang relevan dari dataset Titanic untuk digunakan dalam pemodelan.

- **Impute**: Mengisi nilai-nilai yang kosong (*missing values*) pada data latih agar proses analisis tetap akurat.
- **Data Sampler**: Membagi data menjadi sampel untuk proses pelatihan model dan evaluasi.
- **Model Klasifikasi**: Menggunakan dua algoritma utama, yaitu Random Forest dan Tree.
- **Test and Score**: Melakukan evaluasi performa model dengan metode *Cross Validation* menggunakan 10 *fold*.
- **Predictions & Confusion Matrix**: Digunakan untuk memprediksi data uji baru serta memetakan tingkat kesalahan klasifikasi model.

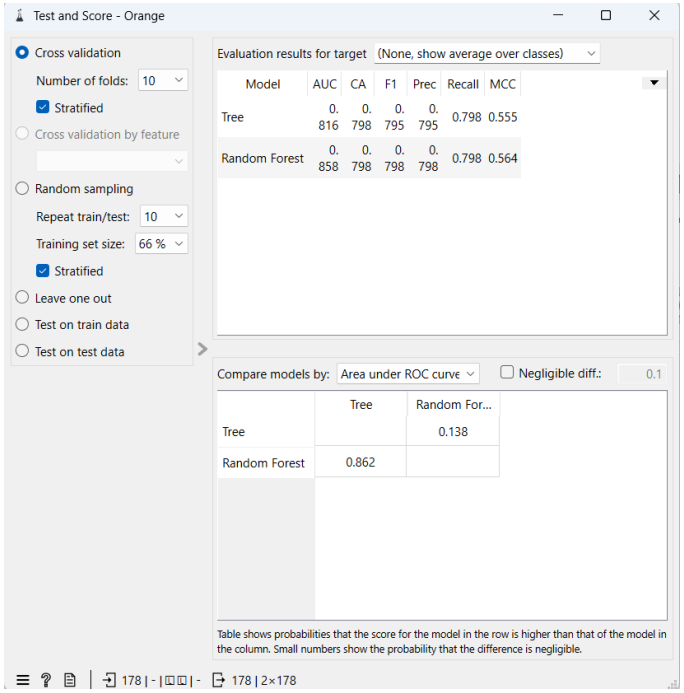

Gambar 1. 4 Test and Score Klasifikasi

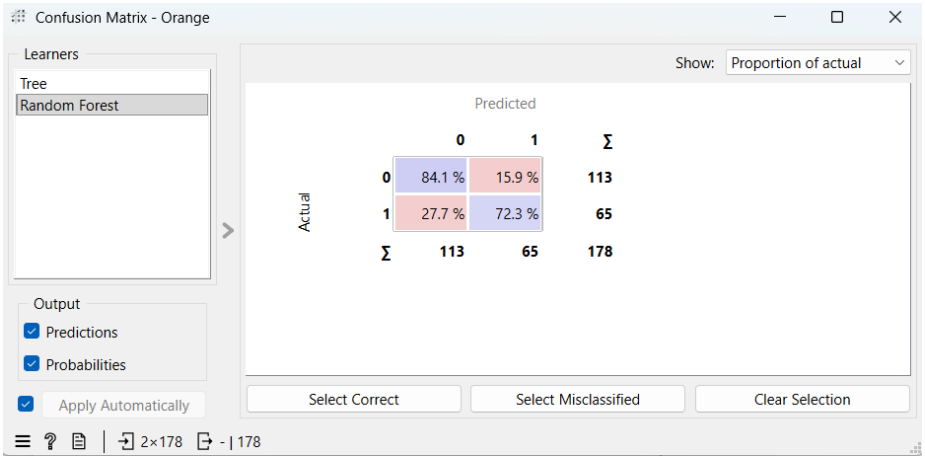

Gambar 1. 5 Confusion Matrix Klasifikasi

Hasil Evaluasi Model Klasifikasi

1. **Perfoma Model Terbaik**: Berdasarkan metrik pengujian, model Random Forest sedikit lebih unggul dibandingkan model Tree dengan nilai AUC 0.858, Akurasi (CA) 0.798, dan F1 0.798.
2. **Analisis Perbandingan**: Tabel perbandingan menunjukkan bahwa *Random Forest* memiliki probabilitas sebesar **0.862** untuk memberikan skor yang lebih tinggi dibandingkan model *Tree* dalam hal Area under ROC curve.
3. **Evaluasi Confusion Matrix (Model Tree)**:
    - **84.1%** dari penumpang yang secara aktual tidak selamat berhasil diprediksi dengan tepat (*True Negative*).
    - **72.3%** dari penumpang yang secara aktual selamat berhasil diprediksi dengan tepat (*True Positive*).

Kesimpulan:

Berdasarkan hasil pengujian, model **Random Forest** direkomendasikan sebagai model terbaik untuk dataset ini karena memberikan hasil klasifikasi yang lebih stabil dan akurat dibandingkan algoritma *Tree* tunggal.

3. Metode : Clustering
Data : Iris Dataset

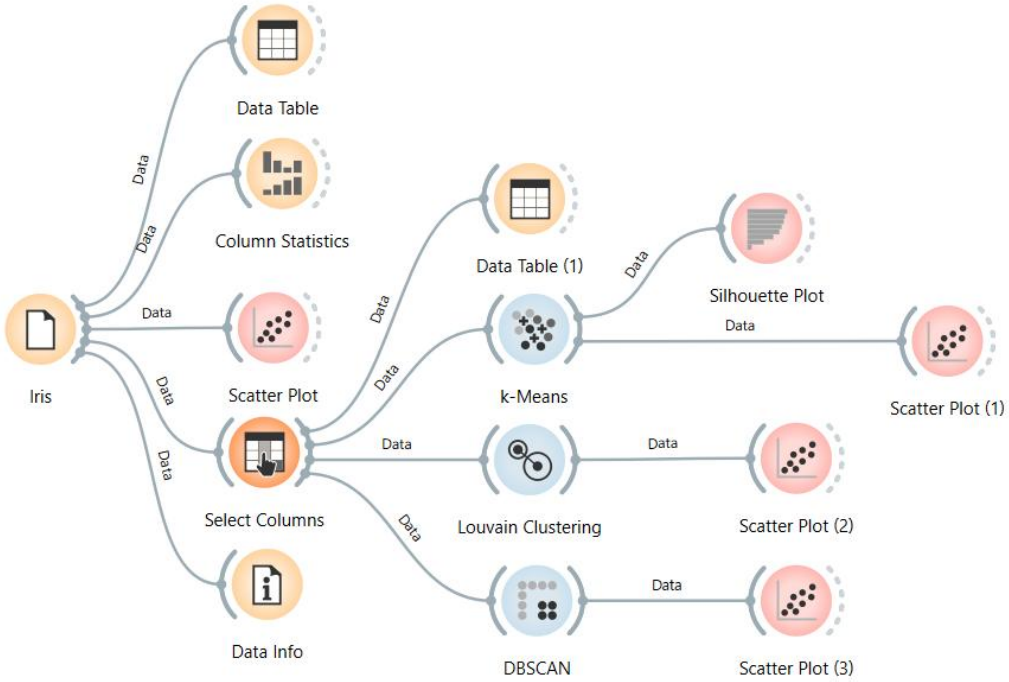

Gambar 1. 6 Clustering Workflow

Penjelasan Workflow

- **Select Columns**: Memilih fitur-fitur spesifik seperti panjang dan lebar petal/sepal untuk menentukan kemiripan antar objek.
- **Algoritma**: Membandingkan tiga pendekatan berbeda: *k-Means* (berbasis jumlah cluster), *Louvain* (berbasis komunitas), dan *DBSCAN* (berbasis kepadatan/densitas).

- **Silhouette Plot**: Digunakan untuk memvalidasi seberapa kuat suatu objek berada di dalam kelompoknya.

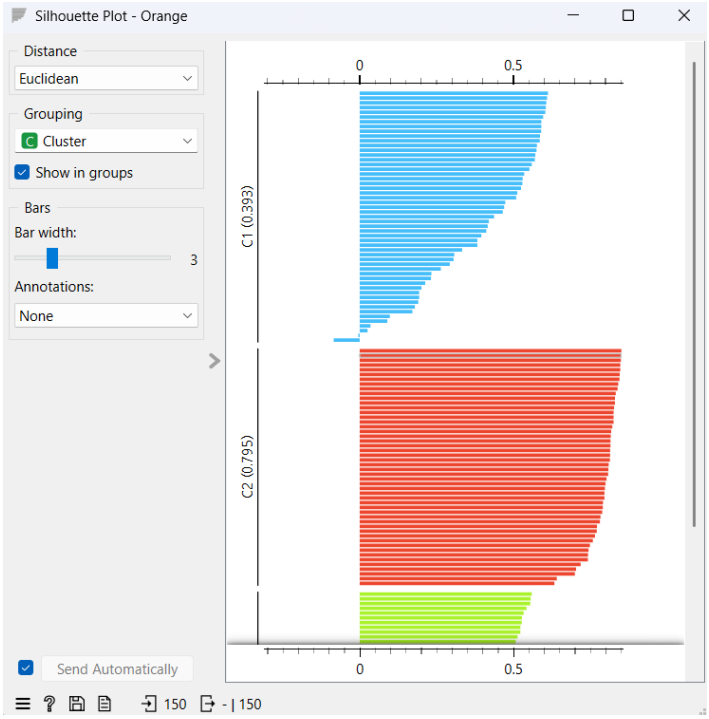

Gambar 1. 7 Silhouette Plot Clustering

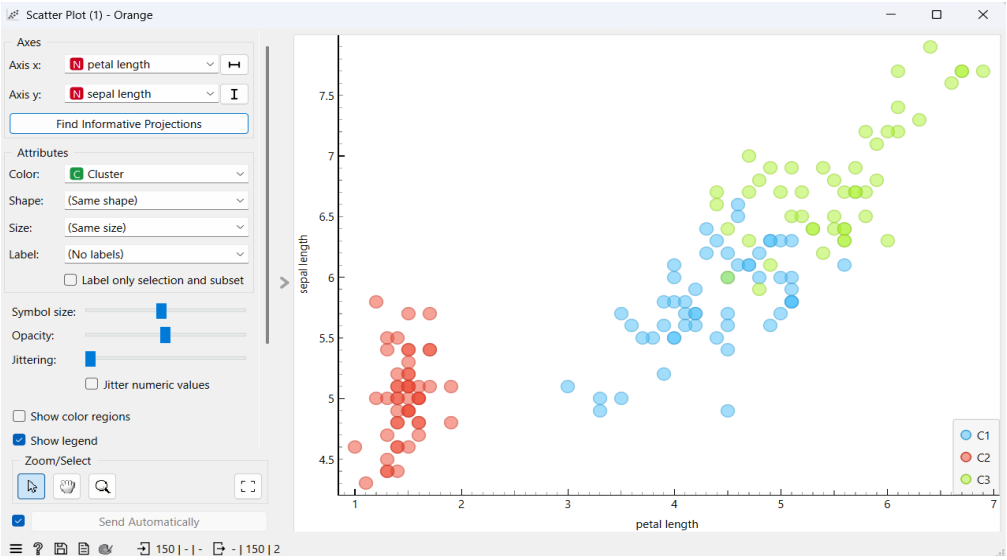

Gambar 1. 8 Scatter Plot (1)

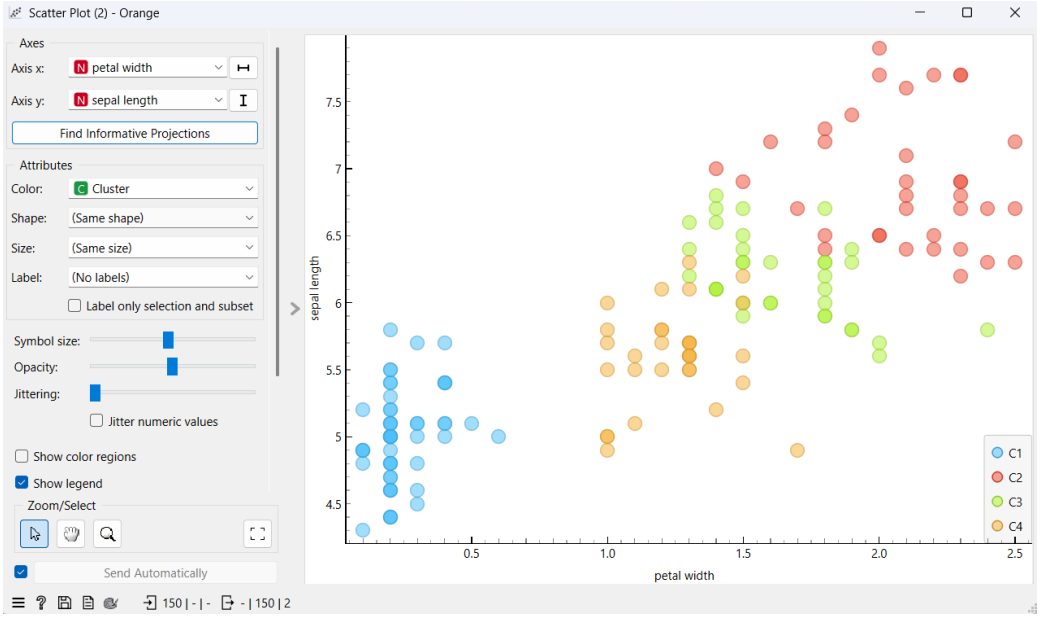

Gambar 1. 9 Scatter Plot (2)

Hasil Evaluasi Silhouette (k-Means)

Berdasarkan Silhouette Plot, asil pengelompokan menunjukkan kualitas yang cukup tinggi:

- **Cluster C2 (Warna Merah)**: Memiliki skor silhouette rata-rata tertinggi sebesar **0.795**. Bar yang lebar dan panjang menunjukkan anggota di cluster ini sangat solid dan terpisah jauh dari cluster lainnya.
- **Cluster C1 (Warna Biru)**: Memiliki skor rata-rata **0.393**. Terdapat satu bar kecil yang bernilai negatif (di bawah garis 0), yang menunjukkan ada data yang kemungkinan salah masuk kelompok atau berada di perbatasan.
- Nilai rata-rata silhouette yang positif menunjukkan bahwa algoritma berhasil menemukan struktur kelompok yang logis dalam data.

Analisis Visualisasi Scatter Plot

Dari hasil visualisasi pada *Scatter Plot (1)* dan *Scatter Plot (2)*:

- Terlihat satu kelompok (warna merah pada metrik petal) terpisah sangat jelas dari kelompok lainnya. Hal ini berkorelasi dengan nilai silhouette yang tinggi (0.795).
- Cluster C1 (biru) dan C3 (hijau) pada metrik *petal length* vs *sepal length* menunjukkan adanya sedikit tumpang tindih (*overlap*). Ini menjelaskan mengapa nilai silhouette pada kelompok tersebut lebih rendah dibandingkan kelompok merah.
- Fitur petal width dan petal length terlihat menjadi pembeda paling signifikan (informatif) dalam menentukan pembentukan cluster dibandingkan fitur sepal.

Perbandingan Algoritma

Berdasarkan alur kerja(Workflow:

1. K-Means : Memberikan hasil yang paling terstruktur untuk pengelompokan berdasarkan jumlah *k* yang ditentukan.

2. Louvain Clustering : Digunakan untuk mendeteksi komunitas dalam data, biasanya menghasilkan jumlah kelompok yang lebih dinamis.
3. DBSCAN : Sangat efektif untuk mendeteksi *outlier* dan menangani kelompok dengan bentuk yang tidak beraturan (non-spherical).