Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

Metode: Klasifikasi
Data: Titanic Dataset

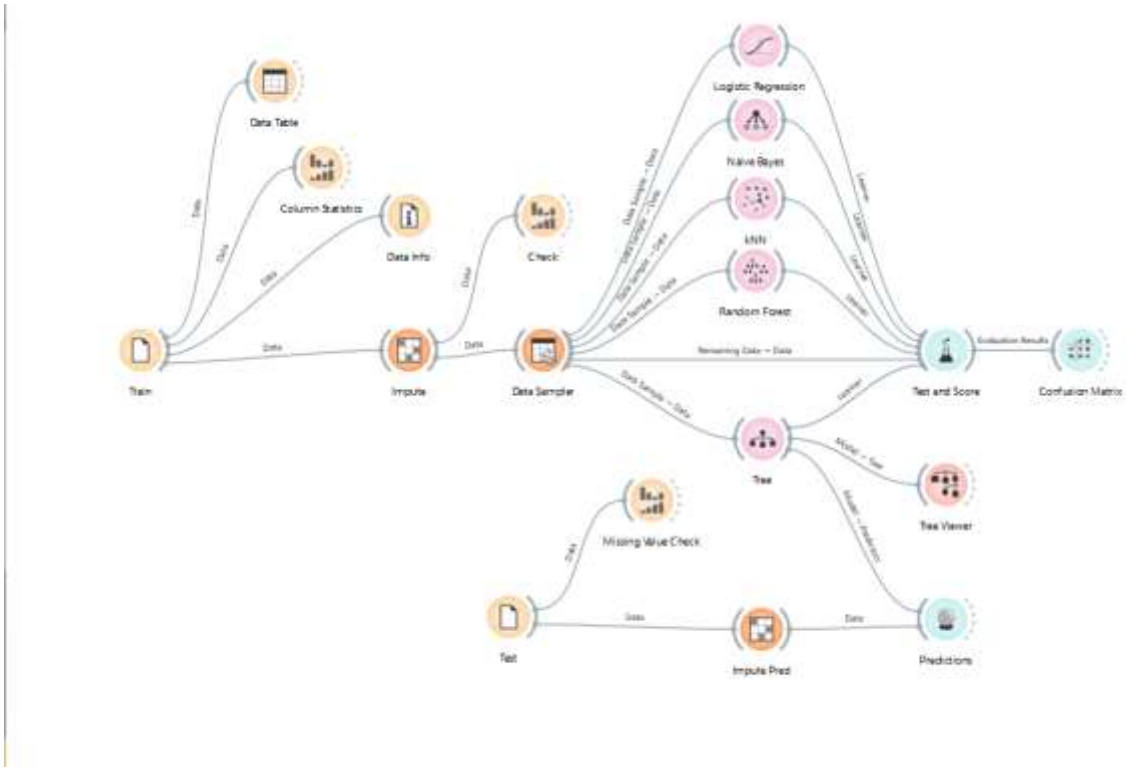

Gambar 1. Titanic Workflow

[*Penjelasan Workflow*]

- Pemuatan dan Eksplorasi Data
  Proses diawali dari widget File (Train) sebagai sumber data latih. Data kemudian dikirim secara paralel ke tiga widget eksplorasi yaitu Data Table untuk melihat isi data secara menyeluruh, Column Statistics untuk melihat ringkasan statistik tiap kolom, dan Data Info untuk menampilkan informasi umum seperti jumlah baris dan tipe kolom. Tahap ini bertujuan memahami struktur data sebelum preprocessing dilakukan.
- Preprocessing Data
  Data dari Train langsung masuk ke widget Impute, yang bertugas menangani missing values menggunakan strategi imputasi seperti rata-rata atau nilai paling sering muncul. Setelah imputasi, data diteruskan ke Data Sampler dan sebagian dialirkan ke Check (Data Info) sebagai verifikasi bahwa data telah bersih.
- Pembagian Data – Data Sampler
  Widget Data Sampler membagi data menjadi dua bagian. Data Sample dikirim ke semua lima algoritma klasifikasi sebagai data latih, sementara Remaining Data dikirim ke widget Test and Score sebagai data uji evaluasi.

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

Dari Data Sampler juga terdapat aliran ke Missing Value Check sebagai pemeriksaan tambahan kualitas data setelah pembagian.

- Pemodelan – 5 Algoritma Klasifikasi
  Logistic Regression adalah model linear yang menghitung probabilitas keselamatan penumpang berdasarkan kombinasi fitur. Naïve Bayes menggunakan pendekatan probabilistik berbasis Teorema Bayes dengan asumsi independensi antar fitur. kNN (k-Nearest Neighbors) mengklasifikasikan data berdasarkan kemiripan dengan tetangga terdekat dalam ruang fitur. Random Forest membangun banyak pohon keputusan secara acak dan menggabungkan hasilnya untuk prediksi yang lebih stabil. Tree (Decision Tree) membangun satu pohon keputusan tunggal yang dapat divisualisasikan melalui widget Tree Viewer.
  Semua model kecuali Tree mengirimkan hasil learner-nya langsung ke widget Test and Score, sedangkan Tree selain ke Test and Score juga menghasilkan output Model yang digunakan untuk prediksi data baru dan visualisasi di Tree Viewer.
- Evaluasi Model
  Widget Test and Score menerima kelima learner sekaligus beserta data uji (Remaining Data), lalu mengevaluasi dan membandingkan performa semua model dalam satu tabel. Hasilnya dikirim ke dua widget, yaitu Evaluation Results yang menampilkan metrik seperti akurasi, AUC, precision, recall, dan F1-score untuk setiap model, serta Confusion Matrix yang menampilkan rincian prediksi benar dan salah per kelas untuk model yang dipilih.
- Prediksi Data Baru
  Secara terpisah, widget File (Test) memuat data uji baru (titanic_test.csv). Data ini masuk ke Impute Pred untuk imputasi agar formatnya konsisten dengan data latih. Selanjutnya, data yang telah bersih dikirim ke widget Predictions yang menggunakan model Tree untuk menghasilkan prediksi akhir terhadap data yang belum diketahui labelnya.

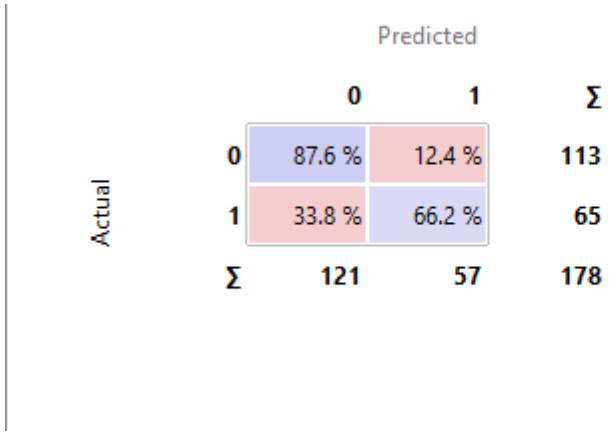

Actual \ Predicted	0	1	Σ
0	87.6 %	12.4 %	113
1	33.8 %	66.2 %	65
Σ	121	57	178

Gambar 2. Model Evaluation (Tree)

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

Actual \ Predicted	0	1	Σ
0	83.2 %	16.8 %	113
1	29.2 %	70.8 %	65
Σ	113	65	178

Gambar 3. Model Evaluation (Random Forest)

Actual \ Predicted	0	1	Σ
0	81.4 %	18.6 %	113
1	41.5 %	58.5 %	65
Σ	119	59	178

Gambar 4. Model Evaluation (kNN)

Actual \ Predicted	0	1	Σ
0	81.4 %	18.6 %	113
1	29.2 %	70.8 %	65
Σ	111	67	178

Gambar 5. Model Evaluation (Naive Bayes)

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

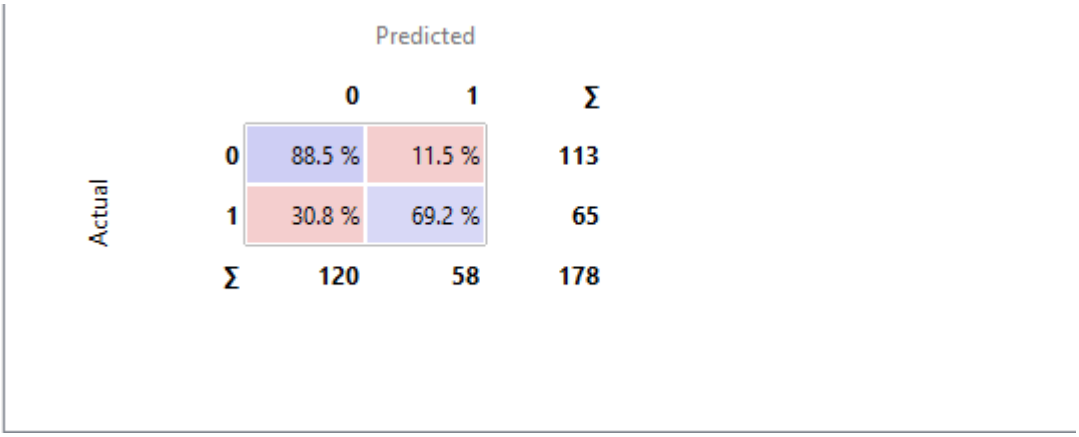

Actual \ Predicted	0	1	Σ
0	88.5 %	11.5 %	113
1	30.8 %	69.2 %	65
Σ	120	58	178

Gambar 6. Model Evaluation (Logistic Regression)

[Penjelasan Evaluation]

Gambar 2 – Tree

TN 87.6% menunjukkan model cukup baik mengenali kelas tidak selamat, namun Recall kelas selamat hanya 66.2% dengan FN 33.8%, artinya sepertiga penumpang yang selamat salah diprediksi. Accuracy ≈ 79.8%, Precision ≈ 75.4%, F1-Score ≈ 70.5%.

Gambar 3 – Random Forest

Model ini menunjukkan keseimbangan yang menarik: FN turun menjadi 29.2% dan TP naik ke 70.8%. Recall dan Precision kelas selamat sama-sama ≈ 70.8%, menghasilkan F1-Score ≈ 70.8%. Accuracy ≈ 78.7%, sedikit di bawah Decision Tree namun lebih seimbang antar kelas.

Gambar 4 – kNN

Performa terlemah di antara kelima model. FN mencapai 41.5%, artinya hampir separuh penumpang yang selamat tidak terdeteksi. Accuracy hanya ≈ 73.0%, Precision ≈ 64.4%, Recall ≈ 58.5%, F1-Score ≈ 61.3%. kNN kemungkinan sensitif terhadap skala fitur dan kurang cocok tanpa normalisasi lebih lanjut.

Gambar 5 – Naïve Bayes

TN 81.4% dan TP 70.8% menunjukkan keseimbangan yang baik antar kelas, serupa dengan Random Forest pada sisi Recall. Accuracy ≈ 77.5%, Precision ≈ 68.7%, F1-Score ≈ 69.7%. Performa solid mengingat Naïve Bayes adalah model yang sangat ringan secara komputasi.

Gambar 6 – Logistic Regression

Model dengan performa terbaik secara keseluruhan. TN tertinggi di antara semua model (88.5%) dan FP terendah (11.5%), menandakan model sangat presisi dalam

mengenali kelas tidak selamat. Accuracy ≈ 81.5%, Precision ≈ 77.6%, Recall ≈ 69.2%, F1-Score ≈ 73.1%.

Kesimpulan

Logistic Regression menjadi model terbaik pada dataset ini dengan accuracy dan precision tertinggi. Random Forest dan Naïve Bayes unggul dalam keseimbangan Recall antar kelas. kNN menjadi model terlemah dan membutuhkan optimasi lebih lanjut seperti normalisasi fitur atau tuning nilai k. Ketidakseimbangan kelas (113 vs 65 sampel) secara konsisten menjadi tantangan di semua model, yang tercermin dari nilai FN yang masih cukup tinggi.

Metode: Regresi

Data: Housing Dataset

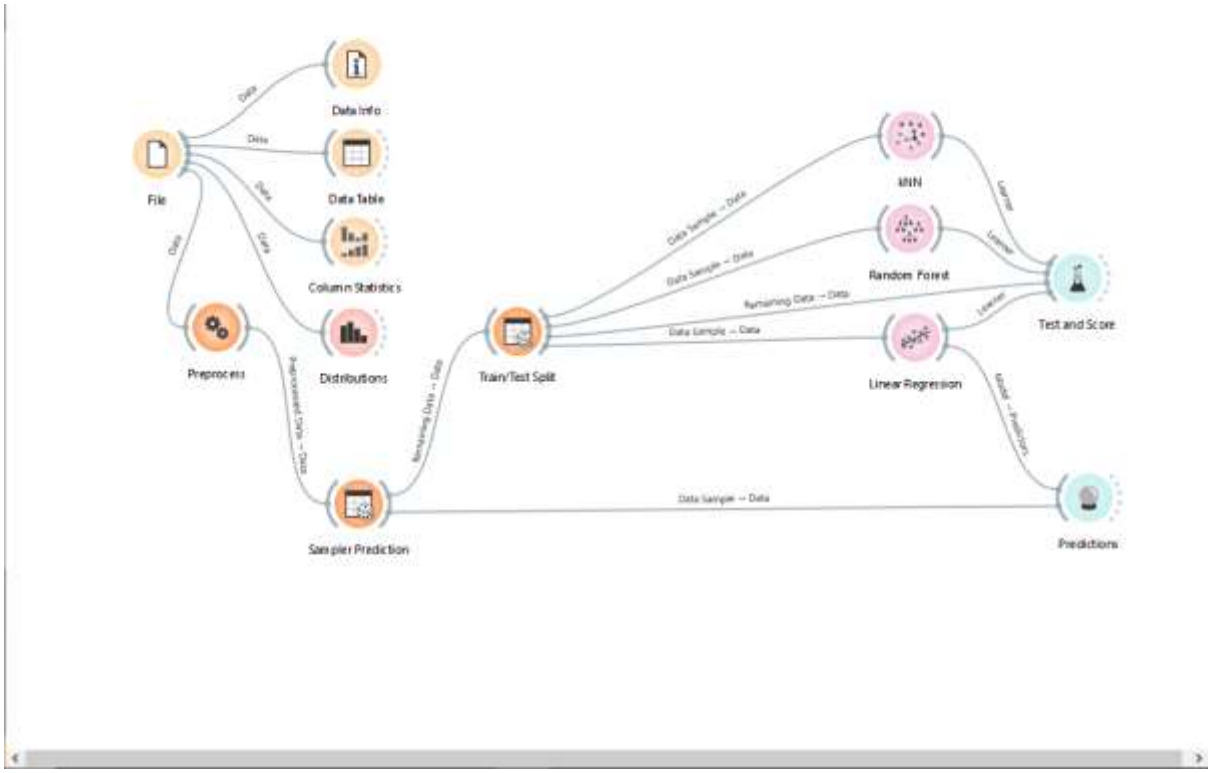

Gambar 7. Housing Workflow

[Penjelasan Workflow]

1. Pemuatan dan Eksplorasi Data

Proses dimulai dari widget File sebagai sumber data housing.csv. Data langsung dikirim ke empat widget eksplorasi secara paralel: Data Info untuk ringkasan umum dataset, Data Table untuk melihat isi data per baris, Column Statistics untuk statistik

deskriptif tiap kolom, dan Distributions untuk melihat distribusi nilai setiap fitur. Tahap ini penting untuk memahami karakteristik data sebelum preprocessing.

2. Preprocessing Data

Data dari File dikirim ke widget Preprocess, yang menangani berbagai tahap pembersihan dan transformasi data seperti normalisasi fitur, penanganan missing values, dan encoding. Output dari Preprocess disebut Preprocessed Data yang kemudian diteruskan ke dua jalur: ke Distributions untuk verifikasi visual hasil preprocessing, dan ke Sampler Prediction sebagai data yang siap digunakan untuk prediksi akhir.

3. Pembagian Data – Train/Test Split

Widget Train/Test Split (ekuivalen Data Sampler) membagi Preprocessed Data menjadi dua bagian. Data Sample dikirim ke ketiga algoritma sebagai data latih, sementara Remaining Data dikirim ke Test and Score sebagai data uji evaluasi model.

4. Pemodelan – Tiga Algoritma Regresi

kNN Regression memprediksi nilai target berdasarkan rata-rata nilai tetangga terdekat dalam ruang fitur. Random Forest Regression membangun banyak pohon keputusan dan merata-ratakan hasilnya untuk prediksi yang lebih stabil dan akurat. Linear Regression memodelkan hubungan linear antara fitur-fitur input dengan harga rumah sebagai target variabel.

Ketiga model mengirimkan learner-nya ke Test and Score, namun khusus Linear Regression juga menghasilkan output Model yang digunakan langsung untuk prediksi pada data baru.

5. Evaluasi Model

Widget Test and Score menerima ketiga learner sekaligus beserta Remaining Data, lalu mengevaluasi dan membandingkan performa semua model. Karena ini adalah regresi, metrik yang digunakan adalah RMSE (Root Mean Squared Error), MAE (Mean Absolute Error), dan R^2 (koefisien determinasi), bukan akurasi seperti pada klasifikasi.

6. Prediksi Data Baru

Widget Sampler Prediction mengirimkan sebagian data ke widget Predictions, yang menggunakan model Linear Regression untuk menghasilkan prediksi nilai harga rumah pada data baru. Alur ini memisahkan proses evaluasi dari proses prediksi operasional.

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

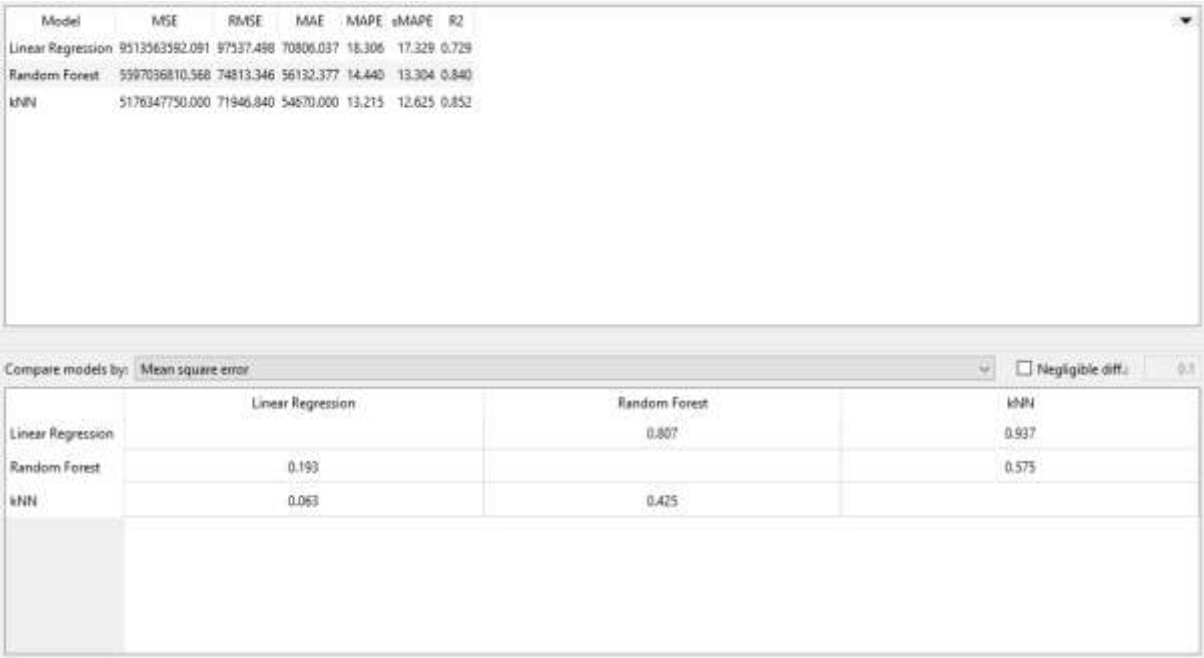

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	9513563592.091	97537.498	70806.037	18.306	17.329	0.729
Random Forest	5597036810.568	74813.346	56132.377	14.440	13.304	0.840
kNN	5176347750.000	71946.840	54570.000	13.215	12.625	0.852

Compare models by: Mean square error — Negligible diff.: 0.1

	Linear Regression	Random Forest	kNN
Linear Regression		0.807	0.937
Random Forest	0.193		0.575
kNN	0.063	0.425	

Gambar 8. Model Evaluation

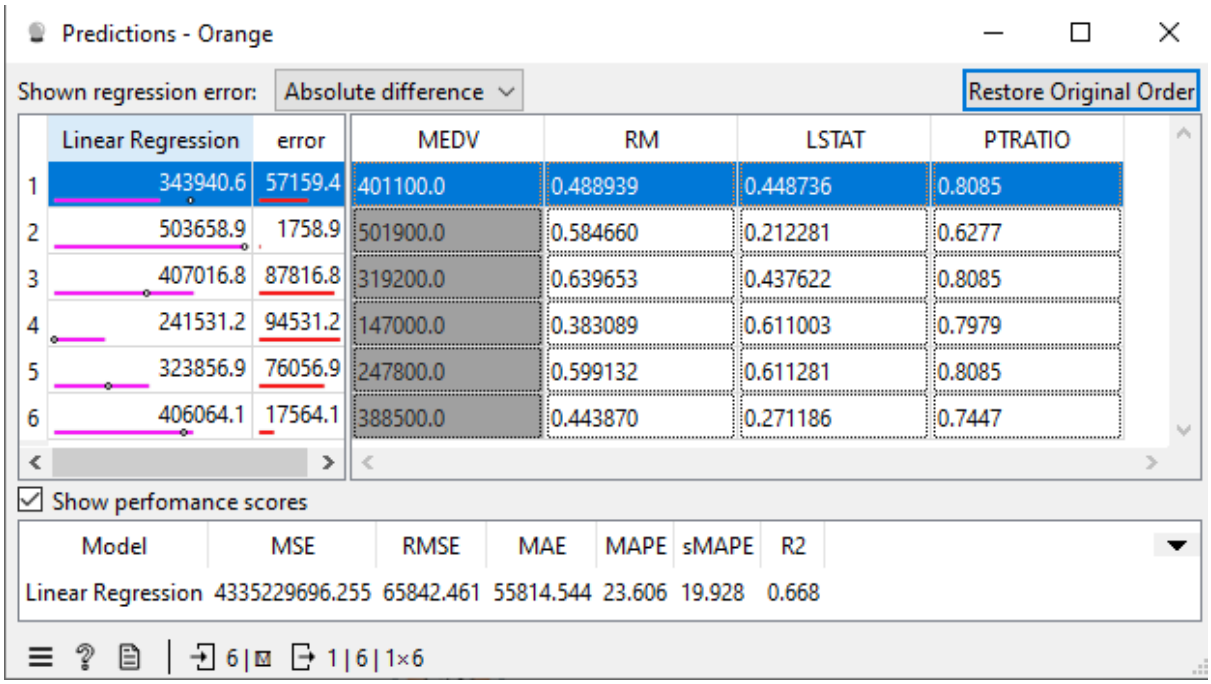

Predictions - Orange

Shown regression error: Absolute difference — Restore Original Order

	Linear Regression	error	MEDV	RM	LSTAT	PTRATIO
1	343940.6	57159.4	401100.0	0.488939	0.448736	0.8085
2	503658.9	1758.9	501900.0	0.584660	0.212281	0.6277
3	407016.8	87816.8	319200.0	0.639653	0.437622	0.8085
4	241531.2	94531.2	147000.0	0.383089	0.611003	0.7979
5	323856.9	76056.9	247800.0	0.599132	0.611281	0.8085
6	406064.1	17564.1	388500.0	0.443870	0.271186	0.7447

Show perfomance scores

Model	MSE	RMSE	MAE	MAPE	sMAPE	R2
Linear Regression	4335229696.255	65842.461	55814.544	23.606	19.928	0.668

6 | 1 | 6 | 1×6

Gambar 9. Model Evaluation

[Penjelasan Evaluation]

Gambar 1 – Test and Score (Perbandingan 3 Model)

Hasil evaluasi menunjukkan perbandingan tiga model regresi menggunakan metrik MSE, RMSE, MAE, MAPE, sMAPE, dan R^2.

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

kNN menjadi model terbaik dengan RMSE dan MAE terendah serta R^2 tertinggi (0.852), artinya model mampu menjelaskan 85.2% variansi harga rumah. Linear Regression menjadi yang terlemah dengan error terbesar dan R^2 hanya 0.729, mengindikasikan hubungan antar fitur dan target tidak sepenuhnya linear.

Pada tabel perbandingan MSE antar model, nilai p-value kNN vs Linear Regression = 0.063 (mendekati signifikan), sedangkan Random Forest vs Linear Regression = 0.193, menunjukkan perbedaan performa antar model belum sepenuhnya signifikan secara statistik.

Gambar 2 – Predictions (Linear Regression)

Widget Predictions menampilkan hasil prediksi Linear Regression pada 6 sampel data baru menggunakan fitur MEDV, RM, LSTAT, dan PTRATIO. Metrik performa pada data prediksi ini adalah MSE 4,335,229,696, RMSE 65,842, MAE 55,814, dan R^2 0.668, sedikit lebih rendah dari hasil Test and Score (0.729). Selisih error (absolute difference) terbesar terlihat pada baris 3 dengan error 87,816, menandakan model kurang akurat pada harga ekstrem.

Kesimpulan

kNN adalah model terbaik untuk dataset ini, diikuti Random Forest. Linear Regression kurang optimal karena Housing Dataset kemungkinan memiliki hubungan non-linear antar fitur. Penurunan R^2 Linear Regression dari 0.729 ke 0.668 pada data prediksi mengindikasikan adanya overfitting ringan atau perbedaan distribusi antara data latih dan data prediksi.

Metode: Clustering

Data: Zoo Dataset

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

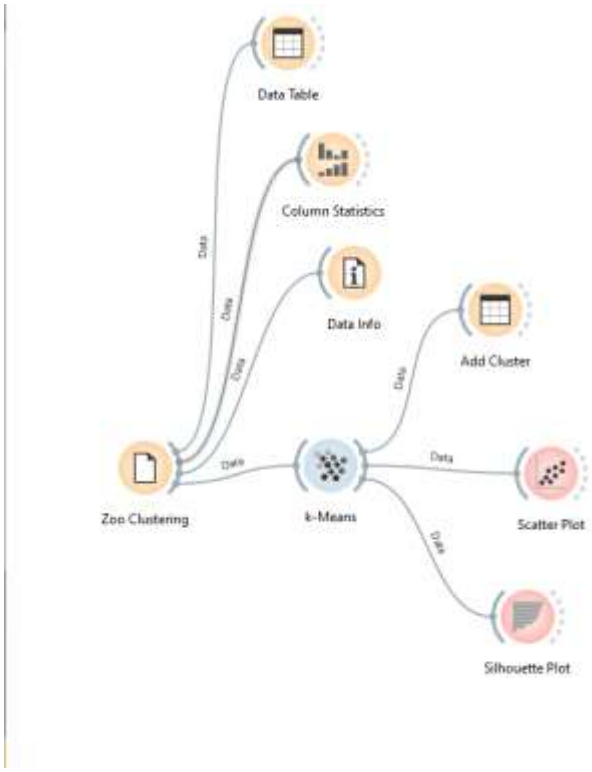

Gambar 10. Zoo Workflow

1. Pemuatan dan Eksplorasi Data

Proses dimulai dari widget File (Zoo Clustering) sebagai sumber dataset. Data dikirim secara paralel ke Data Table, Column Statistics, dan Data Info untuk eksplorasi awal, meliputi isi data, statistik deskriptif, dan informasi umum struktur dataset.

2. Clustering – k-Means

Data dari Zoo Clustering dikirim ke widget k-Means, yang mengelompokkan data ke dalam sejumlah k cluster berdasarkan kemiripan fitur. Algoritma ini bekerja dengan meminimalkan jarak setiap data point terhadap centroid clusternya. Output k-Means menghasilkan dua jalur keluaran: data dengan label cluster ke Add Cluster, dan data hasil clustering ke Silhouette Plot.

3. Visualisasi dan Evaluasi Cluster

Widget Silhouette Plot digunakan untuk mengevaluasi kualitas clustering. Nilai silhouette berkisar antara -1 hingga 1, di mana nilai mendekati 1 menunjukkan cluster yang terbentuk padat dan terpisah dengan baik.

Widget Add Cluster menambahkan kolom label cluster ke dalam data asli, kemudian mengirimkan Selected Data ke widget Scatter Plot untuk memvisualisasikan sebaran data berdasarkan cluster yang terbentuk dalam ruang dua dimensi.

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

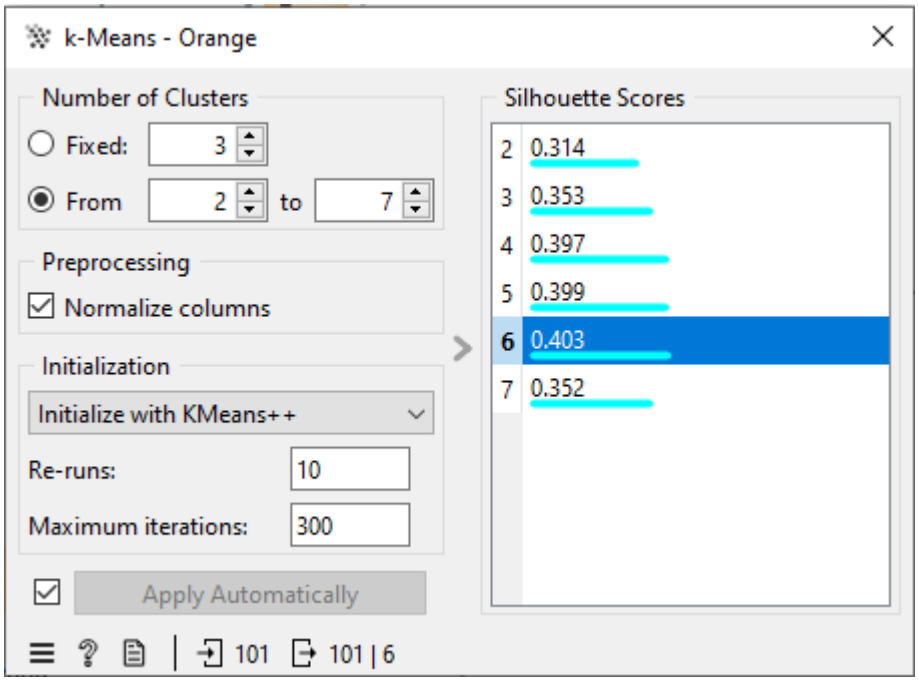

Gambar 11. Cluster Evaluation

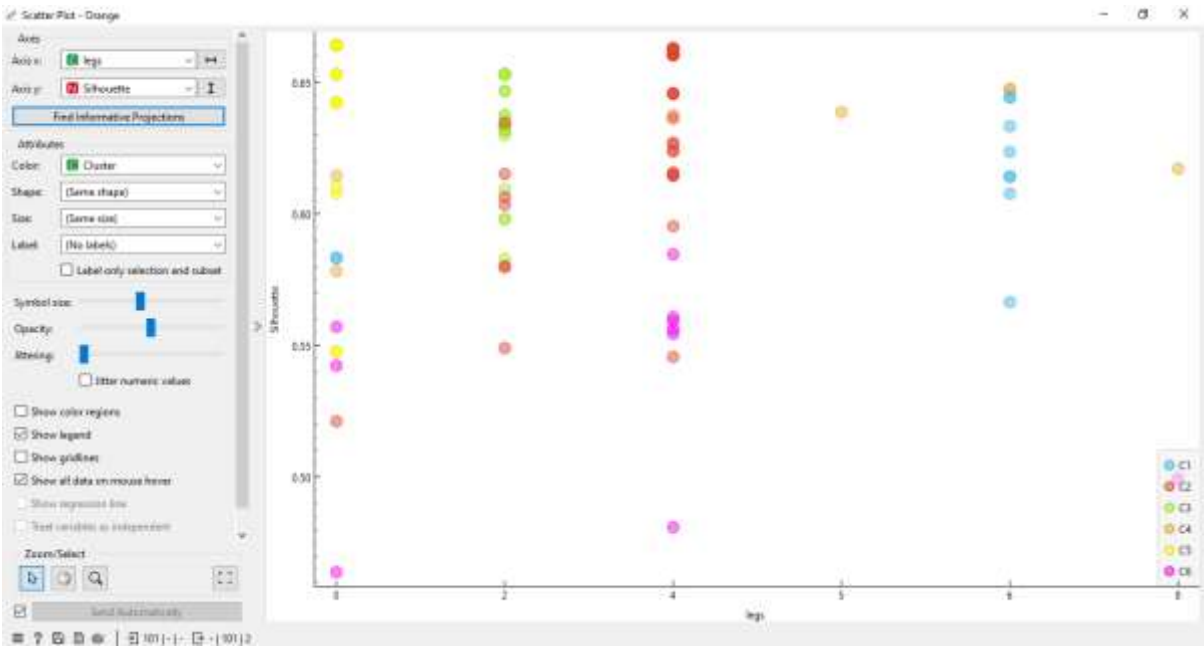

Gambar 12. Cluster Evaluation

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

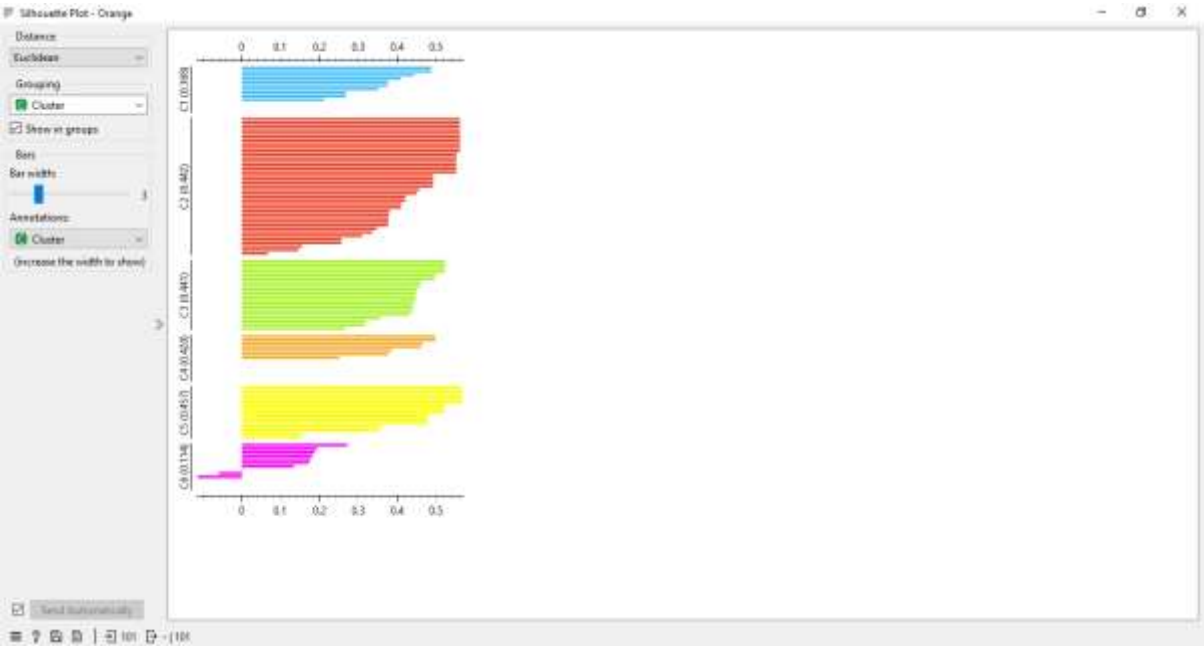

Gambar 13. Cluster Evaluation

a. K Terbaik Berdasarkan Silhouette Score

Dari widget k-Means (Gambar 1), pengujian dilakukan dari k=2 hingga k=7. Hasil silhouette score tiap k adalah: k=2 (0.314), k=3 (0.353), k=4 (0.397), k=5 (0.399), k=6 (0.403), k=7 (0.352). k=6 memberikan silhouette score tertinggi (0.403), menjadikannya konfigurasi cluster terbaik. Meskipun selisihnya tidak besar dibanding k=5, k=6 menghasilkan pemisahan cluster yang paling optimal secara keseluruhan.

b. Karakteristik Tiap Cluster

Berdasarkan Scatter Plot (Gambar 2) dengan sumbu legs vs Silhouette dan Silhouette Plot (Gambar 3), setiap cluster mengelompokkan hewan berdasarkan kesamaan fitur biologis sebagai berikut:

C1 → Hewan dengan 0 kaki dan sirip, kemungkinan besar ikan. Fitur dominan: aquatic, fins, tidak bernapas di darat.

C2 → Hewan dengan 2 kaki, menunjukkan kelompok burung. Fitur dominan: feathers, airborne, bertelur.

C3 → Hewan dengan 4 kaki dan rambut, kelompok mamalia darat. Fitur dominan: hair, milk, backbone, tidak bertelur. Cluster ini memiliki silhouette bar terpanjang di Gambar 3, artinya cluster paling kohesif.

C4 → Hewan dengan 4 kaki namun bertelur, kemungkinan reptil dan amfibi. Fitur dominan: eggs, tidak berbulu, backbone.

Nama: Malik Nur Khaerudin
NIM: 20124085
Kelas: C3|24 S1 Informatika

C5 → Hewan dengan 6 kaki, yaitu kelompok serangga. Fitur dominan: airborne sebagian, bertelur, tidak ber-backbone (invertebrata).

C6 → Hewan dengan 8 kaki atau kaki bervariasi, kelompok arakhnida dan invertebrata lainnya. Cluster terkecil dengan silhouette terendah, menunjukkan kelompok paling heterogen.