Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

Metode: Classification
Data: Titanic Dataset

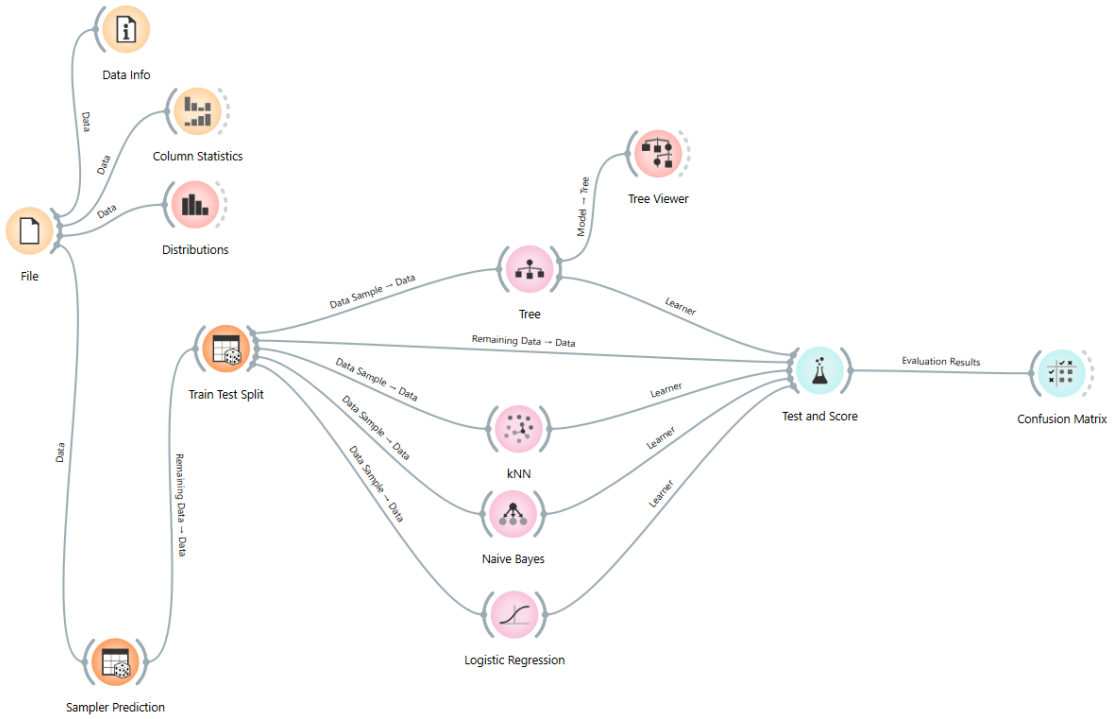

Gambar 1. Classification Workflow

Penjelasan Workflow

Tahap pertama adalah load data titanic menggunakan widget File, kemudian dilakukan eksplorasi data menggunakan Data Info, Column Statistics, dan Distributions untuk memahami karakteristik dataset.

Selanjutnya, dilakukan pembagian data menggunakan Train Test Split menjadi data training dan data testing. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk evaluasi.

Pada tahap berikutnya, digunakan beberapa algoritma klasifikasi yaitu:

- Decision Tree
- k-Nearest Neighbors (kNN)
- Naive Bayes
- Logistic Regression

Setiap model dilatih menggunakan data training, kemudian hasilnya dibandingkan menggunakan widget Test and Score untuk melihat performa masing-masing model.

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

Hasil evaluasi kemudian divisualisasikan menggunakan Confusion Matrix untuk melihat detail kesalahan prediksi, seperti True Positive, True Negative, False Positive, dan False Negative.

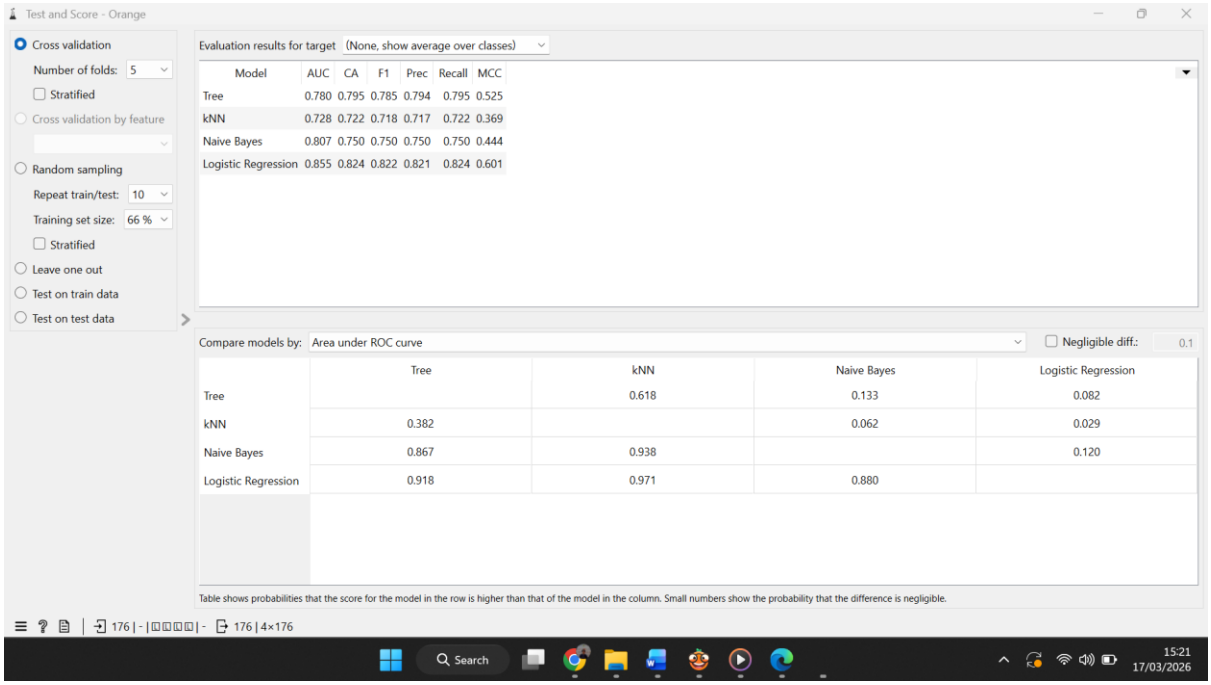

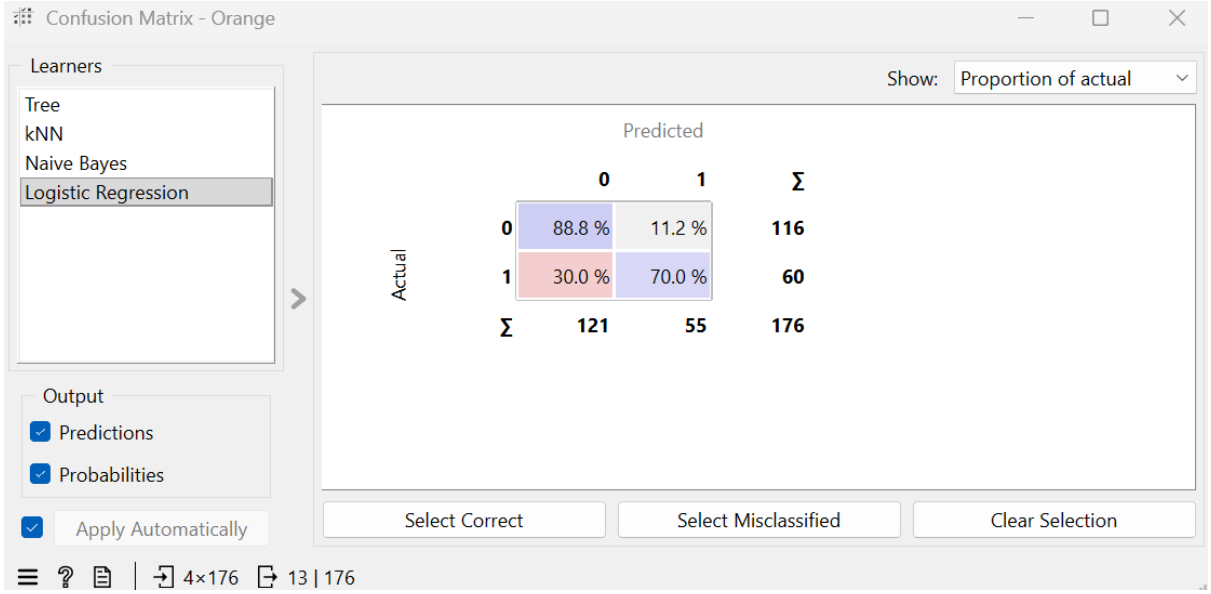

Gambar 2. Model Evaluation (Logistic Regression)

Berdasarkan hasil evaluasi menggunakan Test and Score, dilakukan perbandingan performa beberapa model klasifikasi yaitu Decision Tree, kNN, Naive Bayes, dan Logistic Regression.

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

Hasil menunjukkan bahwa:

- Model dengan nilai AUC tertinggi adalah Logistic Regression sebesar 0.855
- Model dengan nilai F1 Score tertinggi juga adalah Logistic Regression sebesar 0.822

Hal ini menunjukkan bahwa Logistic Regression memiliki kemampuan terbaik dalam membedakan kelas serta memiliki keseimbangan yang baik antara precision dan recall.

Selain itu, berdasarkan Confusion Matrix, terdapat sekitar 13 penumpang yang diprediksi selamat (survived), padahal sebenarnya tidak selamat. Nilai ini diperoleh dari perhitungan:

$11.2\% \times 116 = 12.99 \approx 13$

Sehingga dapat disimpulkan bahwa Logistic Regression merupakan model terbaik pada dataset Titanic dalam percobaan ini.

Metode: Regression
Data: Boston Housing Dataset

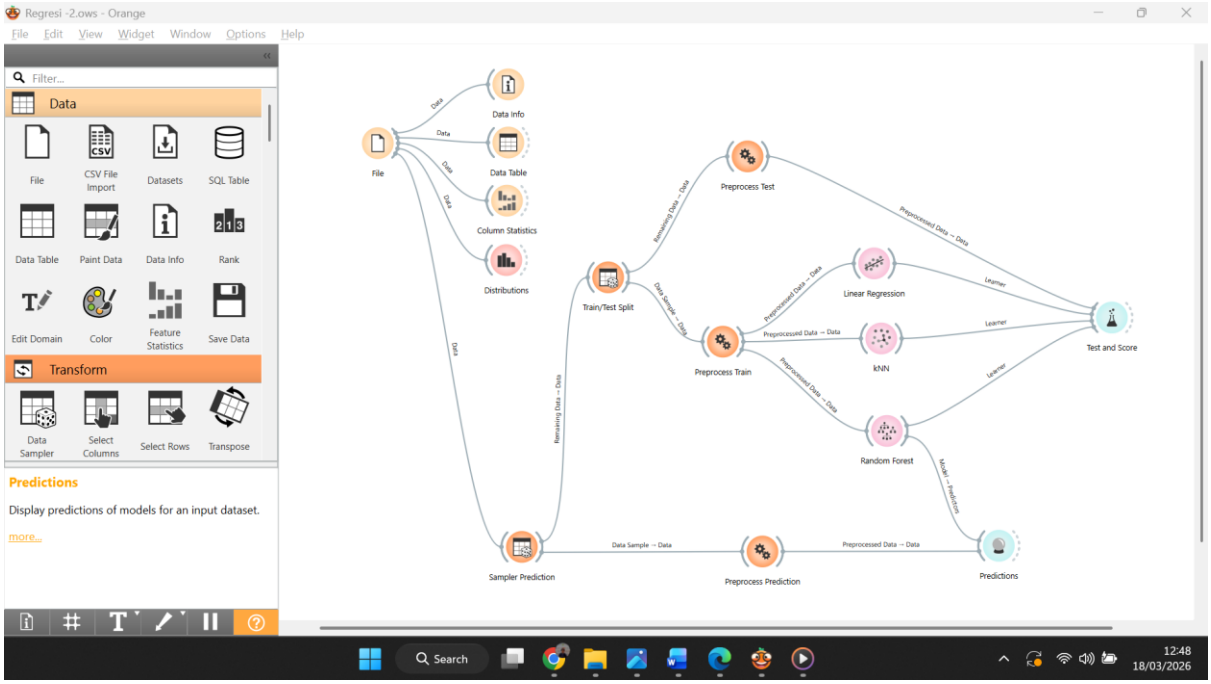

Gambar 3. Regression Workflow

Penjelasan Workflow

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

Tahap pertama adalah melakukan load data boston housing menggunakan widget File, kemudian dilakukan eksplorasi data menggunakan Data Info, Data Table, Column Statistics, dan Distributions untuk memahami karakteristik dataset.

Selanjutnya, dilakukan pembagian data menggunakan Train Test Split menjadi data training dan data testing. Data training digunakan untuk melatih model, sedangkan data testing digunakan untuk evaluasi.

Pada tahap berikutnya, dilakukan preprocessing data menggunakan widget Preprocess baik pada data training maupun data testing agar model dapat bekerja lebih optimal.

Kemudian digunakan beberapa algoritma regresi yaitu:

- Linear Regression
- k-Nearest Neighbors (kNN)
- Random Forest

Setiap model dilatih menggunakan data training, kemudian hasilnya dibandingkan menggunakan widget Test and Score untuk melihat performa masing-masing model.

Selanjutnya, dilakukan prediksi menggunakan model terbaik dengan widget Predictions untuk melihat perbandingan antara nilai aktual dan hasil prediksi.

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

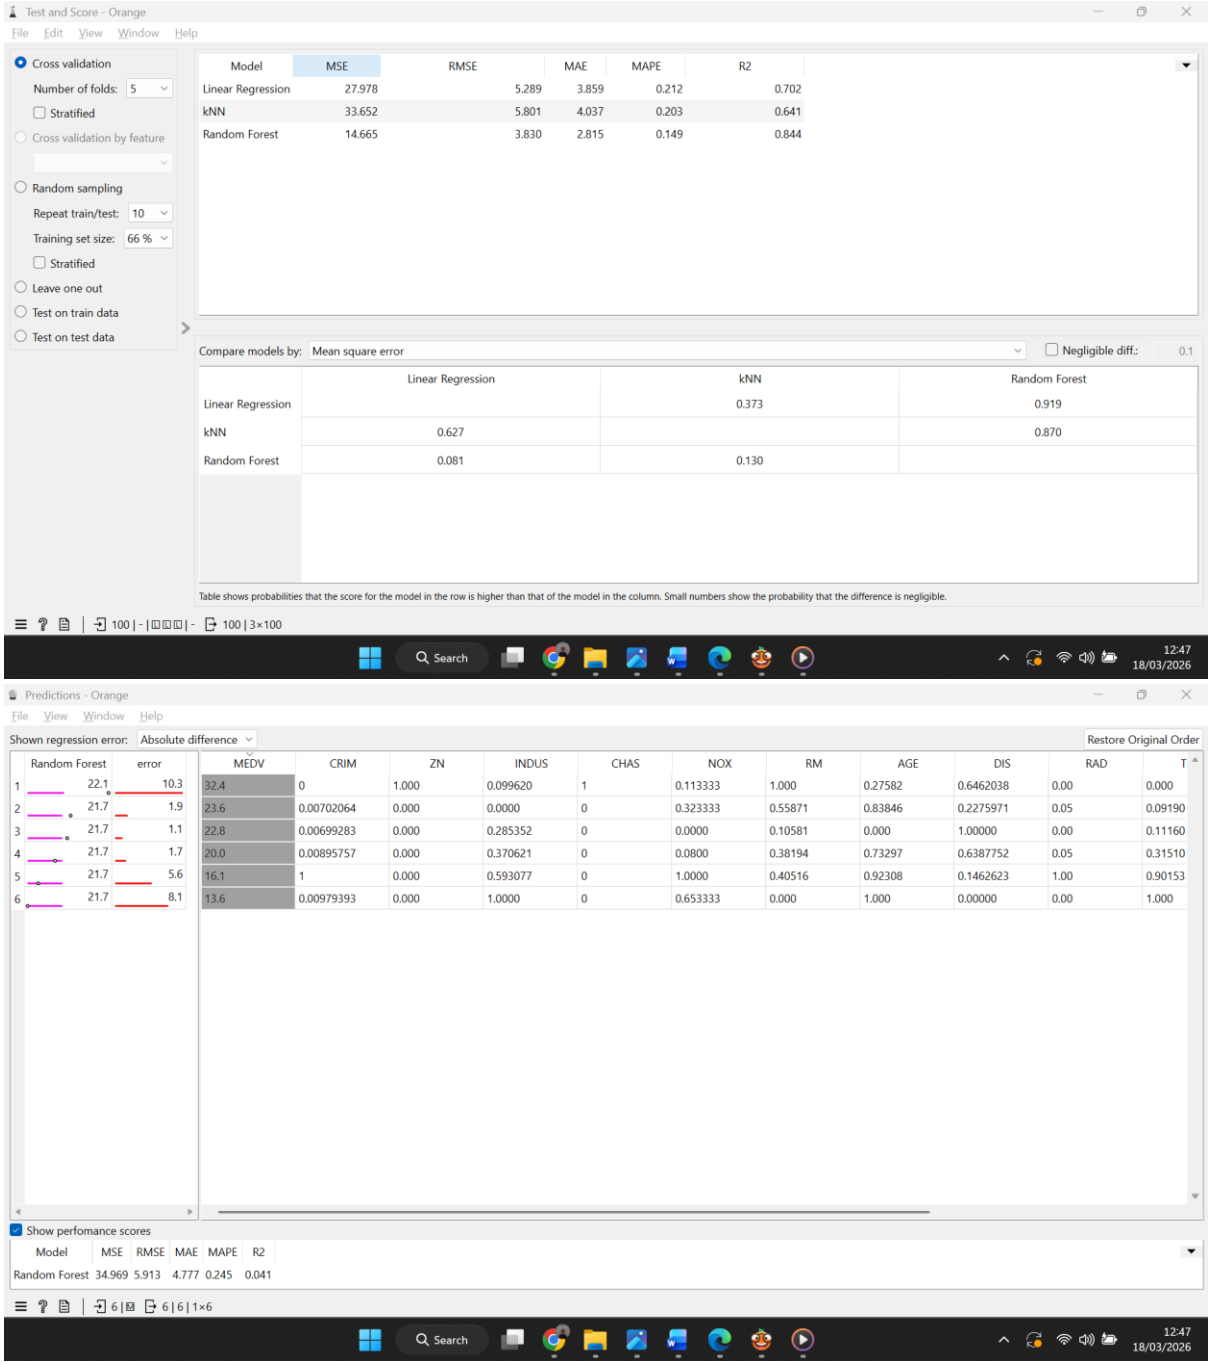

Gambar 5. Model Evaluation (Random Forrest)

Berdasarkan hasil evaluasi menggunakan Test and Score, dilakukan perbandingan performa beberapa model regresi yaitu Linear Regression, kNN, dan Random Forest.

Hasil menunjukkan bahwa:

- Model dengan nilai MAE terendah adalah Random Forest sebesar 2.815
- Model dengan nilai R^2 tertinggi adalah Random Forest sebesar 0.844

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

Hal ini menunjukkan bahwa Random Forest memiliki performa terbaik dibandingkan model lainnya karena memiliki tingkat error paling kecil serta mampu menjelaskan variasi data dengan lebih baik.

Analisis Error (Predictions)

Berdasarkan hasil pada widget Predictions, ditemukan bahwa error terbesar terjadi pada salah satu data dengan nilai:

- Predicted = 22.1
- Actual = 32.4
- Error = 10.3

Hal ini menunjukkan bahwa model mengalami kesulitan dalam memprediksi nilai rumah dengan harga yang tinggi.

Kemungkinan penyebabnya adalah:

- adanya data ekstrem (outlier)
- distribusi data yang tidak merata
- hubungan data yang tidak sepenuhnya linear

Model cenderung melakukan underestimate, yaitu memprediksi nilai yang lebih rendah dari nilai sebenarnya.

Metode: Clustering
Data: Zoo Dataset

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

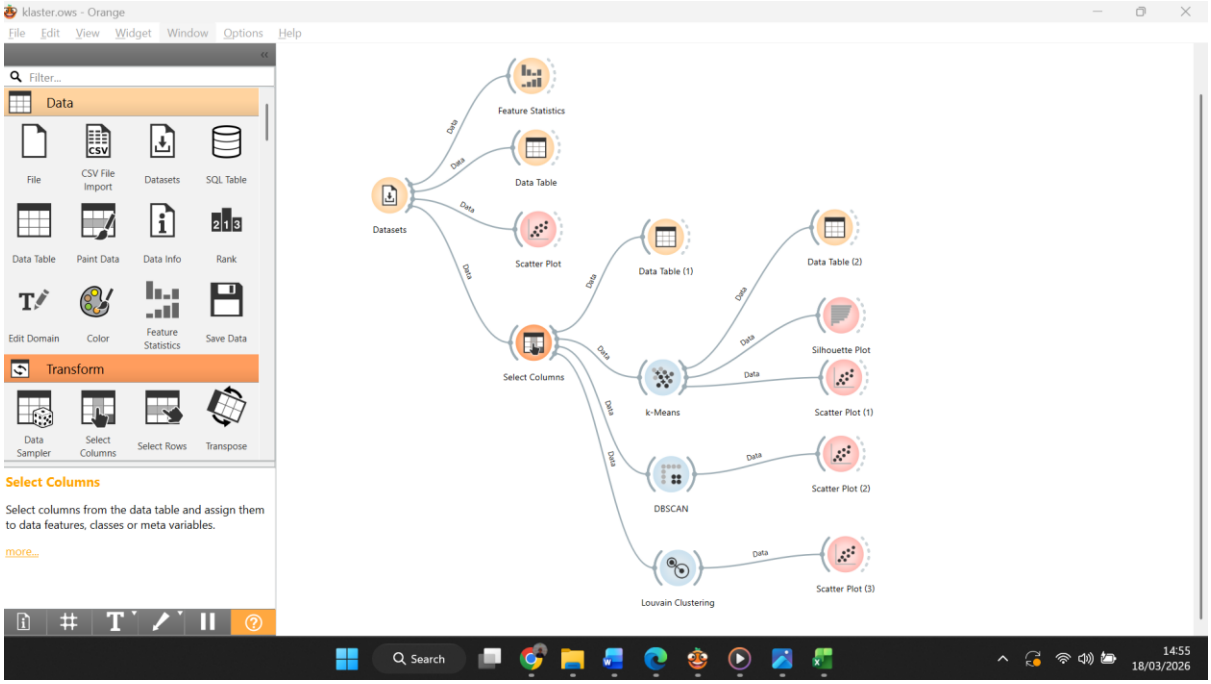

Gambar 6. Clustering Workflow

Tahap pertama adalah melakukan load data menggunakan widget Datasets, kemudian dilakukan eksplorasi data menggunakan Feature Statistics, Data Table, dan Scatter Plot untuk memahami karakteristik dataset Zoo.

Selanjutnya, dilakukan seleksi atribut menggunakan widget Select Columns, dimana atribut name dan type dihapus agar tidak digunakan dalam proses clustering, karena metode K-Means tidak menggunakan label.

Pada tahap berikutnya, dilakukan proses clustering menggunakan beberapa algoritma, yaitu:

- K-Means
- DBSCAN
- Louvain Clustering

Namun, fokus utama dalam percobaan ini adalah pada algoritma K-Means.

Algoritma K-Means digunakan untuk mengelompokkan data berdasarkan kemiripan fitur. Untuk menentukan jumlah cluster terbaik, dilakukan percobaan dengan beberapa nilai k.

Hasil clustering kemudian divisualisasikan menggunakan:

- Data Table : untuk melihat hasil pengelompokan data

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

- Silhouette Plot : untuk mengevaluasi kualitas cluster
- Scatter Plot : untuk visualisasi distribusi cluster

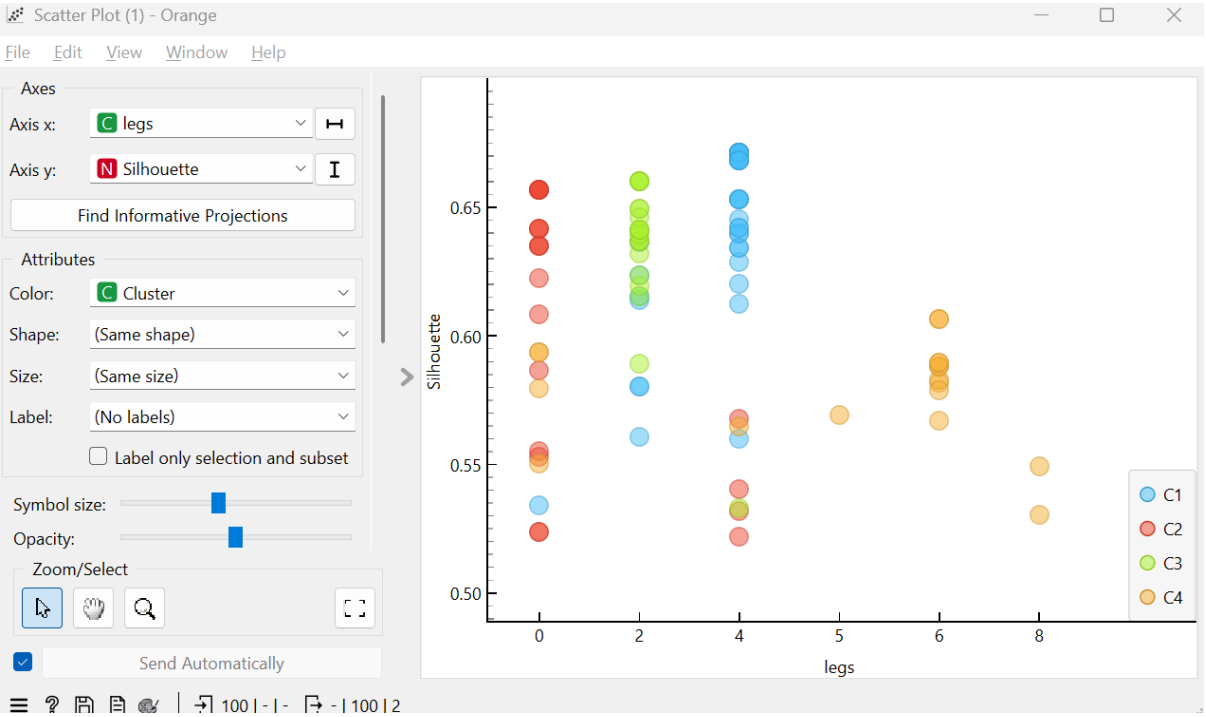

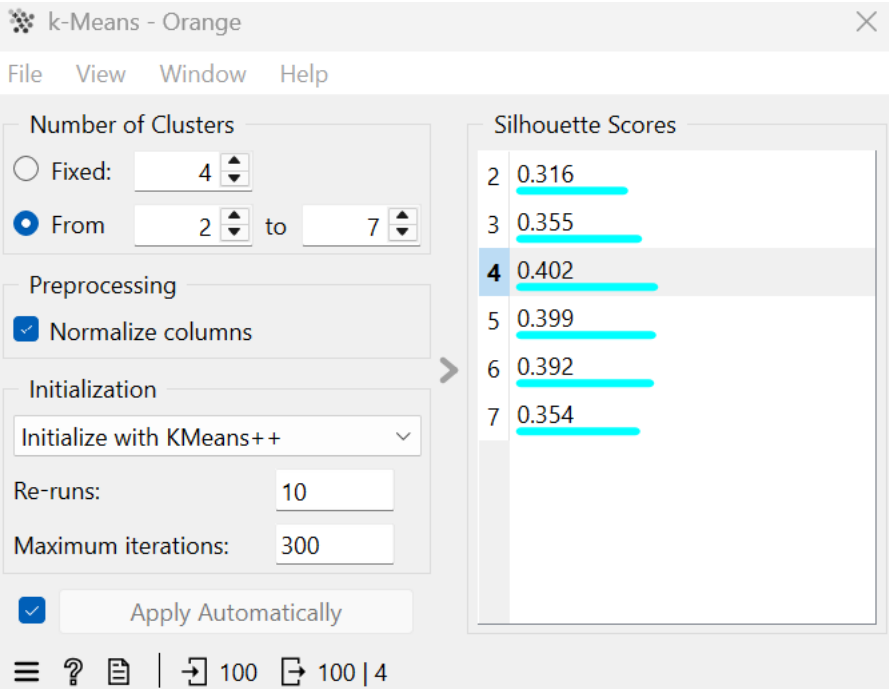

Gambar 7. Model Evaluation (K-Means)

Dilakukan percobaan dengan beberapa jumlah cluster (k), yaitu:

- k = 2 → 0.316
- k = 3 → 0.355

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

- k = 4 → 0.402 (tertinggi)
- k = 5 → 0.399
- k = 6 → 0.392
- k = 7 → 0.354

Berdasarkan hasil tersebut, diperoleh bahwa nilai silhouette score tertinggi terdapat pada k = 4.

Hal ini menunjukkan bahwa jumlah cluster terbaik adalah 4 cluster, karena memiliki tingkat pemisahan dan kepadatan cluster yang paling optimal.

Berdasarkan hasil pengelompokan pada k = 4, diperoleh karakteristik sebagai berikut:

Cluster 1 (C1)

Ciri-ciri:

- hair = yes
- milk = yes
- backbone = yes
- breathes = yes
- legs = 4

Kesamaan:

Hewan dalam cluster ini termasuk mamalia

Cluster 2 (C2)

Ciri-ciri:

- egg = yes
- aquatic = yes
- fins = yes
- legs = 0
- tidak memiliki rambut

Kesamaan:

Hewan dalam cluster ini termasuk ikan / hewan air

Cluster 3 (C3)

Ciri-ciri:

- feather = yes
- egg = yes

Nama: Alfan Maulana
NIM: 20124088
Kelas: C3

- airborne = yes
- legs = 2

Kesamaan:

Hewan dalam cluster ini termasuk burung

Cluster 4 (C4)

- Ciri-ciri:
- hair = no
- feather = no
- milk = no
- egg = yes
- backbone = sebagian besar tidak
- legs = bervariasi (0, 6, 8)
- beberapa venomous

Kesamaan:

Hewan dalam cluster ini termasuk invertebrata dan serangga

Penamaan Cluster

Cluster	Nama
C1	Mamalia
C2	Ikan / Hewan Air
C3	Burung
C4	Invertebrata & Serangga