TUGAS PYTHON: MACHINE LEARNING

Nama : Najwa Annisa Putri
NIM : 20124093
Kelas : C3 - 24

1. **Metode : Classification**
   Data : Titanic Dataset

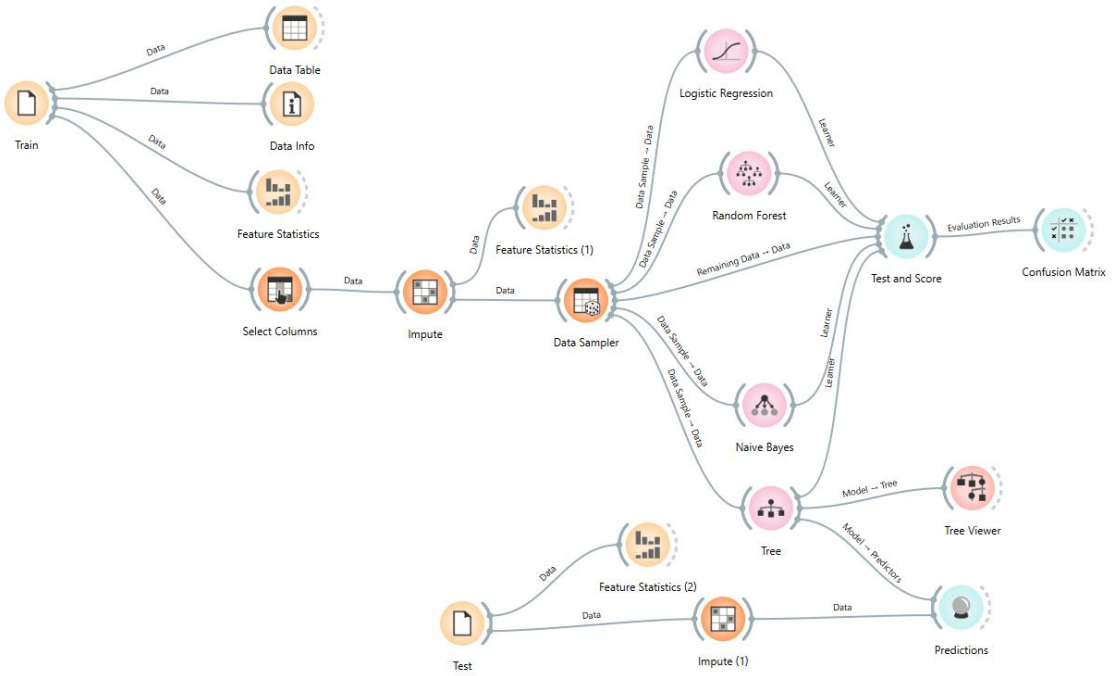

Gambar 1. Classification Workflow

Penjelasan Workflow

Proses classification dimulai dengan memasukkan dataset, kemudian dilakukan eksplorasi data untuk mengetahui struktur dan karakteristik tiap atribut. Tahap ini dilakukan menggunakan Data Table, Data Info, dan Feature Statistics agar dapat memahami kondisi data sebelum dilakukan pemodelan.

Selanjutnya dilakukan tahap preprocessing untuk menyiapkan data agar lebih optimal. Pada tahap ini, *Select Columns* digunakan untuk memilih atribut yang relevan, sedangkan *Impute* digunakan untuk menangani data yang kosong atau missing value.

Tahapan utama dalam proses:

- **Pembagian data**
  Data dibagi menggunakan Data Sampler menjadi data latih dan data uji agar proses pelatihan dan pengujian dapat dilakukan secara terpisah dan lebih objektif.
- **Pembuatan model**
  Model yang digunakan meliputi Logistic Regression, Random Forest, Naive Bayes, dan Decision Tree, yang masing-masing memiliki pendekatan berbeda dalam melakukan klasifikasi.

Model-model tersebut kemudian dievaluasi menggunakan Test and Score untuk mengetahui performanya. Selain itu, digunakan Confusion Matrix untuk melihat hasil klasifikasi secara lebih rinci, serta Tree Viewer untuk menampilkan struktur dari model Decision Tree. Pada tahap akhir, model Decision Tree digunakan untuk menghasilkan output prediksi.

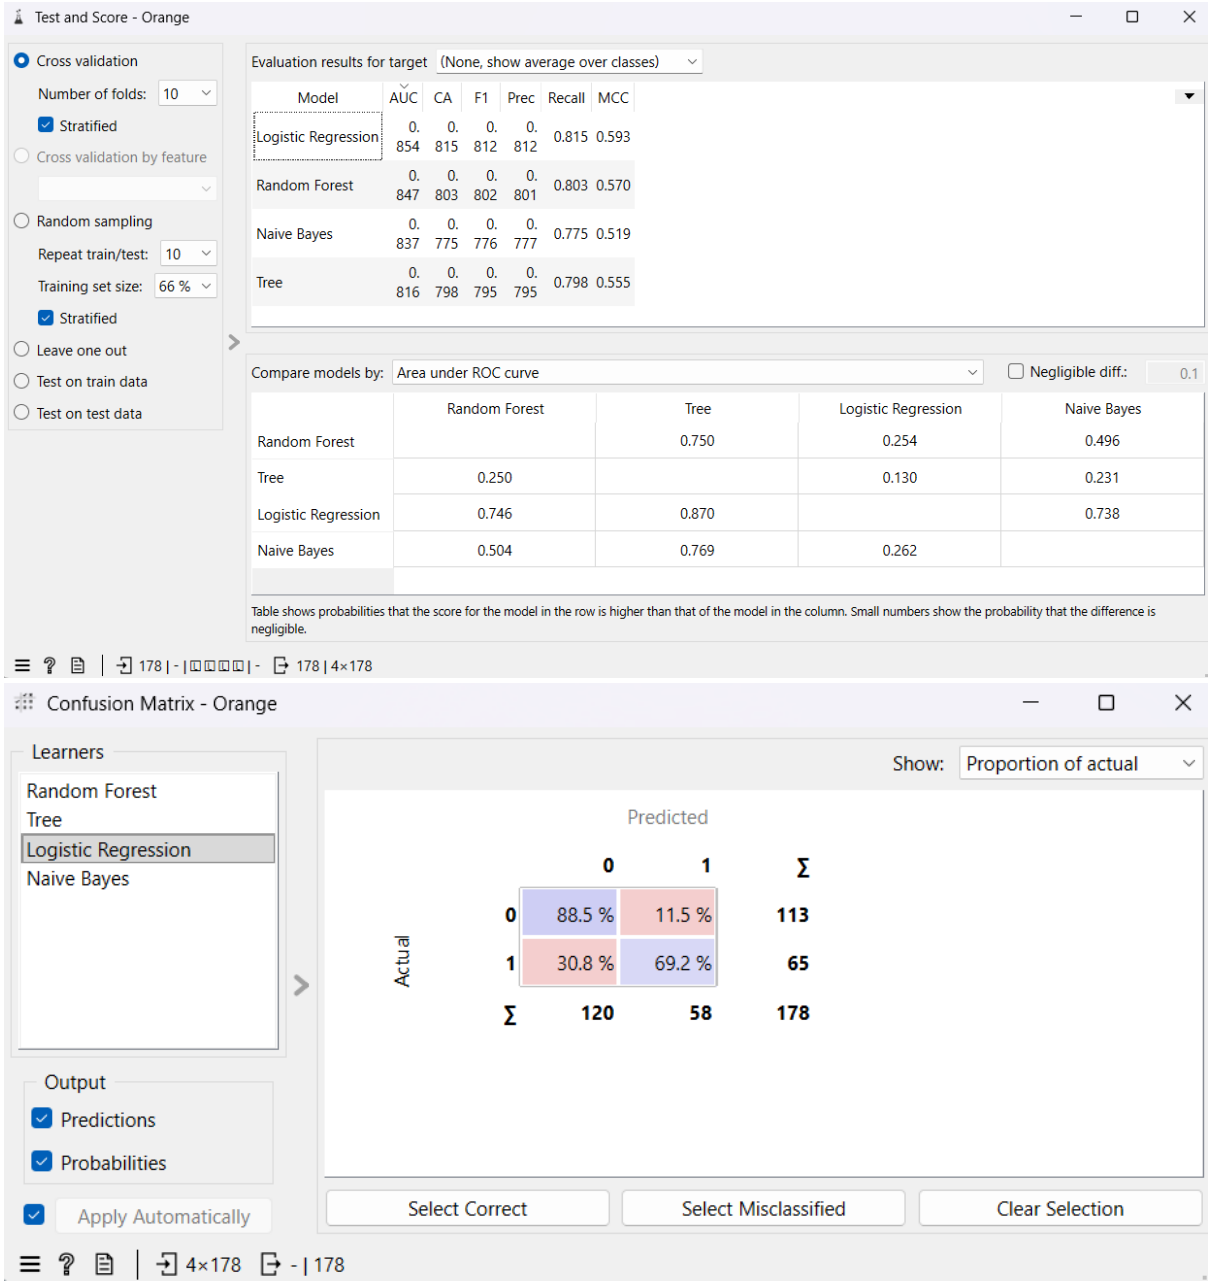

Gambar 2. Model Evaluation (Logistic Reression)

Berdasarkan hasil evaluasi yang dilakukan, terlihat bahwa setiap model memiliki performa yang berbeda. Penilaian dilakukan menggunakan metrik seperti AUC, akurasi (CA), dan F1-score.

Dari hasil tersebut, model **Logistic Regression** menunjukkan performa yang paling baik dibandingkan model lainnya. Hal ini terlihat dari nilai AUC yang paling tinggi serta didukung oleh nilai akurasi dan F1-score yang juga cukup baik dan stabil.

Jika dibandingkan:

- Logistic Regression memiliki performa terbaik
- Random Forest menunjukkan hasil yang cukup baik dan mendekati Logistic Regression
- Decision Tree memiliki performa yang stabil, namun masih di bawah kedua model tersebut
- Naive Bayes memiliki performa paling rendah

Berdasarkan Confusion Matrix, model mampu mengklasifikasikan data kelas 0 dengan cukup baik, namun masih terdapat kesalahan dalam mengklasifikasikan kelas 1. Hal ini menunjukkan bahwa model masih memiliki keterbatasan dalam mengenali seluruh kelas secara seimbang.
Secara keseluruhan, Logistic Regression dipilih sebagai model terbaik karena mampu memberikan hasil klasifikasi yang lebih akurat dan konsisten dibandingkan model lainnya.

2. **Metode : Regression**
   Data : Housing Dataset

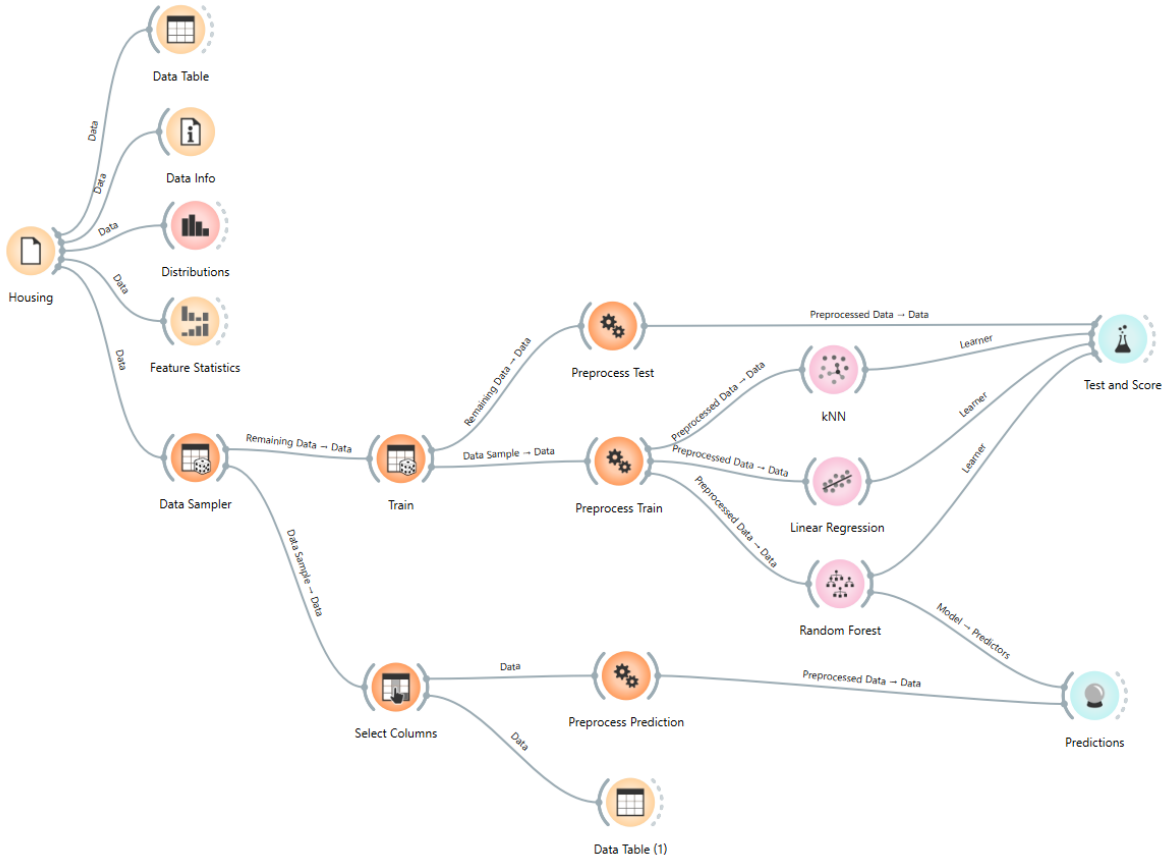

Gambar 3. Regression Workflow

Penjelasan Workflow

Proses regression diawali dengan memasukkan dataset *Housing*, kemudian dilakukan eksplorasi data untuk memahami distribusi dan karakteristik setiap atribut. Tahap ini dilakukan menggunakan Data Table, Data Info, Distributions, dan Feature Statistics agar memperoleh gambaran awal mengenai data.
Setelah itu, data dibagi menggunakan Data Sampler menjadi data latih dan data uji. Pembagian ini bertujuan agar proses pelatihan model dan pengujian dapat dilakukan secara terpisah sehingga hasil evaluasi lebih objektif.

Sebelum digunakan dalam pemodelan, data terlebih dahulu diproses melalui tahap preprocessing.

Tahapan utama:

- **Preprocessing data**
  Data latih dan data uji diproses menggunakan *Preprocess Train* dan *Preprocess Test* agar memiliki format yang konsisten. Selain itu, *Select Columns* digunakan untuk memilih fitur yang relevan.
- **Pembuatan model**
  Model yang digunakan meliputi:
  - Linear Regression
  - k-Nearest Neighbors (kNN)
  - Random Forest

Setiap model memiliki pendekatan berbeda dalam memprediksi nilai numerik.

Model yang telah dibuat kemudian dievaluasi menggunakan Test and Score. Pada tahap akhir, model Random Forest digunakan pada bagian Predictions untuk menghasilkan nilai prediksi.

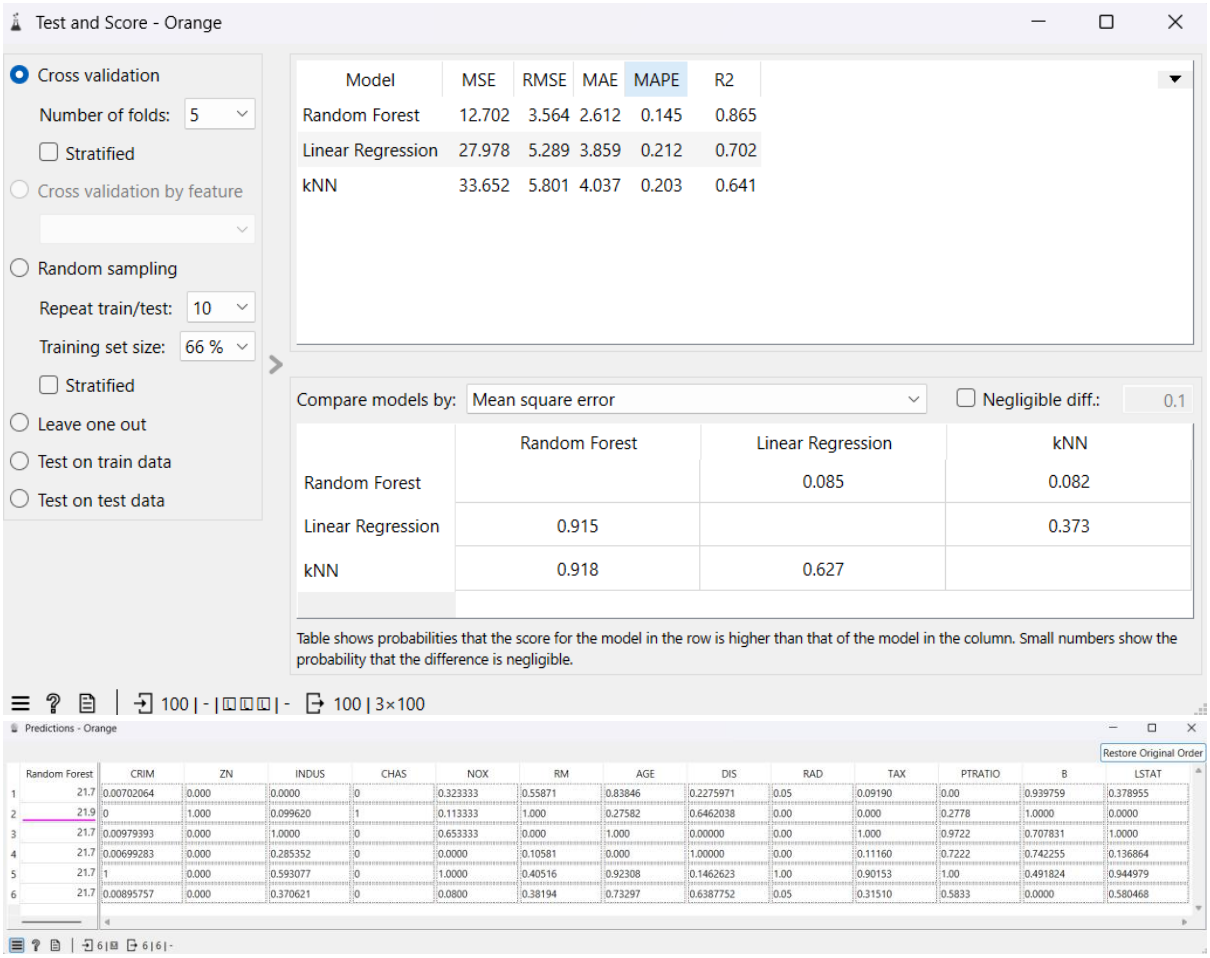

Gambar 4. Model Evaluation (Random Forest)

Penjelasan Model Evaluation

Evaluasi model dilakukan menggunakan beberapa metrik regresi seperti MSE, RMSE, MAE, MAPE, dan R^2. Dalam regresi, model yang lebih baik ditunjukkan oleh nilai error yang lebih kecil serta nilai R^2 yang lebih tinggi.

Berdasarkan hasil evaluasi, model **Random Forest** menunjukkan performa terbaik dibandingkan model lainnya. Hal ini terlihat dari nilai MSE (12.702) yang paling kecil serta nilai R^2 (0.865) yang paling tinggi.

Perbandingan performa model:

- **Random Forest**: performa terbaik (error paling kecil, R^2 tertinggi)
- **Linear Regression**: performa cukup baik namun error masih cukup besar
- **kNN**: performa paling rendah dengan error terbesar

Dengan demikian, dapat disimpulkan bahwa Random Forest merupakan model yang paling optimal dalam melakukan prediksi pada dataset ini karena mampu menghasilkan nilai yang lebih mendekati data sebenarnya.

3. **Metode : Clustering**
   Data : Iris Dataset

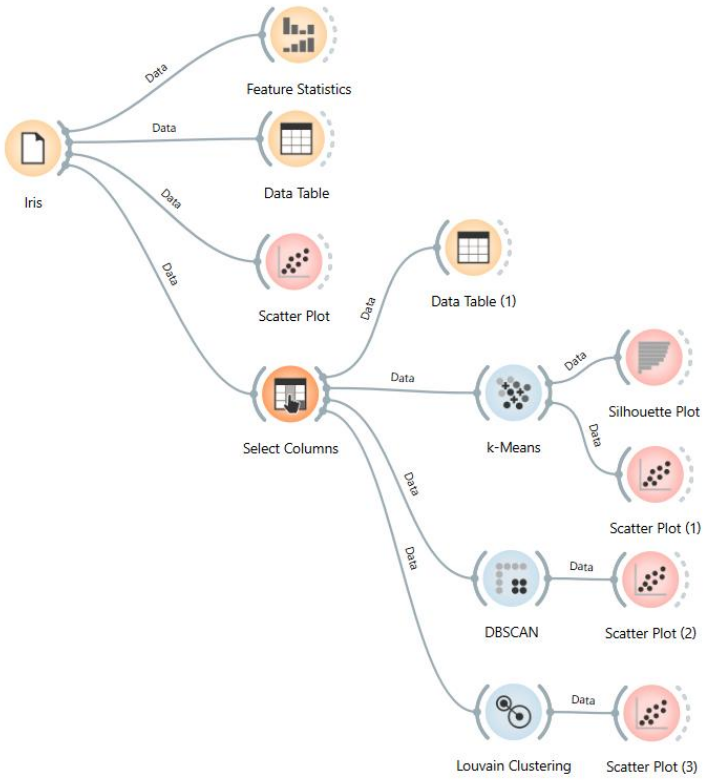

Gambar 5. Clustering Workflow

Penjelasan Workflow

Proses clustering dimulai dengan memasukkan dataset *Iris*, kemudian dilakukan eksplorasi data untuk memahami distribusi dan hubungan antar atribut. Tahap ini dilakukan menggunakan Data Table, Feature Statistics, dan Scatter Plot untuk melihat pola awal pada data.

Selanjutnya, dilakukan pemilihan fitur menggunakan *Select Columns* agar atribut yang digunakan lebih relevan untuk proses clustering.

Tahapan utama:

- **Penerapan metode clustering**
  Data kemudian diproses menggunakan beberapa algoritma, yaitu:
  - **k-Means**: mengelompokkan data berdasarkan jarak antar titik

- **DBSCAN**: mengelompokkan data berdasarkan kepadatan
- **Louvain Clustering**: membentuk cluster berdasarkan hubungan antar data

Hasil dari masing-masing metode kemudian divisualisasikan menggunakan Scatter Plot untuk melihat pola pengelompokan data secara langsung.

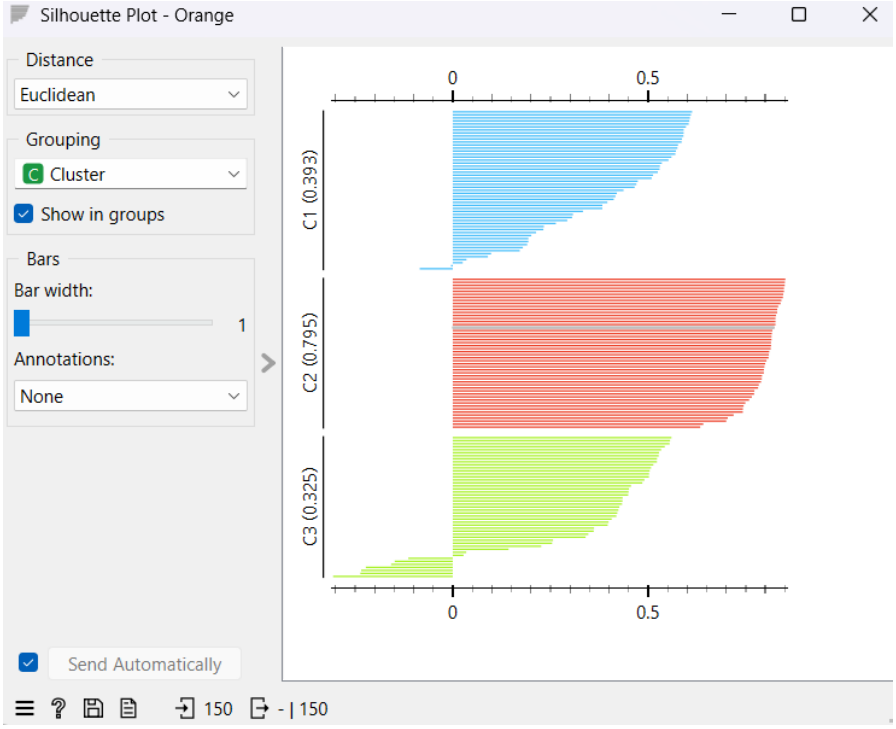

Gambar 6. Silhouette Plot

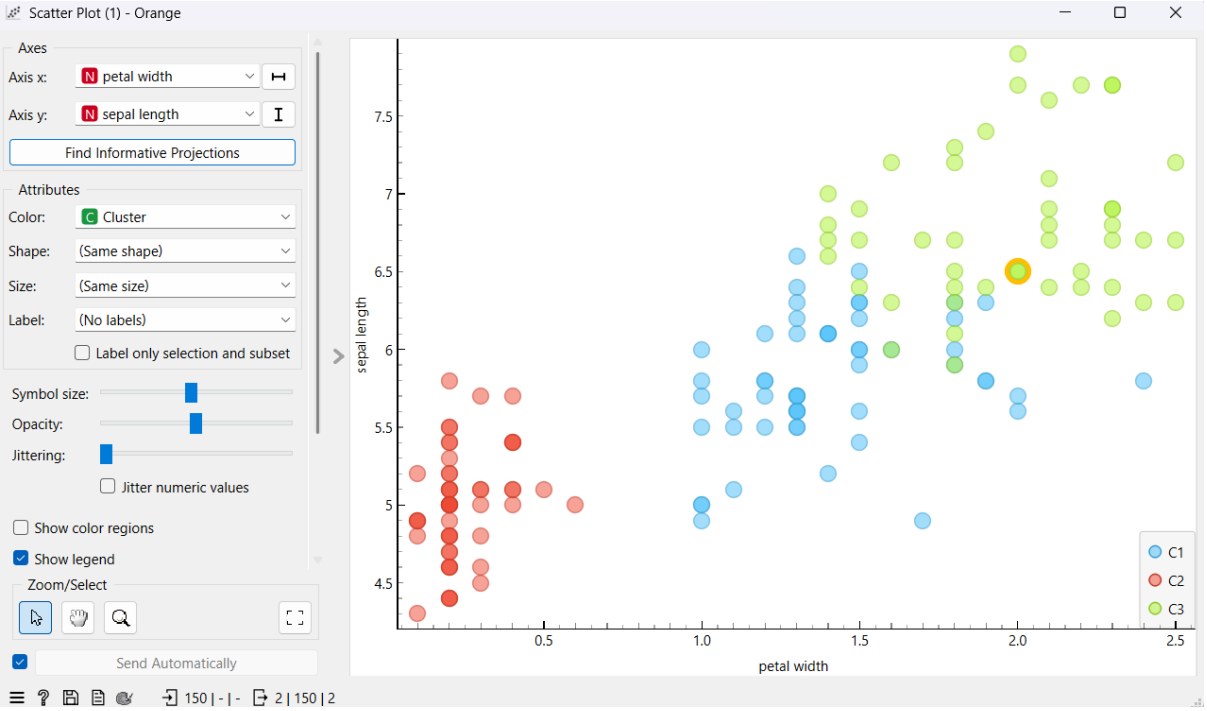

Gambar 7. Model Evaluation (k-Means)

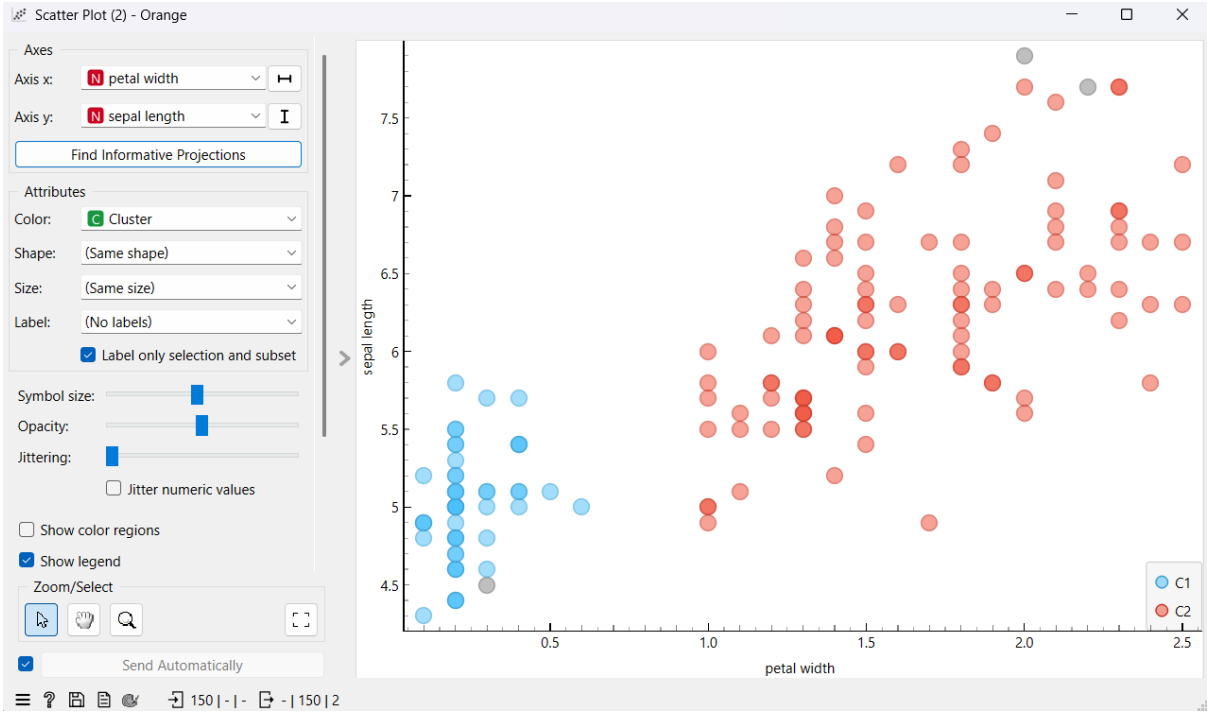

Gambar 8. Model Evaluation (DBSCAN)

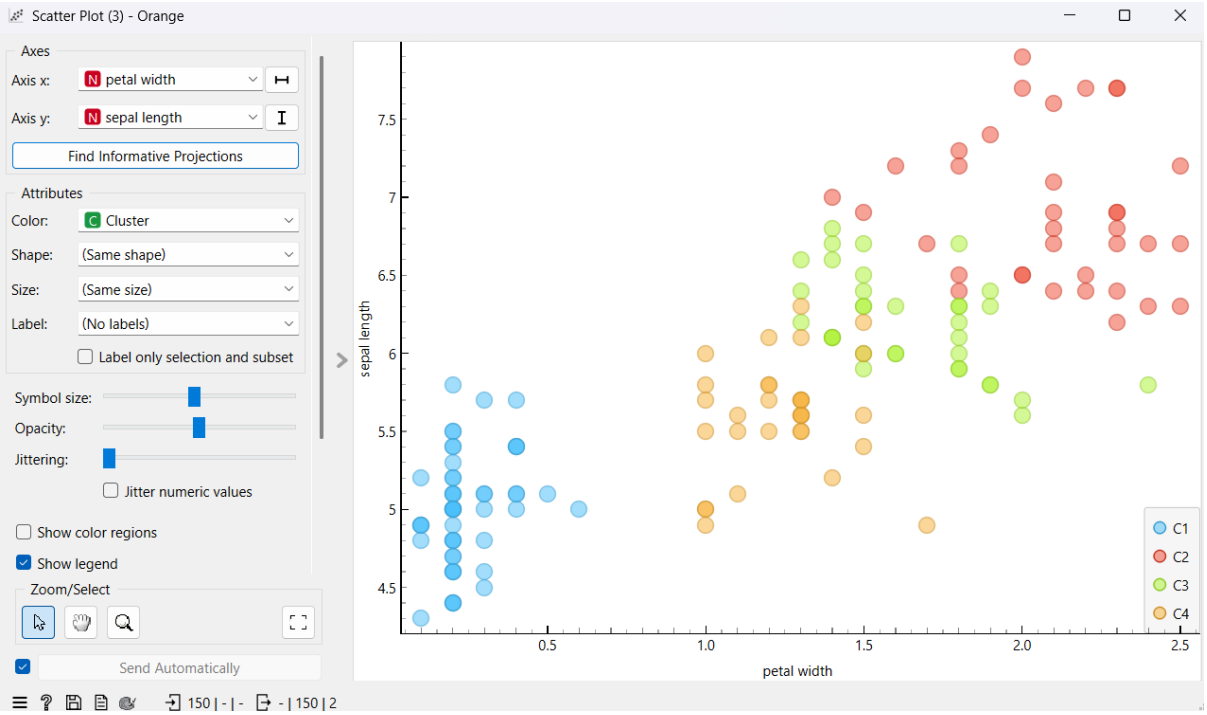

Gambar 9. Model Evaluation (Louvain Clustering)

Penjelasan Model Evaluation

Evaluasi pada clustering dilakukan dengan melihat kualitas hasil pengelompokan, bukan berdasarkan label seperti pada klasifikasi. Oleh karena itu, digunakan **Silhouette Plot** dan **Scatter Plot** sebagai alat evaluasi.

Hasil evaluasi:

- **k-Means**
  Menunjukkan hasil terbaik dengan nilai silhouette yang dominan positif. Cluster terlihat cukup jelas dan terpisah dengan baik pada scatter plot.
- **DBSCAN**
  Mampu mendeteksi kelompok berbasis kepadatan, namun hasil cluster kurang merata dan terdapat beberapa data yang tidak terkelompok dengan baik.
- **Louvain Clustering**
  Menghasilkan jumlah cluster yang lebih banyak, namun pemisahan antar cluster kurang jelas dibandingkan k-Means.

Berdasarkan hasil tersebut, metode **k-Means** dapat dianggap sebagai metode yang paling optimal karena menghasilkan cluster yang lebih terstruktur dan mudah diinterpretasikan.