TUGAS PYTHON MACHINE LEARNING

Nama : Dini Sriastuti
NIM : 20124097
Kelas : C3 - 24

1. Metode : Klasifikasi
   Data : Titanic Dataset

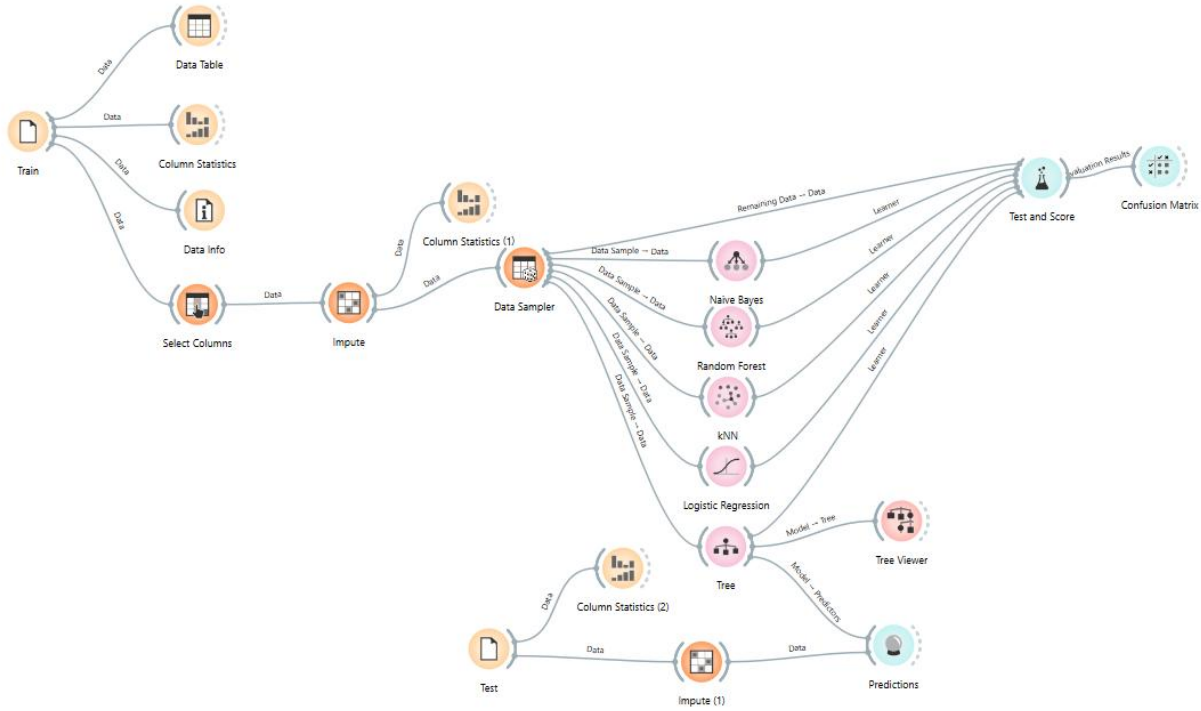

Gambar 1. Classification Workflow

Penjelasan Workflow:

Workflow klasifikasi dimulai dengan memasukkan dataset Titanic, kemudian dilakukan eksplorasi data untuk memahami karakteristik dan distribusi setiap atribut. Tahap ini penting sebagai dasar sebelum dilakukan pemodelan.

Tahapan utama dalam workflow:

- **Eksplorasi Data**
  Menggunakan Data Table, Column Statistics, dan Data Info untuk melihat struktur serta distribusi data.
- **Preprocessing Data**
  Dilakukan menggunakan:
  - *Select Columns* untuk memilih fitur yang relevan
  - *Impute* untuk menangani missing value

Setelah itu, data dibagi menggunakan Data Sampler menjadi data latih dan data uji agar proses pelatihan dan pengujian lebih objektif.

- **Pembuatan Model**
  Model yang digunakan meliputi Logistic Regression, Random Forest, Decision Tree, Naive Bayes, dan kNN.

- **Evaluasi Model**
  Dilakukan menggunakan Test and Score dengan metode cross-validation untuk membandingkan performa masing-masing model.

Pada tahap akhir, dilakukan prediksi menggunakan Decision Tree, serta analisis lebih lanjut menggunakan Confusion Matrix untuk melihat tingkat akurasi dan kesalahan klasifikasi.

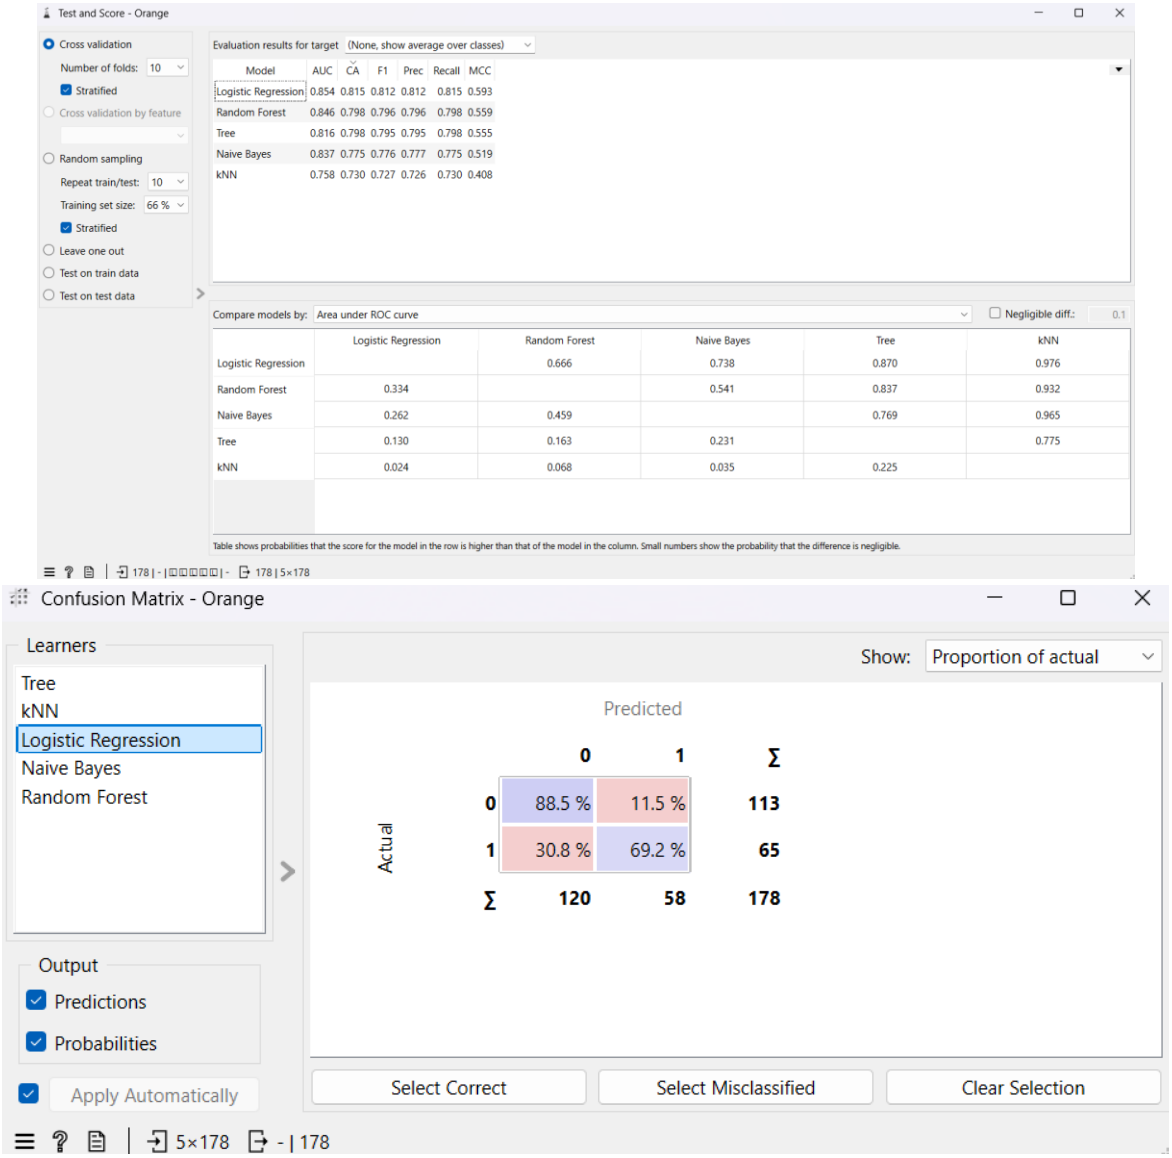

Gambar 2. Model Evaluation (Logistic Reression)

Berdasarkan hasil evaluasi yang dilakukan menggunakan Test and Score, diperoleh perbandingan kinerja dari beberapa model klasifikasi yang digunakan. Evaluasi ini menggunakan metrik AUC, akurasi (CA), dan F1-score untuk mengukur kemampuan masing-masing model dalam melakukan klasifikasi.

Dari hasil tersebut, model **Logistic Regression** menunjukkan kinerja terbaik dibandingkan model lainnya. Hal ini dapat dilihat dari nilai AUC yang paling tinggi, serta didukung oleh nilai akurasi dan F1-score yang juga cukup baik dan stabil.

Ringkasan hasil evaluasi:

- **Logistic Regression**: model dengan performa terbaik
- **Random Forest & Decision Tree**: memiliki performa yang cukup baik
- **Naive Bayes**: berada pada tingkat performa menengah
- **kNN**: memiliki performa paling rendah

Berdasarkan hasil tersebut, dapat disimpulkan bahwa Logistic Regression merupakan model yang paling optimal untuk digunakan dalam proses klasifikasi pada dataset Titanic. Model ini mampu memberikan hasil yang cukup akurat serta memiliki kemampuan yang baik dalam membedakan setiap kelas.

2. Metode : Regression
   Data : Housing Dataset

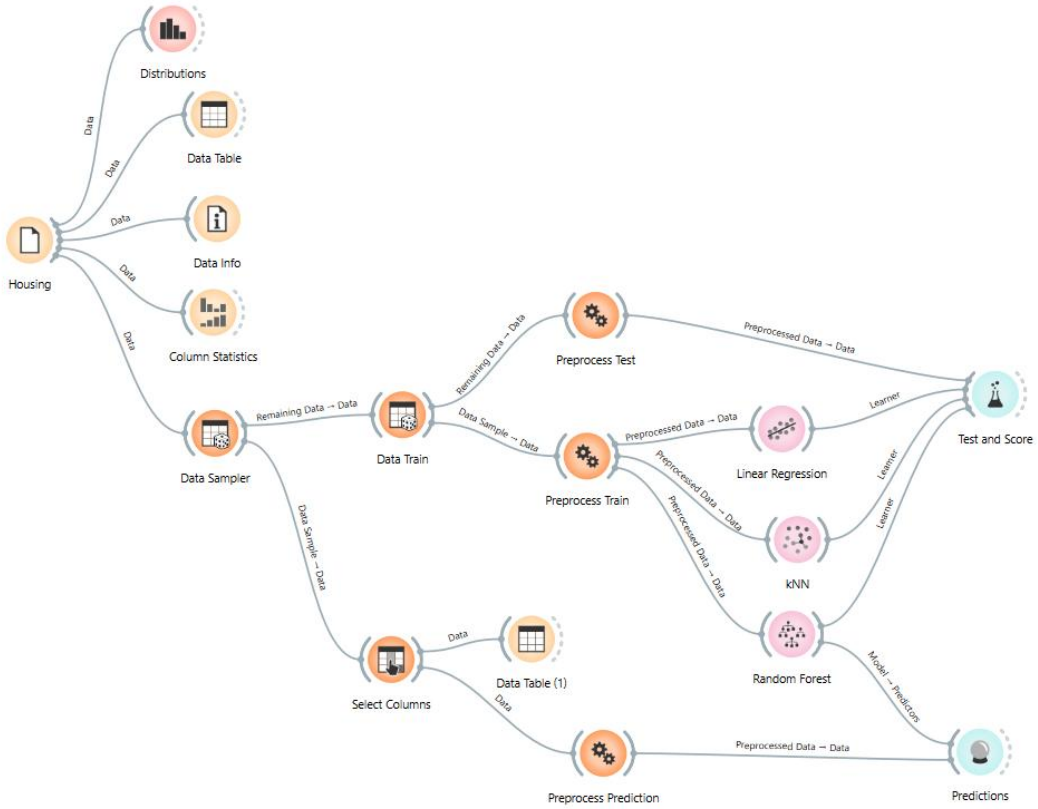

Gambar 3. Regression Workflow

Penjelasan Workflow:

Workflow dimulai dengan memasukkan dataset **Housing**, kemudian dilakukan eksplorasi data untuk memahami karakteristik setiap atribut. Tahap ini bertujuan untuk mengetahui kondisi awal data sebelum dilakukan proses pemodelan.

Tahapan utama dalam workflow:

- **Eksplorasi Data**
  Menggunakan Data Table, Distributions, Data Info, dan Column Statistics untuk melihat struktur serta distribusi data.
- **Pembagian Data**
  Data dibagi menggunakan Data Sampler menjadi data latih dan data uji.

Setelah itu, data diproses lebih lanjut sebelum digunakan dalam pemodelan.

- **Preprocessing Data**
  - *Preprocess Train* digunakan untuk menyiapkan data latih
  - *Preprocess Test* digunakan untuk memastikan data uji diproses dengan cara yang sama
  - *Select Columns* digunakan untuk memilih fitur yang relevan

Data latih kemudian digunakan untuk membangun beberapa model regresi, yaitu Linear Regression, k-Nearest Neighbors (kNN), dan Random Forest. Setiap model memiliki pendekatan yang berbeda dalam memprediksi nilai numerik.

- **Evaluasi Model**

  Semua model diuji menggunakan Test and Score untuk membandingkan performa berdasarkan metrik regresi.

Pada tahap akhir, model terbaik digunakan pada bagian Predictions untuk menghasilkan nilai prediksi dari data yang diuji.

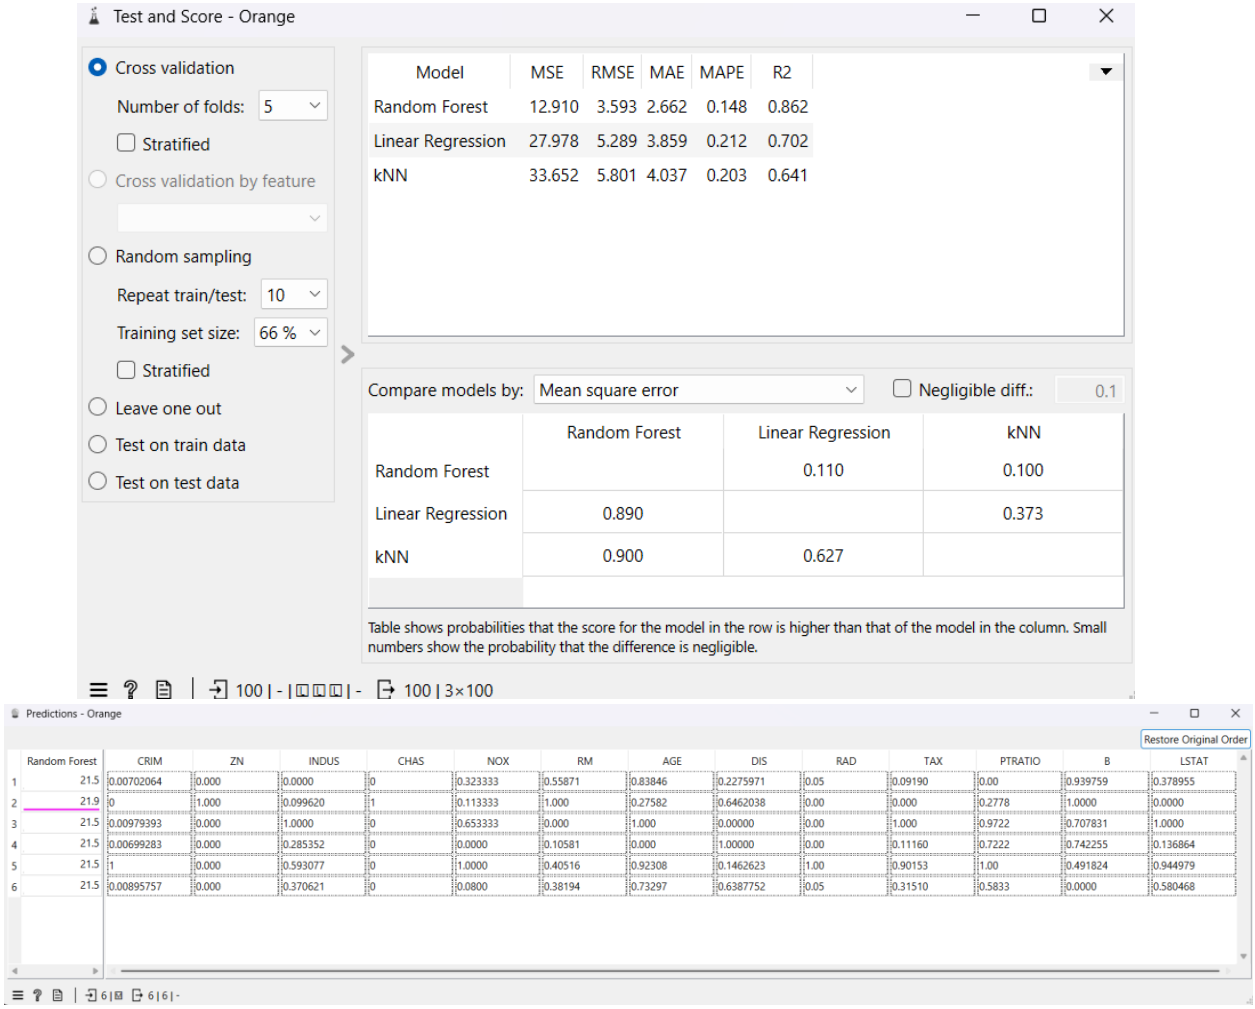

Gambar 4. Model Evaluation (Random Forest)

Berdasarkan hasil evaluasi menggunakan Test and Score, dilakukan perbandingan performa model regresi menggunakan beberapa metrik seperti MSE, RMSE, MAE, MAPE, dan R^2. Pada regresi, model yang lebih baik ditunjukkan oleh nilai error yang lebih kecil serta nilai R^2 yang lebih tinggi.

Ringkasan hasil evaluasi:

- **Random Forest**: model terbaik
  - MSE: 12.910 (terkecil)
  - RMSE: 3.593
  - MAE: 2.662
  - R^2: 0.862 (tertinggi)
- **Linear Regression**: performa cukup baik, namun error lebih besar
- **kNN**: performa terendah dengan error paling tinggi

Hasil tersebut menunjukkan bahwa Random Forest memiliki kemampuan prediksi yang paling baik dibandingkan model lainnya. Model ini mampu menghasilkan nilai prediksi yang lebih mendekati nilai sebenarnya serta memiliki tingkat kesalahan yang lebih rendah.

Dengan demikian, Random Forest dipilih sebagai model terbaik dan digunakan pada tahap Predictions untuk menghasilkan output prediksi.

3. Metode : Clustering
   Data : Iris Dataset

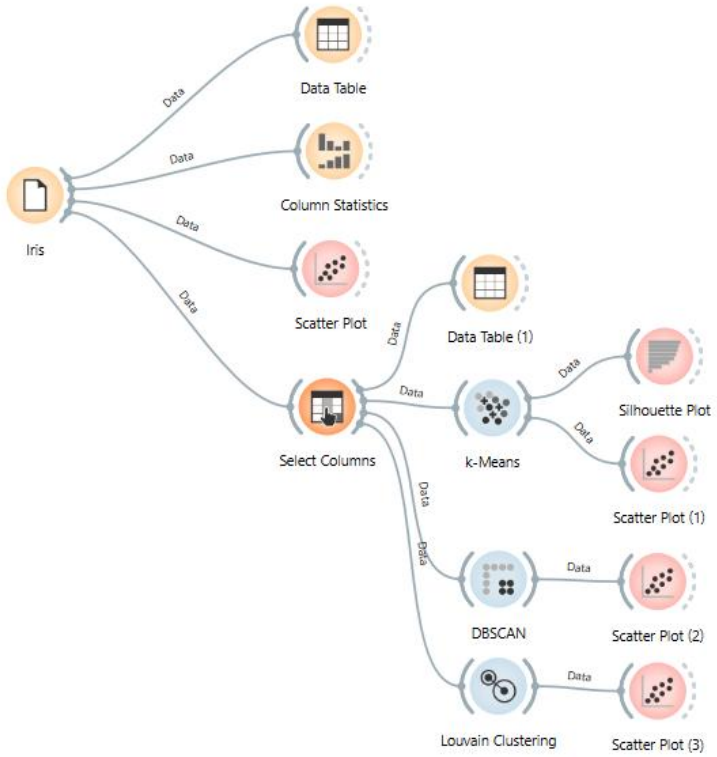

Gambar 5. Clustering Workflow

Penjelasan Workflow:

Workflow clustering dimulai dengan memasukkan dataset Iris, kemudian dilakukan eksplorasi data untuk memahami distribusi dan hubungan antar atribut. Tahap ini penting untuk melihat pola awal sebelum proses clustering dilakukan.

Tahapan utama dalam workflow:

- **Eksplorasi Data**
  Menggunakan Data Table, Column Statistics, dan Scatter Plot untuk melihat distribusi serta hubungan antar fitur.
- **Preprocessing Data**
  Menggunakan *Select Columns* untuk memilih atribut yang relevan agar proses clustering lebih optimal.

Selanjutnya dilakukan proses clustering menggunakan beberapa metode, yaitu k-Means, DBSCAN, dan Louvain Clustering yang masing-masing memiliki pendekatan berbeda dalam mengelompokkan data.

Hasil clustering kemudian divisualisasikan menggunakan Scatter Plot untuk melihat pola pengelompokan data secara visual.

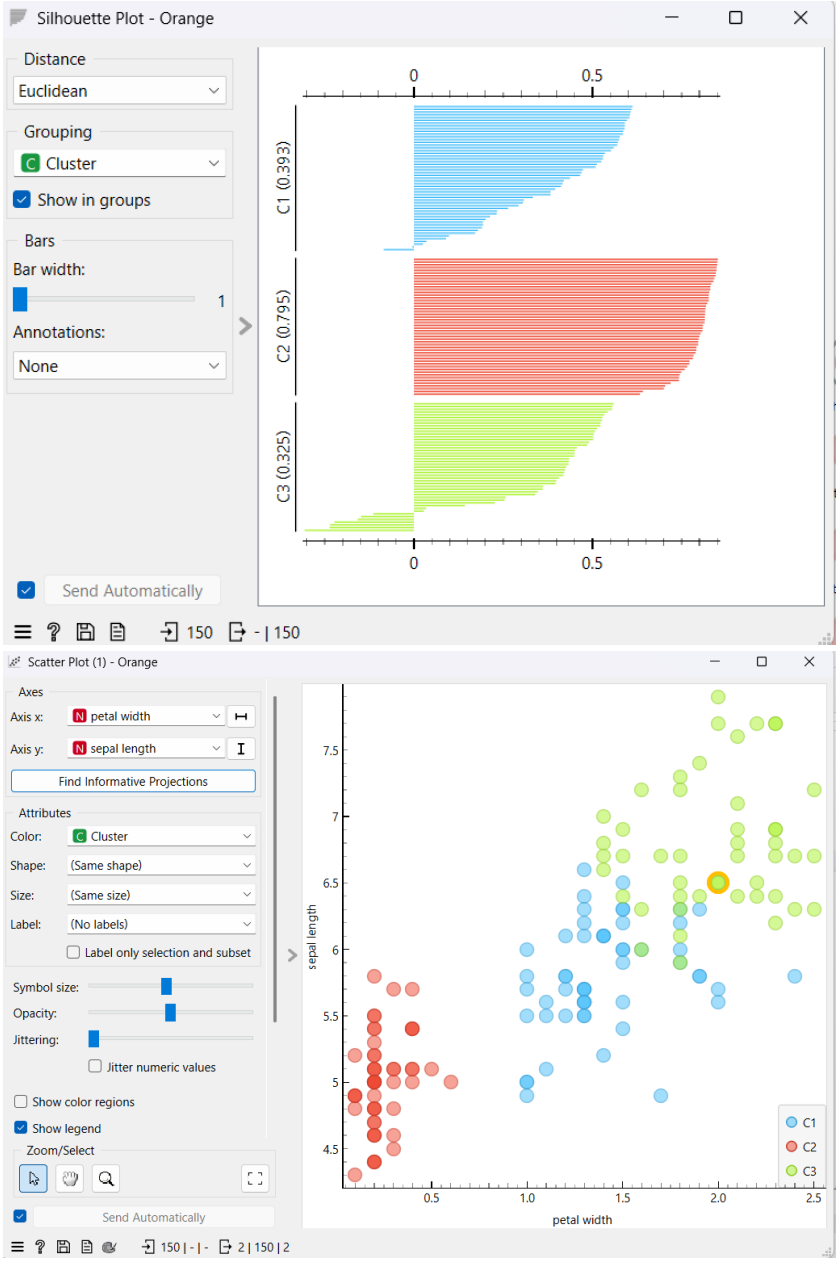

Gambar 6. Model Evaluation (k-Means)

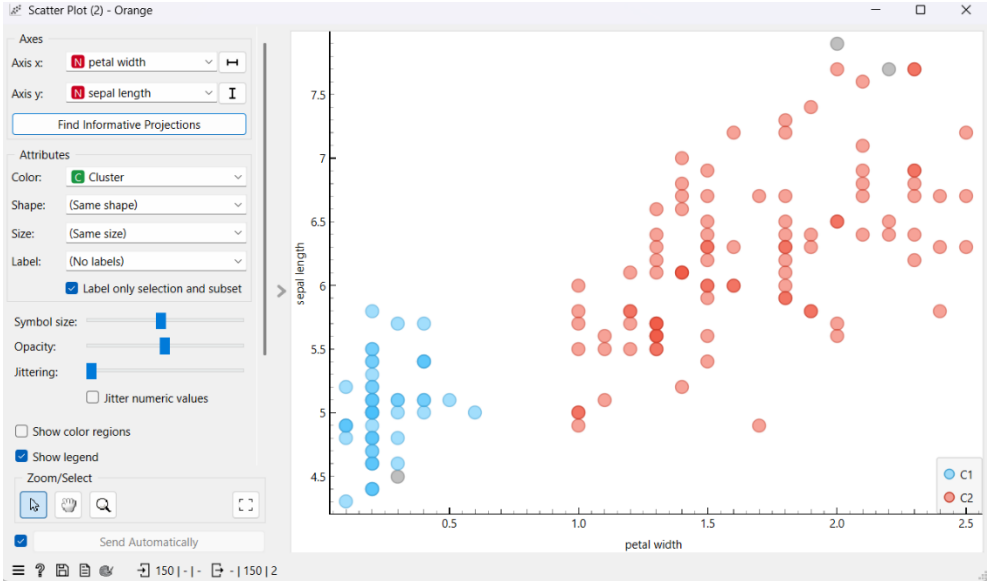

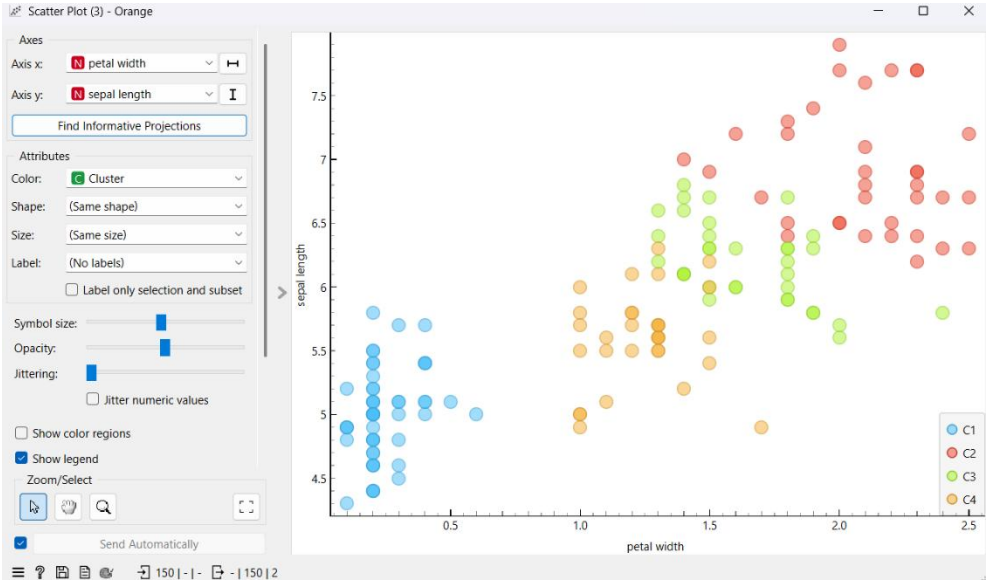

Gambar 7. Model Evaluation (DBSCAN dan Louvain Clustering)

Evaluasi pada metode clustering dilakukan menggunakan **Silhouette Plot** dan **visualisasi Scatter Plot** untuk melihat kualitas pengelompokan data. Berbeda dengan klasifikasi, evaluasi clustering tidak menggunakan label, melainkan berdasarkan seberapa baik data dikelompokkan dalam cluster.

Secara umum, metode **k-Means** menunjukkan hasil clustering yang paling baik dibandingkan metode lainnya. Hal ini terlihat dari nilai silhouette yang cenderung positif serta visualisasi cluster pada scatter plot yang menunjukkan pemisahan kelompok yang cukup jelas.

Perbandingan antar metode:

- **k-Means**
  Menghasilkan cluster yang paling rapi dan terpisah dengan baik. Nilai silhouette menunjukkan kualitas clustering yang baik.
- **DBSCAN**
  Mampu mendeteksi pola berbasis kepadatan, namun hasil cluster kurang merata dan terdapat beberapa data yang dianggap sebagai noise.

- **Louvain Clustering**
  Menghasilkan jumlah cluster yang lebih banyak, namun pemisahan antar cluster kurang jelas dibandingkan k-Means.

Berdasarkan hasil tersebut, dapat disimpulkan bahwa metode **k-Means** merupakan metode terbaik dalam melakukan clustering pada dataset Iris karena mampu menghasilkan pengelompokan data yang lebih optimal dan mudah diinterpretasikan.