TUGAS PEMROGRAMAN PHYTON (MACHINE LEARNING)

Nama : Damia Hasna Difa

NIM : 20124116

Kelas : C3.24

Metode : Classification

Data : Titanic Dataset

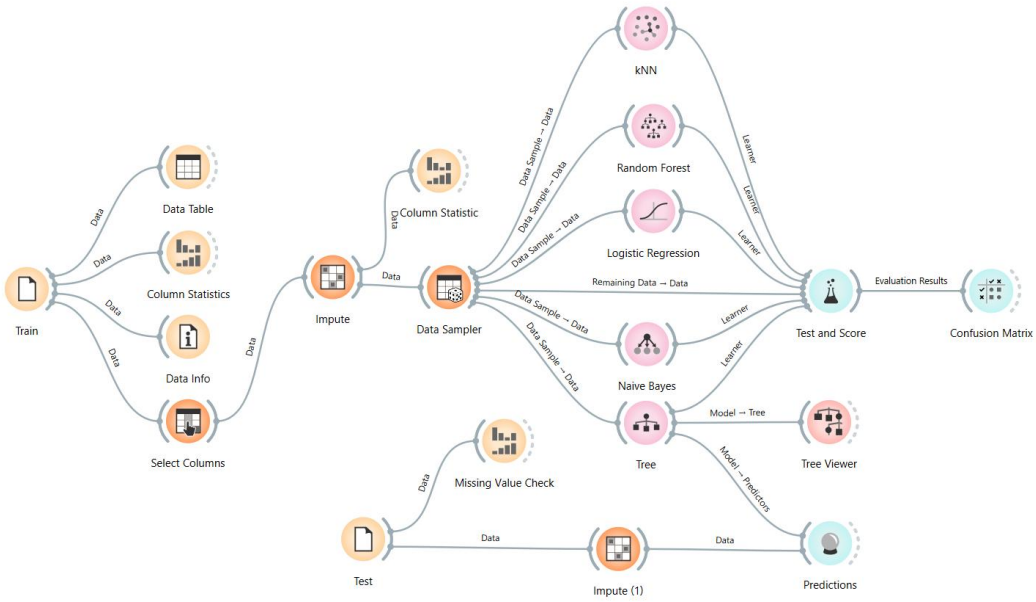

Gambar 1. Titanic Workflow

Pada tahap ini dilakukan proses klasifikasi menggunakan dataset Titanic dengan tujuan untuk memprediksi apakah seorang penumpang selamat (survived) atau tidak. Alur kerja dimulai dari input data menggunakan widget File, kemudian dilakukan eksplorasi awal menggunakan Data Table, Column Statistics, dan Distributions untuk memahami karakteristik data.

Selanjutnya dilakukan pemilihan atribut menggunakan Select Columns, di mana variabel Survived dijadikan sebagai target, sedangkan atribut lain seperti Pclass, Sex, Age, dan Fare digunakan sebagai features. Tahap

preprocessing dilakukan menggunakan widget Impute untuk menangani missing values.

Setelah itu data dibagi menggunakan Data Sampler untuk keperluan training dan testing. Model klasifikasi yang digunakan meliputi:

- Decision Tree
- Naive Bayes
- Random Forest
- k-Nearest Neighbor (kNN)
- Logistic Regression

Pemilihan beberapa model ini bertujuan untuk membandingkan performa masing-masing algoritma dalam memprediksi data Titanic.

Interpretasi:

- Workflow menunjukkan alur lengkap dari preprocessing hingga evaluasi model.
- Penggunaan beberapa model bertujuan untuk membandingkan performa.
- Tahap preprocessing penting untuk meningkatkan kualitas data sebelum modeling.

		Predicted		
		0	1	Σ
Actual	0	83.2 %	16.8 %	113
	1	33.8 %	66.2 %	65
	Σ	116	62	178

Gambar 2. Model Evaluation Titanic Confusion Matrix

Confusion Matrix digunakan untuk mengevaluasi hasil klasifikasi dengan membandingkan antara nilai aktual dan prediksi. Matriks ini menampilkan jumlah:

- True Positive
- True Negative
- False Positive
- False Negative

Dari hasil ini dapat dilihat seberapa baik model dalam mengklasifikasikan data. Semakin banyak nilai pada diagonal utama, maka performa model semakin baik karena prediksi sesuai dengan data asli.

Interpretasi:

- Nilai diagonal tinggi → model akurat.
- Kesalahan prediksi terlihat pada FP dan FN.
- Membantu memahami jenis error, bukan hanya jumlah error.

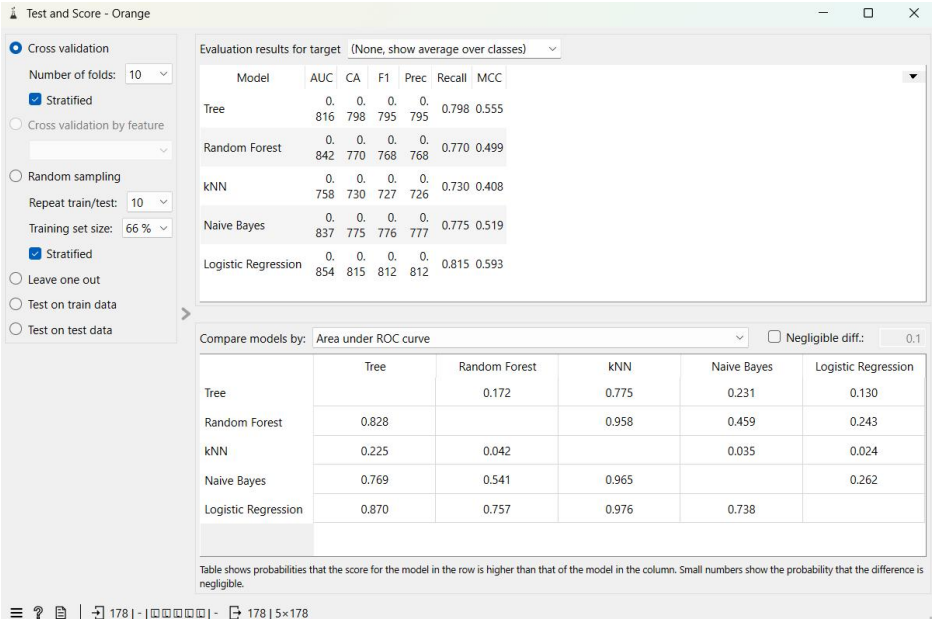

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.816	0.798	0.795	0.795	0.798	0.555
Random Forest	0.842	0.770	0.768	0.768	0.770	0.499
kNN	0.758	0.730	0.727	0.726	0.730	0.408
Naive Bayes	0.837	0.775	0.776	0.777	0.775	0.519
Logistic Regression	0.854	0.815	0.812	0.812	0.815	0.593

	Tree	Random Forest	kNN	Naive Bayes	Logistic Regression
Tree		0.172	0.775	0.231	0.130
Random Forest	0.828		0.958	0.459	0.243
kNN	0.225	0.042		0.035	0.024
Naive Bayes	0.769	0.541	0.965		0.262
Logistic Regression	0.870	0.757	0.976	0.738	

Gambar 3. Test and Score Titanic

Hasil evaluasi menunjukkan performa masing-masing model berdasarkan metrik seperti:

- Accuracy
- Precision
- Recall
- F1-Score

Berdasarkan hasil yang diperoleh, model Random Forest cenderung memiliki performa paling baik dibandingkan model lain. Hal ini karena Random Forest

mampu mengatasi overfitting dengan menggabungkan banyak decision tree sehingga menghasilkan prediksi yang lebih stabil dan akurat.

Sementara itu:

- Naive Bayes bekerja cepat namun kurang optimal karena asumsi independensi fitur
- kNN sensitif terhadap skala data
- Logistic Regression cocok untuk hubungan linear
- Decision Tree mudah dipahami namun rentan overfitting

Interpretasi:

- Random Forest → performa paling stabil dan tinggi.
- Logistic Regression → baik untuk pola linear.
- kNN → dipengaruhi jarak dan skala data.
- Naive Bayes → cepat tapi asumsi terlalu sederhana.
- Decision Tree → mudah dipahami tapi rawan overfitting.

Metode : Regression

Data : Housing Dataset

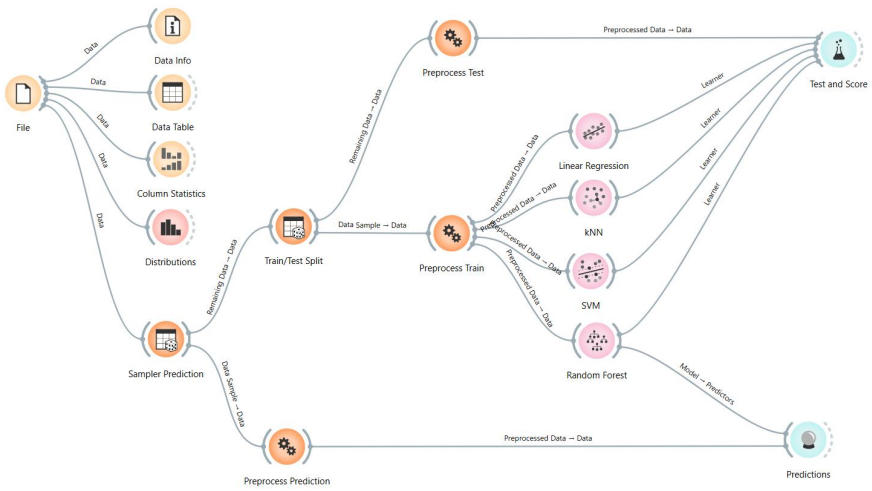

Gambar 4. Housing Workflow

Pada tahap ini dilakukan analisis regresi menggunakan Housing Dataset untuk memprediksi nilai harga rumah. Proses dimulai dari input data, kemudian dilakukan eksplorasi menggunakan Data Table dan Distributions.

Data kemudian dibagi menjadi data training dan testing menggunakan Train/Test Split. Selanjutnya dilakukan preprocessing menggunakan widget Preprocess untuk normalisasi dan penyesuaian data.

Model regresi yang digunakan adalah:

- Linear Regression
- kNN Regression
- Support Vector Machine (SVM)
- Random Forest Regression

Pemilihan model ini dilakukan untuk membandingkan pendekatan linear dan non-linear dalam memprediksi harga rumah.

Interpretasi:

- Workflow menunjukkan pemisahan jelas antara training dan testing.
- Preprocessing memastikan data siap digunakan model.
- Penggunaan berbagai model untuk membandingkan pendekatan linear dan non-linear.

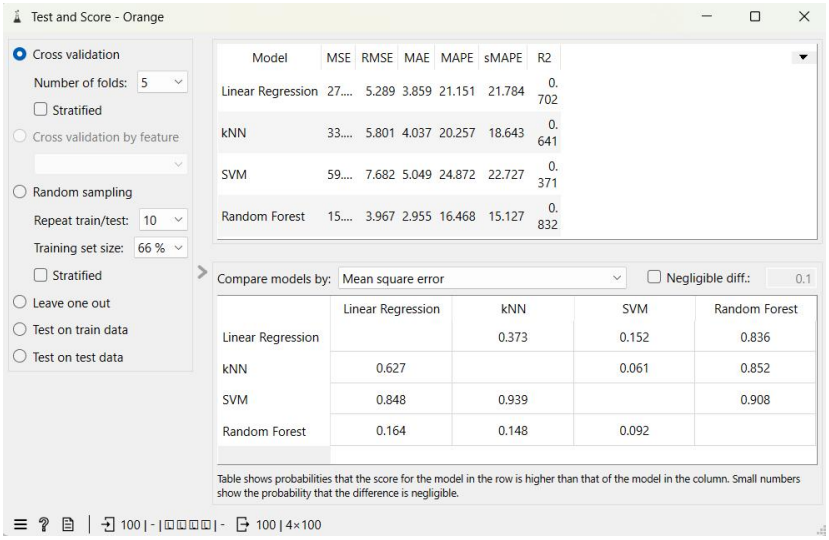

Gambar 5. Test and Score Housing Dataset

Evaluasi model regresi menggunakan metrik:

- MAE (Mean Absolute Error)
- RMSE (Root Mean Square Error)
- R^2 (Coefficient of Determination)

Model Random Forest menunjukkan performa terbaik karena mampu menangkap hubungan kompleks antar variabel. Model ini bekerja dengan menggabungkan banyak pohon keputusan sehingga hasil prediksi lebih akurat.

Sementara itu:

- Linear Regression cocok untuk hubungan linear, namun kurang optimal jika data kompleks
- kNN bergantung pada kedekatan data
- SVM efektif untuk data non-linear tetapi sensitif terhadap parameter

Interpretasi:

- Random Forest → error paling kecil (paling akurat).
- Linear Regression → cocok untuk hubungan sederhana.
- kNN → bergantung pada data terdekat.
- SVM → mampu menangani pola kompleks tapi sensitif parameter.
- Model terbaik dipilih berdasarkan:
- RMSE paling kecil
- R^2 paling tinggi

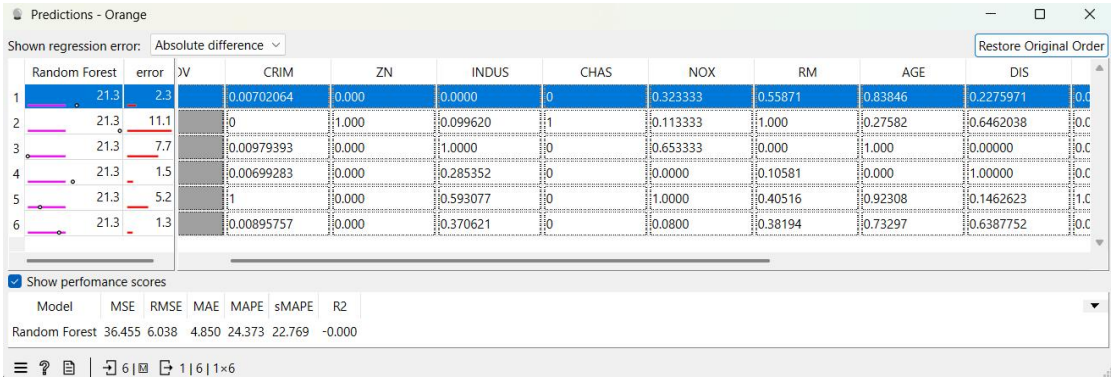

Gambar 6. Predictions Housing Dataset

Pada tahap ini digunakan model terbaik (misalnya Random Forest atau Linear Regression) untuk melakukan prediksi terhadap data baru. Model yang digunakan merupakan hasil dari proses training sebelumnya sehingga mampu memberikan output berupa nilai prediksi harga rumah.

Hasil prediksi menunjukkan nilai estimasi yang dihasilkan model berdasarkan pola yang telah dipelajari dari data training. Semakin kecil nilai error, maka hasil prediksi semakin mendekati nilai aktual.

Interpretasi:

- Model menghasilkan estimasi harga rumah berdasarkan pola data.
- Perbedaan antara nilai aktual dan prediksi menunjukkan tingkat error.
- Semakin kecil error → semakin baik model.

Metode : Clustering

Data : Iris Dataset

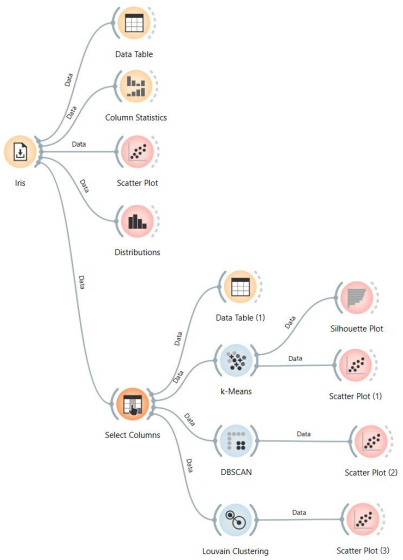

Gambar 7. Iris Workflow

Pada tahap clustering digunakan dataset Iris untuk mengelompokkan data berdasarkan kemiripan tanpa menggunakan label target. Metode clustering yang digunakan meliputi:

- K-Means
- DBSCAN
- Louvain Clustering

Tujuan dari clustering adalah untuk menemukan pola atau kelompok alami dalam data.

Interpretasi:

- Clustering bertujuan menemukan pola alami dalam data.
- Tidak menggunakan label → murni berdasarkan kemiripan data.

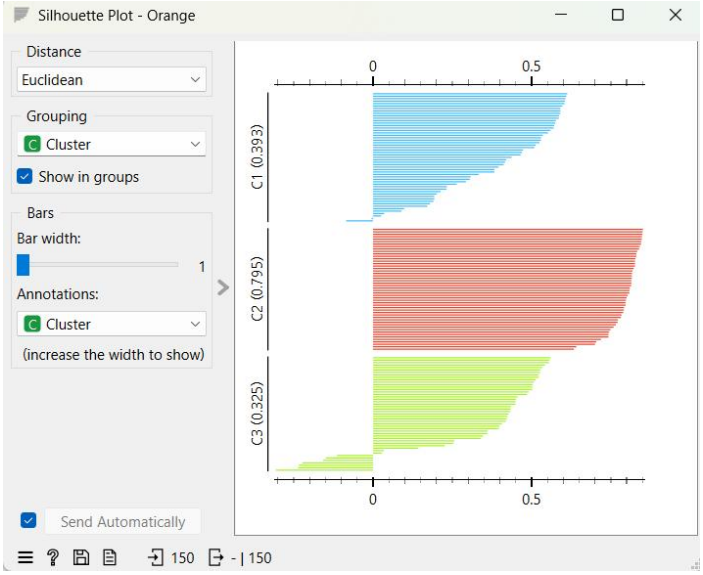

Gambar 8. Silhouette Plot (Evaluasi K-Means)

Silhouette Plot digunakan untuk mengukur kualitas clustering. Nilai silhouette berkisar antara -1 hingga 1:

- Mendekati 1: cluster baik
- Mendekati 0: overlap
- Negatif: salah cluster

Hasil menunjukkan bahwa metode K-Means menghasilkan pemisahan cluster yang cukup baik.

Interpretasi:

- Mendekati 1 → cluster jelas.
- Mendekati 0 → overlap.
- Negatif → salah cluster.
- Digunakan untuk menentukan kualitas cluster terbaik.

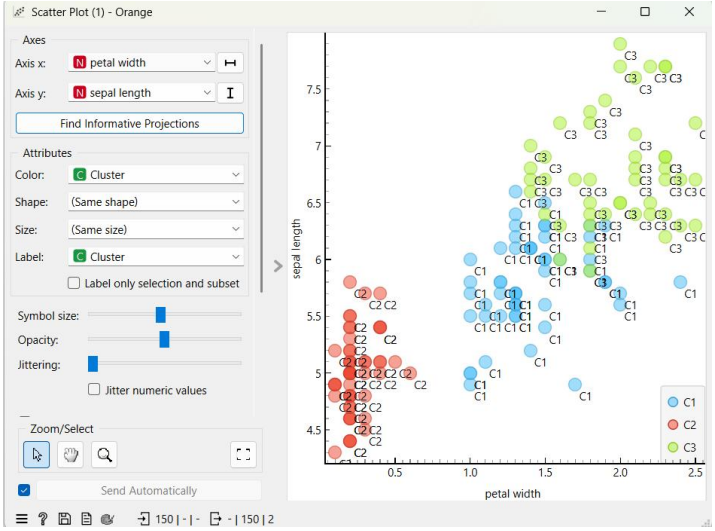

Gambar 9. Scatter Plot 1 (Evaluasi K-Means)

Visualisasi menunjukkan bahwa data berhasil dikelompokkan menjadi beberapa cluster dengan batas yang cukup jelas. Hal ini menunjukkan bahwa K-Means efektif untuk dataset Iris.

Interpretasi:

- Cluster terlihat jelas dan terpisah.
- Mendekati jumlah kelas asli (3).
- K-Means efektif untuk dataset Iris.

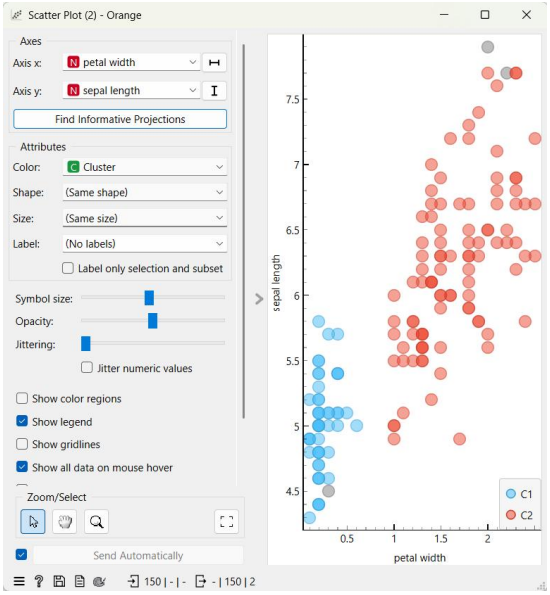

Gambar 10. Scatter Plot 2 (Evaluasi DBSCAN)

DBSCAN mampu mendeteksi noise dan cluster berdasarkan kepadatan data. Namun hasil clustering tidak sejelas K-Means karena parameter epsilon dan minimum samples sangat berpengaruh.

Interpretasi:

- Beberapa data dianggap noise.
- Cluster tidak sejelas K-Means.
- Sensitif terhadap parameter.

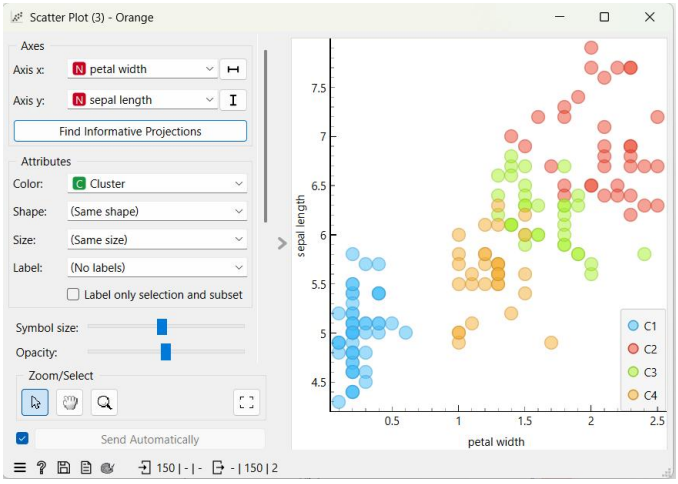

Gambar 11. Scatter Plot 3 (Evaluasi Louvain Clustering)

Louvain Clustering digunakan untuk mendeteksi komunitas dalam data. Metode ini menghasilkan cluster yang lebih kompleks dan berbasis struktur jaringan.

Interpretasi:

- Jumlah cluster lebih banyak dari kelas asli (3).
- Terjadi over-segmentation (cluster terpecah).
- Metode terlalu sensitif terhadap struktur data.
- Cocok untuk data kompleks, kurang optimal untuk Iris.