LAPORAN PRAKTIKUM

Supervised & Unsupervised

Nama : Da'ifa Maulana

NIM : 20124084

Kelas : C3-Informatika|24

1. Klasifikasi (Classification)

Dataset : Titanic (titanic_train.csv & titanic_test.csv)

Target : survived (0 = tidak selamat, 1 = selamat)

Model : Decision Tree, Random Forest, kNN, Logistic Regression, Naive Bayes

Evaluasi : Cross Validation 10-fold, Stratified

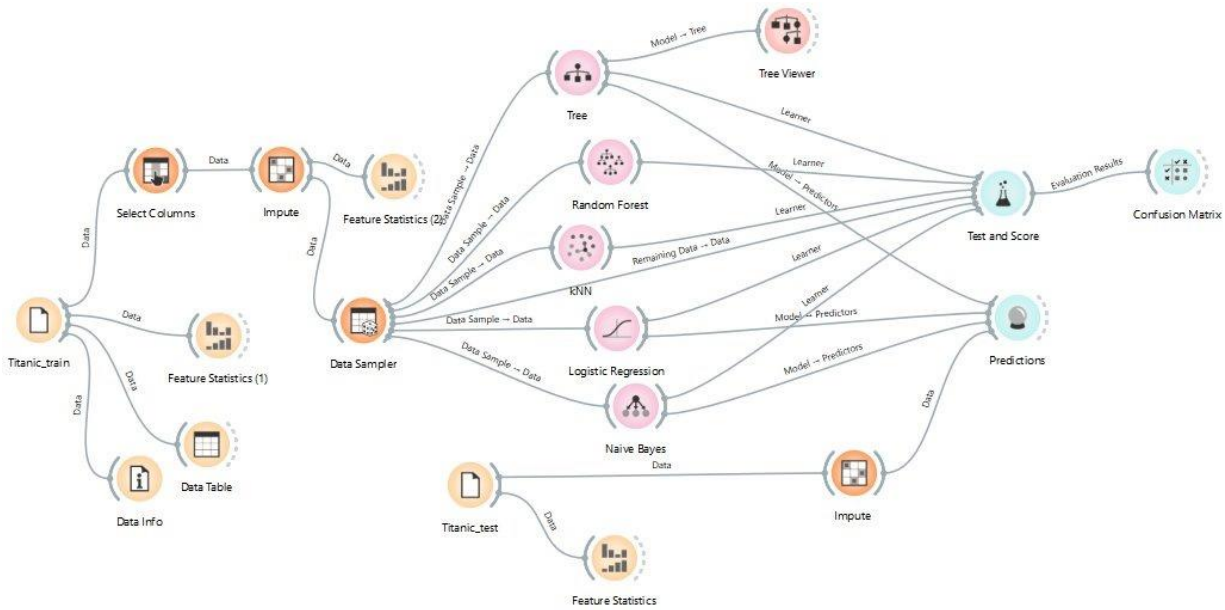

Gambar 1. Workflow Supervised Learning — Klasifikasi Titanic Dataset

Penjelasan Workflow

Komponen-komponen utama dalam workflow klasifikasi di atas:

1. Titanic_train & Titanic_test: Dua file dataset diload terpisah — train untuk melatih model, test untuk prediksi akhir.
2. Select Columns + Impute: Memilih fitur relevan (Pclass, Sex, Age, SibSp, Parch, Fare, Embarked) dan mengisi missing values dengan metode imputasi.
3. Feature Statistics: Menampilkan statistik deskriptif tiap fitur untuk eksplorasi data awal.
4. Data Sampler: Membagi data train menjadi subset untuk training dan validation.

5. 5 Model Klasifikasi (Tree, Random Forest, kNN, Logistic Regression, Naive Bayes): Lima algoritma dijalankan secara paralel untuk perbandingan.
6. Test and Score: Evaluasi semua model menggunakan Cross Validation 10-fold, menghasilkan metrik AUC, CA, F1, Precision, Recall, dan MCC.
7. Confusion Matrix & Predictions: Visualisasi detail performa model dan prediksi pada data test.

Hasil Evaluasi — Test and Score

Hasil evaluasi kelima model menggunakan Cross Validation 10-fold (Stratified):

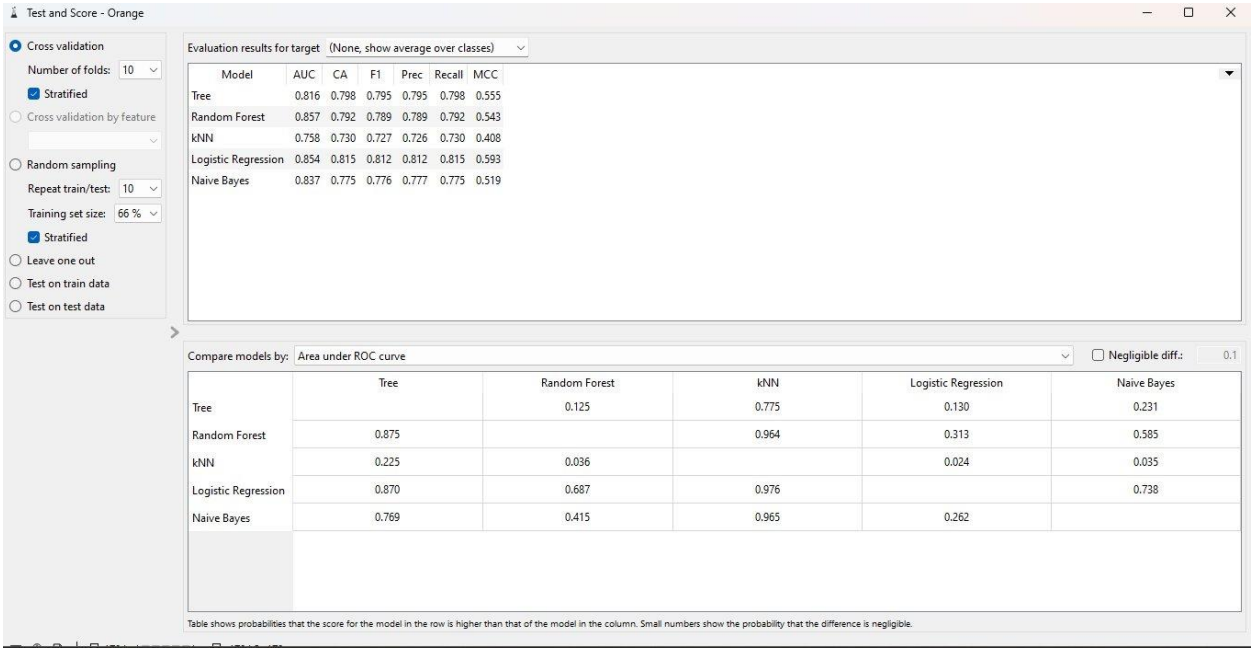

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.816	0.798	0.795	0.795	0.798	0.555
Random Forest	0.857	0.792	0.789	0.789	0.792	0.543
kNN	0.758	0.730	0.727	0.726	0.730	0.408
Logistic Regression	0.854	0.815	0.812	0.812	0.815	0.593
Naive Bayes	0.837	0.775	0.776	0.777	0.775	0.519

	Tree	Random Forest	kNN	Logistic Regression	Naive Bayes
Tree		0.125	0.775	0.130	0.231
Random Forest	0.875		0.964	0.313	0.585
kNN	0.225	0.036		0.024	0.035
Logistic Regression	0.870	0.687	0.976		0.738
Naive Bayes	0.769	0.415	0.965	0.262	

Gambar 2. Hasil Test and Score — Perbandingan 5 Algoritma Klasifikasi

Analisis Hasil Evaluasi

Berdasarkan hasil Test and Score di atas, berikut ringkasan performa setiap model:

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.816	0.798	0.795	0.795	0.798	0.555
Random Forest	**0.857**	**0.792**	**0.789**	**0.789**	**0.792**	**0.543**
kNN	0.758	0.730	0.727	0.726	0.730	0.408
Logistic Regression	**0.854**	**0.815**	**0.812**	**0.812**	**0.815**	**0.593**
Naive Bayes	0.837	0.775	0.776	0.777	0.775	0.519

Sumber: Hasil Test and Score Orange — Cross Validation 10-fold Stratified

Dari hasil evaluasi di atas, dapat dianalisis sebagai berikut:

- Logistic Regression meraih CA tertinggi (0.815) dan F1 tertinggi (0.812), menjadikannya model terbaik untuk klasifikasi Titanic dari segi akurasi keseluruhan.
- Random Forest memiliki AUC tertinggi (0.857), menunjukkan kemampuan diskriminasi terbaik antara kelas survived dan tidak survived.
- kNN memiliki performa terendah (AUC 0.758, CA 0.730), kemungkinan karena sensitif terhadap fitur yang tidak ter-scale dengan baik.
- Naive Bayes menunjukkan AUC 0.837 yang kompetitif meski dengan asumsi independensi fitur yang kuat, menandakan fitur-fitur Titanic cukup informatif secara individual.

Hasil Prediksi pada Data Test

Setelah model dievaluasi, dilakukan prediksi pada dataset Titanic_test menggunakan widget Predictions. Berikut tampilan hasil prediksi dari tiga model (Tree, Logistic Regression, Naive Bayes):

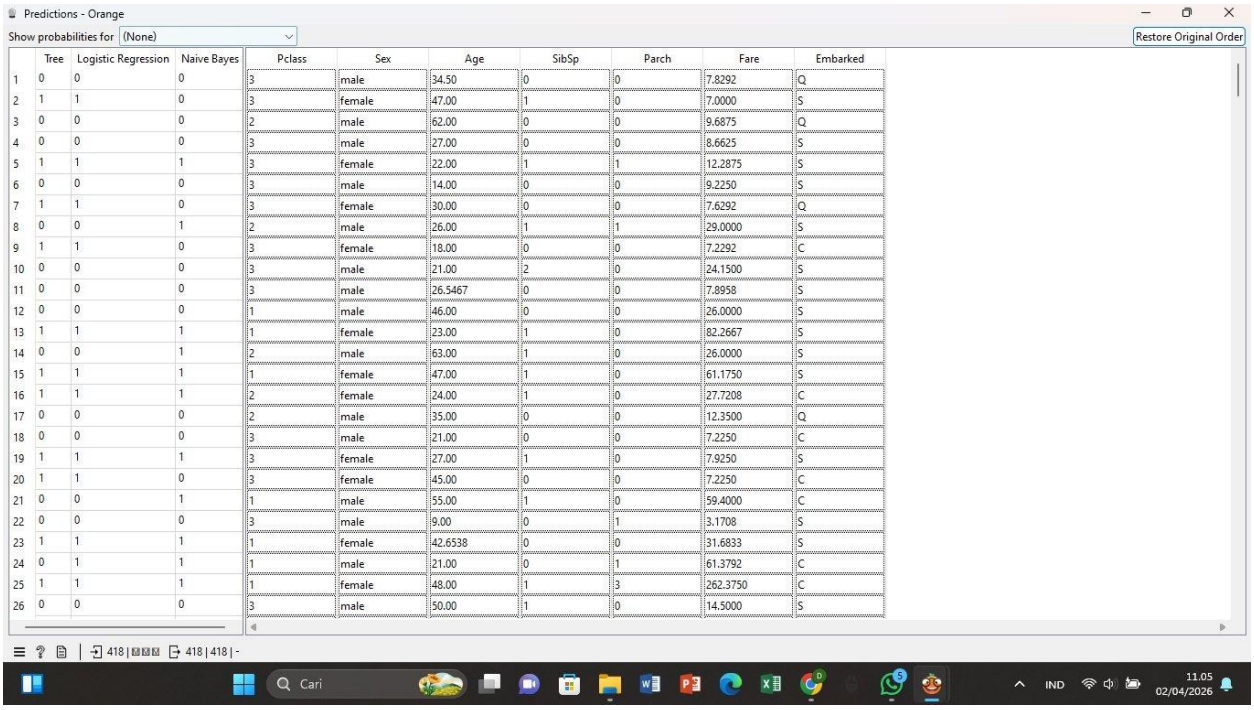

	Tree	Logistic Regression	Naive Bayes	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
1	0	0	0	3	male	34.50	0	0	7.8292	Q
2	1	1	0	3	female	47.00	1	0	7.0000	S
3	0	0	0	2	male	62.00	0	0	9.6875	Q
4	0	0	0	3	male	27.00	0	0	8.6625	S
5	1	1	1	3	female	22.00	1	1	12.2875	S
6	0	0	0	3	male	14.00	0	0	9.2250	S
7	1	1	0	3	female	30.00	0	0	7.6292	Q
8	0	0	1	2	male	26.00	1	1	29.0000	S
9	1	1	0	3	female	18.00	0	0	7.2292	C
10	0	0	0	3	male	21.00	2	0	24.1500	S
11	0	0	0	3	male	26.5467	0	0	7.8958	S
12	0	0	0	1	male	46.00	0	0	26.0000	S
13	1	1	1	1	female	23.00	1	0	82.2667	S
14	0	0	1	2	male	63.00	1	0	26.0000	S
15	1	1	1	1	female	47.00	1	0	61.1750	S
16	1	1	1	2	female	24.00	1	0	27.7208	C
17	0	0	0	2	male	35.00	0	0	12.3500	Q
18	0	0	0	3	male	21.00	0	0	7.2250	C
19	1	1	1	3	female	27.00	1	0	7.9250	S
20	1	1	0	3	female	45.00	0	0	7.2250	C
21	0	0	1	1	male	55.00	1	0	59.4000	C
22	0	0	0	3	male	9.00	0	1	3.1708	S
23	1	1	1	1	female	42.6538	0	0	31.6833	S
24	0	1	1	1	male	21.00	0	1	61.3792	C
25	1	1	1	1	female	48.00	1	3	262.3750	C
26	0	0	0	3	male	50.00	1	0	14.5000	S

Gambar 3. Hasil Prediksi pada Titanic Test Dataset (418 data)

Kolom Tree, Logistic Regression, dan Naive Bayes menampilkan prediksi kelas (0 = tidak selamat, 1 = selamat) untuk setiap penumpang pada data test. Perbedaan antar model terlihat pada beberapa baris, mencerminkan perbedaan keputusan boundary masing-masing algoritma.

Confusion Matrix

Berikut adalah Confusion Matrix untuk model Logistic Regression — model terbaik berdasarkan CA (0.815) dan F1 (0.812) tertinggi:

Gambar 4. Confusion Matrix — Logistic Regression (Proporsi dari Aktual)

Analisis Confusion Matrix Logistic Regression:

- True Negative (TN): 88.5% — Logistic Regression berhasil memprediksi 88.5% penumpang yang tidak selamat dengan benar.
- False Positive (FP): 11.5% — hanya 11.5% penumpang tidak selamat yang diprediksi salah sebagai selamat.
- False Negative (FN): 30.8% — 30.8% penumpang selamat diprediksi tidak selamat. Ini lebih baik dibanding Decision Tree (33.8%).
- True Positive (TP): 69.2% — model berhasil memprediksi 69.2% penumpang yang selamat dengan benar, lebih tinggi dari Decision Tree (66.2%).

Logistic Regression menunjukkan performa Confusion Matrix yang lebih baik dari Decision Tree: TN lebih tinggi (88.5% vs 87.6%), TP lebih tinggi (69.2% vs 66.2%), dan FN lebih rendah (30.8% vs 33.8%). Hal ini konsisten dengan nilai CA=0.815 yang merupakan tertinggi di antara semua model.

2. Regresi (Regression)

Dataset : Housing Dataset (housing.tab — bawaan Orange)

Target : MEDV (nilai median rumah, dalam $1000)

Algoritma : Linear Regression, Random Forest, Gradient Boosting

Evaluasi : Cross Validation 5-fold — MSE, RMSE, MAE, MAPE, R^2

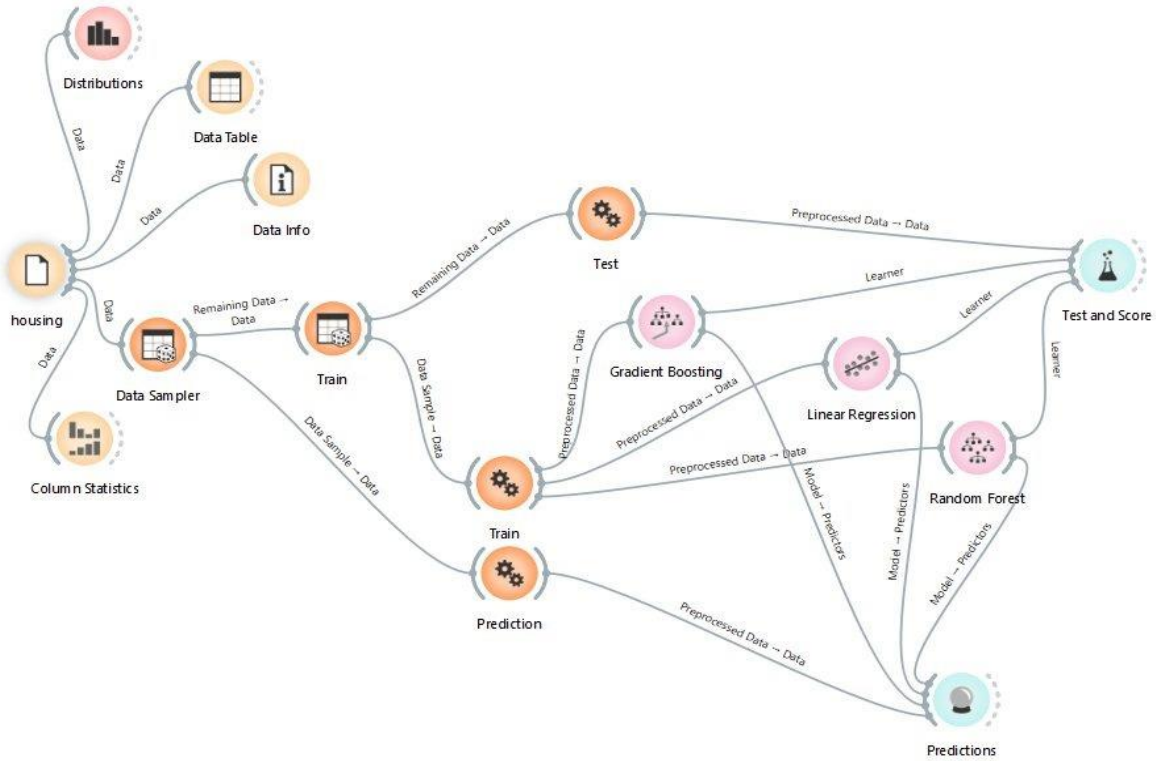

Gambar 5. Workflow Supervised Learning — Regresi (Housing Dataset)

Penjelasan Workflow

Komponen utama dalam workflow regresi:

1. housing: File dataset housing.tab diload dari library bawaan Orange.
2. Distributions, Data Table, Data Info, Column Statistics: Widget eksplorasi data untuk memahami distribusi dan statistik deskriptif dataset.
3. Data Sampler: Membagi data menjadi subset Train dan Test.
4. 3 Model Regresi (Linear Regression, Random Forest, Gradient Boosting): Tiga algoritma dijalankan paralel. Preprocessor digunakan untuk normalisasi data sebelum masuk ke model.
5. Test and Score: Evaluasi model menggunakan Cross Validation 5-fold, menghasilkan metrik MSE, RMSE, MAE, MAPE, dan R^2.
6. Predictions: Menampilkan prediksi nilai MEDV beserta error absolut dari masing-masing model pada data test.

Hasil Evaluasi — Test and Score

Hasil evaluasi tiga model regresi menggunakan Cross Validation 5-fold:

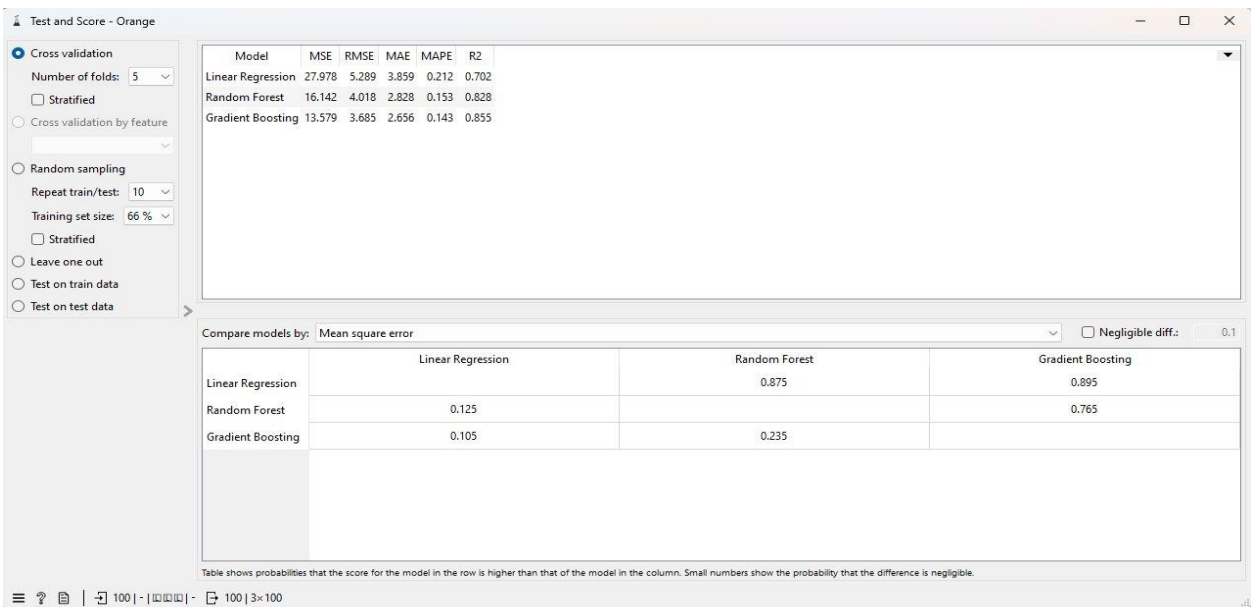

Gambar 6. Hasil Test and Score — Perbandingan 3 Algoritma Regresi

Analisis Hasil Evaluasi

Berdasarkan hasil Test and Score di atas, berikut ringkasan performa setiap model regresi:

Model	MSE	RMSE	MAE	MAPE	R^2
Linear Regression	27.978	5.289	3.859	0.212	0.702
Random Forest	16.142	4.018	2.828	0.153	0.828
Gradient Boosting	**13.579**	**3.685**	**2.656**	**0.143**	**0.855**

Sumber: Hasil Test and Score Orange — Cross Validation 5-fold | Semakin kecil MSE/RMSE/MAE dan semakin besar R^2, semakin baik model

Analisis hasil regresi:

- Gradient Boosting adalah model terbaik dengan R^2=0.855 (menjelaskan 85.5% variasi data), MSE terendah (13.579), RMSE terendah (3.685), dan MAE terendah (2.656).
- Random Forest memberikan performa kompetitif dengan R^2=0.828, jauh melampaui Linear Regression (R^2=0.702).
- Linear Regression memiliki MSE tertinggi (27.978) dan R^2 terendah (0.702), menunjukkan hubungan antara fitur dan MEDV bersifat non-linear sehingga model linear kurang optimal.
- MAPE Gradient Boosting sebesar 0.143 (14.3%) menunjukkan rata-rata error prediksi sekitar 14.3% dari nilai aktual MEDV.

Hasil Prediksi pada Data Test

Berikut tampilan hasil prediksi nilai MEDV dari tiga model beserta error absolut masing-masing dan performa score pada data test:

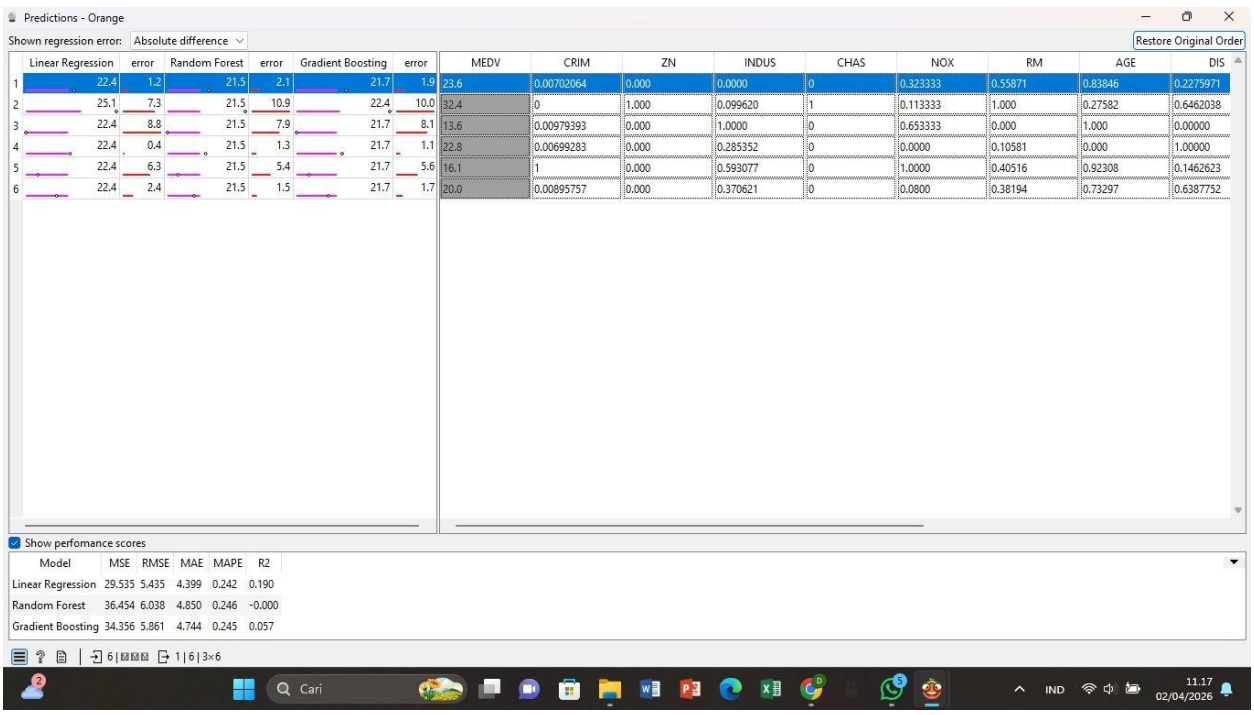

	Linear Regression	error	Random Forest	error	Gradient Boosting	error	MEDV	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS
1	22.4	1.2	21.5	2.1	21.7	1.9	23.6	0.00702064	0.000	0.0000	0	0.323333	0.55871	0.83846	0.2275971
2	25.1	7.3	21.5	10.9	22.4	10.0	32.4	0	1.000	0.099620	1	0.113333	1.000	0.27582	0.6462038
3	22.4	8.8	21.5	7.9	21.7	8.1	13.6	0.00979393	0.000	1.0000	0	0.653333	0.000	1.000	0.00000
4	22.4	0.4	21.5	1.3	21.7	1.1	22.8	0.00699283	0.000	0.285352	0	0.0000	0.10581	0.000	1.00000
5	22.4	6.3	21.5	5.4	21.7	5.6	16.1	1	0.000	0.593077	0	1.0000	0.40516	0.92308	0.1462623
6	22.4	2.4	21.5	1.5	21.7	1.7	20.0	0.00895757	0.000	0.370621	0	0.0800	0.38194	0.73297	0.6387752

Model	MSE	RMSE	MAE	MAPE	R2
Linear Regression	29.535	5.435	4.399	0.242	0.190
Random Forest	36.454	6.038	4.850	0.246	-0.000
Gradient Boosting	34.356	5.861	4.744	0.245	0.057

Gambar 7. Hasil Predictions pada Housing Test Dataset — Nilai MEDV dan Error Absolut

Dari tabel Predictions terlihat bahwa Gradient Boosting secara konsisten menghasilkan error absolut yang lebih kecil dibanding Linear Regression dan Random Forest. Performa score pada data test juga menunjukkan Gradient Boosting (R^2=0.057) lebih unggul, meski nilai R^2 pada test data lebih rendah dari cross-validation karena data test yang digunakan sangat kecil (6 sampel yang ditampilkan).

3. Clustering — K-Means, DBSCAN, dan Louvain

Dataset : Iris Dataset (iris.tab — bawaan Orange, 150 sampel, 4 fitur)

Metode : K-Means, DBSCAN, Louvain Clustering

Visualisasi : Scatter Plot — Axis X: petal length, Axis Y: sepal length

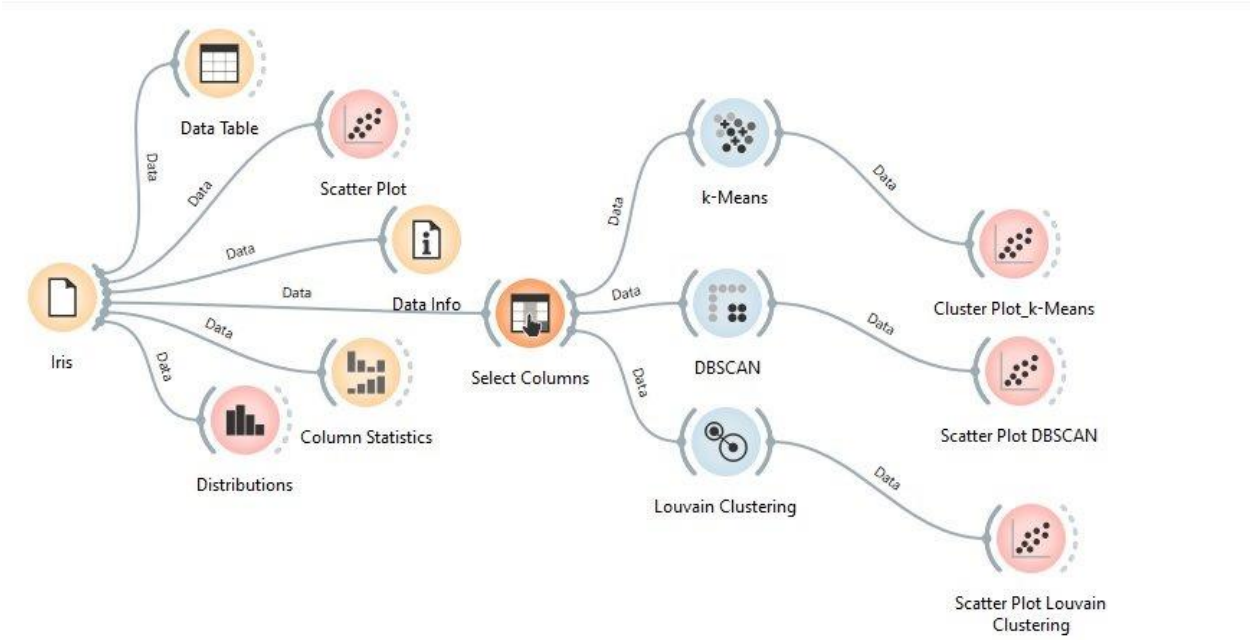

Gambar 8. Workflow Unsupervised Learning — K-Means, DBSCAN, dan Louvain Clustering (Iris Dataset)

Workflow menggunakan tiga algoritma clustering secara paralel: K-Means, DBSCAN, dan Louvain Clustering. Masing-masing dihubungkan ke Scatter Plot tersendiri untuk perbandingan visual.

Penjelasan Workflow

1. Iris: File dataset iris.tab diload dari library bawaan Orange.
2. Data Table, Scatter Plot, Data Info, Column Statistics, Distributions: Widget eksplorasi data awal.
3. Select Columns: Memilih fitur numerik dan mengecualikan kolom class agar clustering bersifat unsupervised.
4. k-Means: Algoritma K-Means dengan k=3, menghasilkan 3 cluster (C1, C2, C3).
5. DBSCAN: Density-Based Spatial Clustering — mengelompokkan berdasarkan kepadatan titik, mampu mendeteksi noise/outlier.
6. Louvain Clustering: Algoritma berbasis graf/community detection, menghasilkan jumlah cluster secara otomatis berdasarkan modularity.

Hasil 1 — K-Means Clustering (k=3)

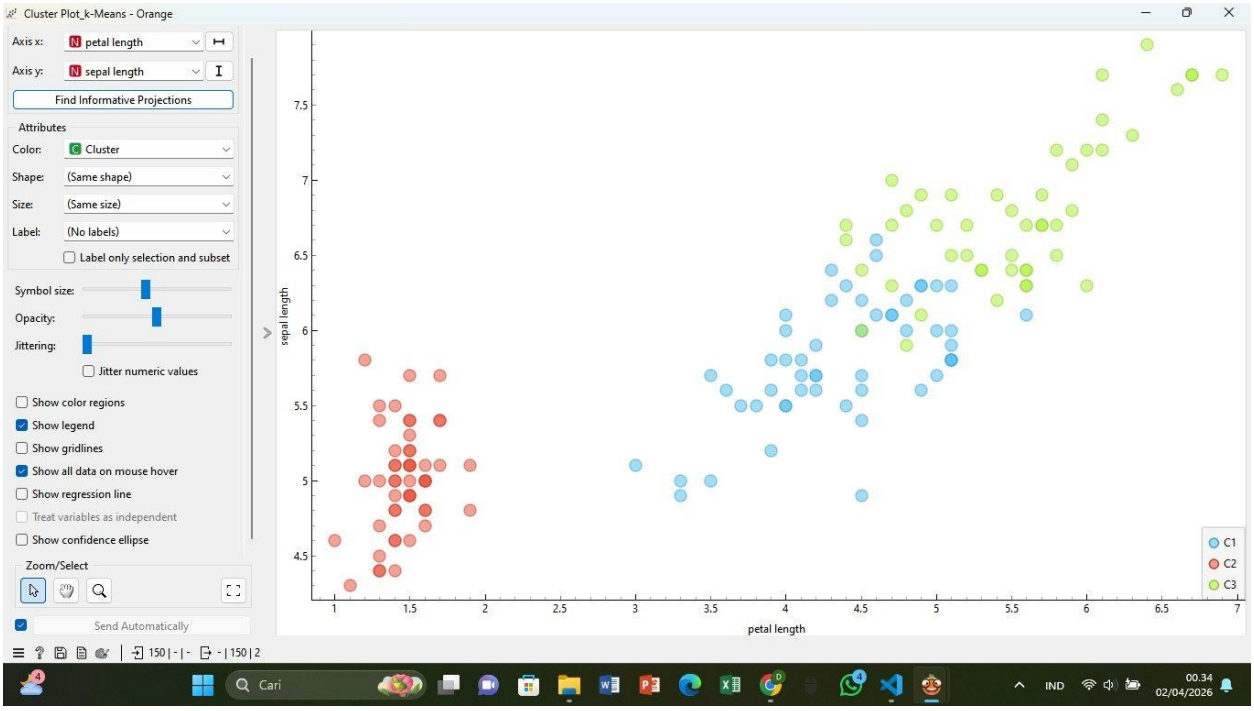

Gambar 9. Scatter Plot K-Means Clustering — 3 Cluster (C1=biru, C2=merah, C3=hijau)

K-Means dengan k=3 menghasilkan tiga cluster yang terdefinisi dengan baik pada scatter plot petal length vs sepal length:

- C2 (merah/kiri bawah): Cluster Iris setosa — terpisah sangat jelas karena petal length pendek (1–2 cm). Kohesif dan tidak overlap.
- C1 (biru/tengah): Cluster Iris versicolor — petal length menengah (3–5 cm), sepal length 5.5–6.5 cm.
- C3 (hijau/kanan atas): Cluster Iris virginica — petal length panjang (5–7 cm). Terdapat sedikit overlap dengan C1 pada petal length ~4–5 cm.

Hasil 2 — DBSCAN Clustering

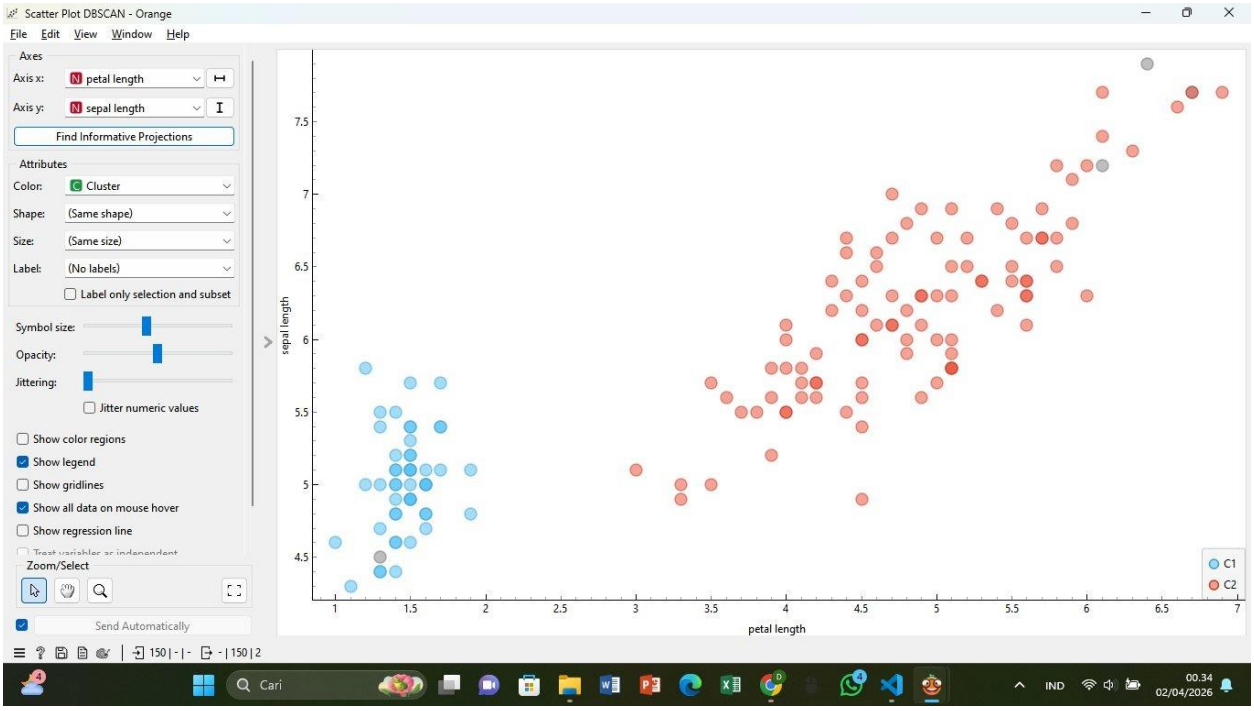

Gambar 10. Scatter Plot DBSCAN Clustering — 2 Cluster + Noise (abu-abu)

DBSCAN menghasilkan 2 cluster utama (C1 dan C2) dengan beberapa titik abu-abu yang teridentifikasi sebagai noise/outlier:

- C1 (biru/kiri): Mengelompokkan Iris setosa berdasarkan kepadatan titik di area petal length rendah.
- C2 (merah/kanan): Menggabungkan Iris versicolor dan virginica menjadi satu cluster besar karena keduanya memiliki kepadatan yang menyambung.
- Noise (abu-abu): Beberapa titik di batas antar cluster diidentifikasi sebagai outlier — keunggulan DBSCAN dibanding K-Means.

Hasil 3 — Louvain Clustering

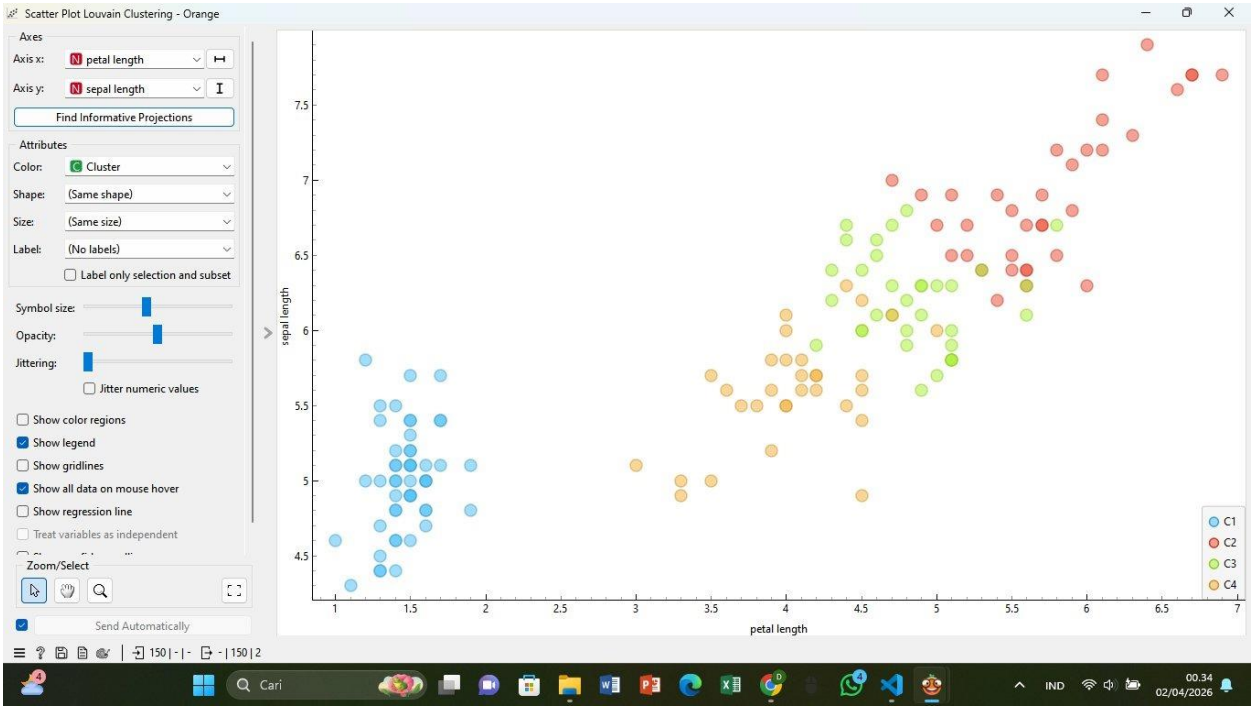

Gambar 11. Scatter Plot Louvain Clustering — 4 Cluster (C1–C4)

Louvain Clustering secara otomatis menentukan jumlah cluster berdasarkan struktur modularity graf, menghasilkan 4 cluster pada dataset Iris:

1. C1 (biru): Subset Iris setosa di area petal length sangat pendek.
2. C2 (merah): Iris virginica di petal length panjang.
3. C3 (hijau): Area transisi antara versicolor dan virginica.
4. C4 (oranye): Iris versicolor — cluster terpisah di area tengah. Louvain memecah data lebih granular dibanding K-Means.

Analisis:

- K-Means (k=3): Menghasilkan 3 cluster yang sesuai dengan 3 spesies Iris. Iris setosa terkelompok sangat jelas karena ukuran petal yang jauh lebih pendek dibanding dua spesies lainnya. Iris versicolor dan virginica sedikit tumpang tindih karena ukuran petal yang mirip.
- DBSCAN: Menghasilkan 2 cluster — Iris setosa terpisah sendiri, sementara versicolor dan virginica digabung menjadi satu cluster karena kerapatan datanya saling menyambung. Kelebihan DBSCAN adalah kemampuannya mendeteksi data yang tidak masuk cluster mana pun (outlier), ditandai dengan titik berwarna abu-abu.
- Louvain: Secara otomatis menemukan 4 cluster tanpa perlu menentukan jumlah cluster terlebih dahulu. Algoritma ini memecah versicolor dan virginica lebih detail dibanding K-Means, cocok digunakan ketika jumlah kelompok dalam data belum diketahui.