Nama : Muhamad Hasbi

Nim 20124074

Kelas : C3|24

Metode: klasifikasi

Data: Titanic Dataset

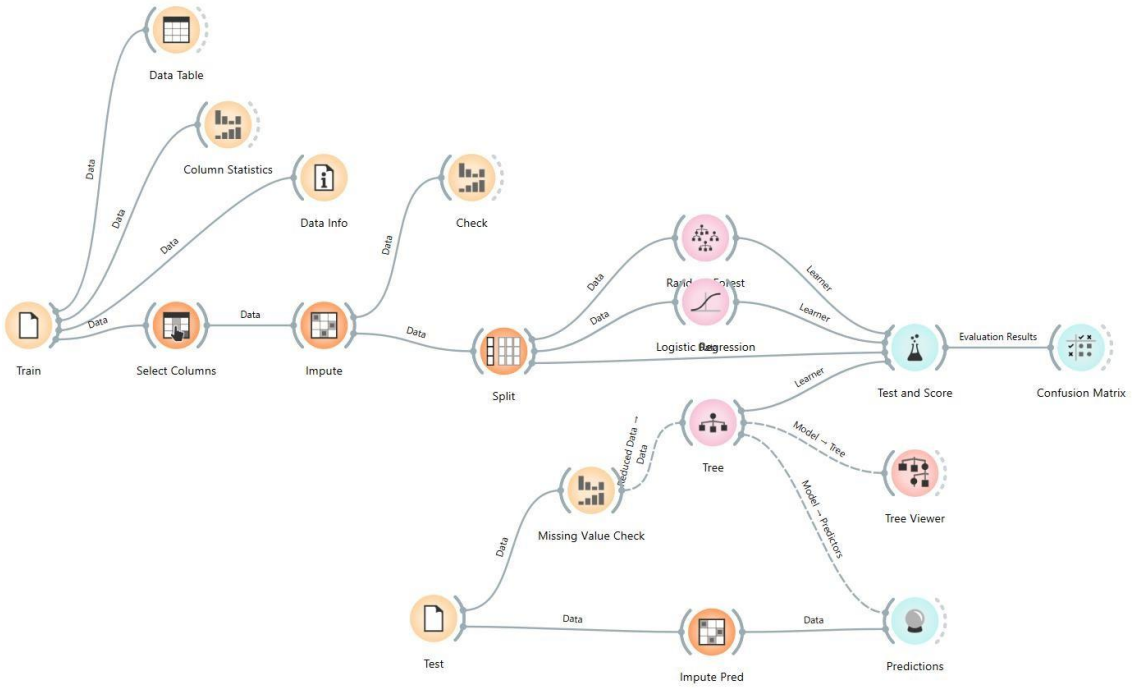

Workflow dimulai dengan memuat dataset menggunakan widget Train, kemudian dilakukan pemilihan atribut menggunakan Select Columns. Selanjutnya, dilakukan proses penanganan missing value menggunakan widget Impute untuk meningkatkan kualitas data.

Data kemudian dibagi menjadi data training dan testing menggunakan widget Split. Tiga model digunakan dalam proses klasifikasi yaitu Random Forest, Decision Tree, dan Logistic Regression.

Evaluasi model dilakukan menggunakan widget Test & Score untuk mengetahui performa masing-masing model, serta Confusion Matrix untuk melihat hasil prediksi secara lebih detail.

Model	AUC	CA	F1	Prec	Recall	MCC
Tree	0.755	0.788	0.757	0.816	0.788	0.498
Random Forest	0.757	0.787	0.757	0.813	0.787	0.495
Logistic Regression	0.747	0.778	0.764	0.772	0.778	0.462

Berdasarkan hasil evaluasi pada Test & Score, diperoleh bahwa model Decision Tree memiliki akurasi sebesar 0.788, diikuti oleh Random Forest sebesar 0.787, dan Logistic Regression sebesar 0.778.

Dari ketiga model tersebut, Decision Tree menunjukan performa terbaik, meskipun perbedaannya tidak terlalu signifikan dibandingkan Random Forest. Logistic Regression memiliki performa paling rendah, namun masih cukup baik dalam melakukan klasifikasi.

Actual \ Predicted	no	yes	Σ
no	98.3 %	1.7 %	1490
yes	62.0 %	38.0 %	711
Σ	1906	295	2201

Berdasarkan Confusion Matrix, model mampu mengklasifikasikan data dengan cukup baik pada kelas “no” dengan tingkat akurasi sebesar 98.3%. Namun, pada kelas “yes”, model hanya mampu mengenali sebesar 38.0%, yang menunjukkan bahwa model masih kesulitan dalam mendeteksi kelas tersebut.

Selain itu, terdapat kesalahan prediksi sebesar 62.0% pada data aktual “yes” yang diprediksi sebagai “no”. Hal ini menunjukkan adanya ketidakseimbangan performa model dalam mengenali kedua kelas.

Perbedaan performa antara kelas “no” dan “yes” kemungkinan disebabkan oleh ketidakseimbangan jumlah data (imbalanced data), di mana jumlah data “no” lebih banyak dibandingkan “yes”. Hal ini menyebabkan model cenderung lebih baik dalam memprediksi kelas mayoritas.

Unsupervised

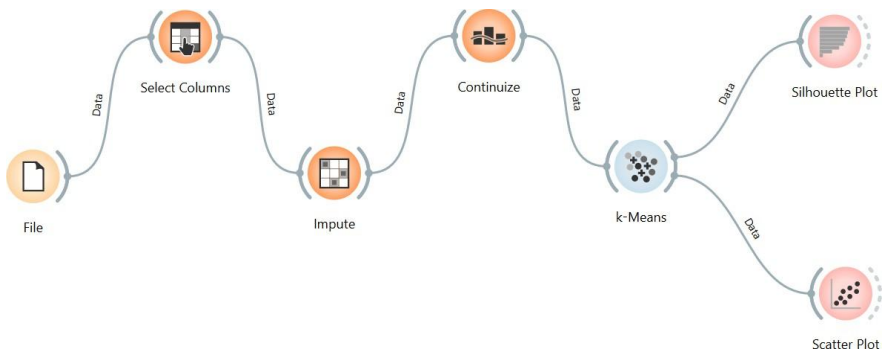

Proses dimulai dengan memasukkan dataset menggunakan widget File. Selanjutnya dilakukan

pemilihan atribut menggunakan Select Columns agar hanya fitur yang relevan yang digunakan.

Tahap berikutnya adalah preprocessing dengan Impute untuk menangani missing value dan Continuize untuk mengubah data kategorikal menjadi numerik agar dapat diproses oleh algoritma clustering.

Setelah itu, dilakukan proses clustering menggunakan algoritma K-Means untuk mengelompokkan data berdasarkan kemiripan karakteristik.

Hasil clustering kemudian dievaluasi menggunakan Silhouette Plot untuk melihat kualitas cluster, serta divisualisasikan menggunakan Scatter Plot.

Silhouette Scores

3	0.459
4	0.390
5	0.348
6	0.328
7	0.335
8	0.343

Berdasarkan hasil clustering menggunakan K-Means, data berhasil dikelompokkan ke dalam beberapa cluster.

Visualisasi pada Scatter Plot menunjukkan pemisahan antar cluster yang cukup jelas, yang menandakan bahwa data memiliki pola tertentu yang dapat dikelompokkan.

Nilai silhouette yang diperoleh menunjukkan kualitas cluster yang cukup baik, meskipun masih terdapat beberapa data yang berada di batas antar cluster.

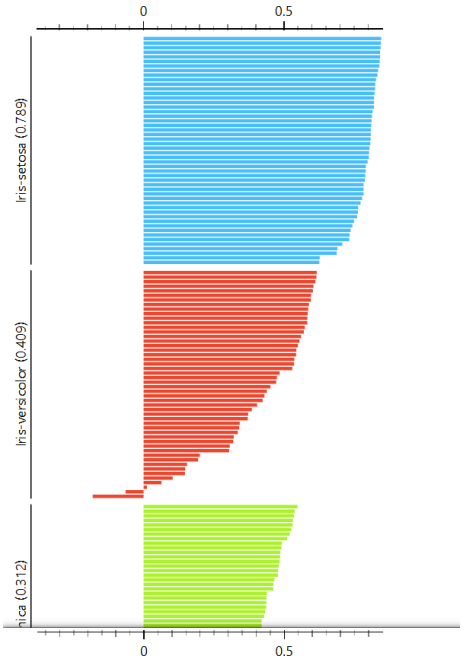

Silhouette Plot digunakan untuk mengevaluasi kualitas hasil clustering yang dihasilkan oleh algoritma K-Means. Nilai silhouette berkisar antara -1 hingga 1, di mana nilai yang mendekati 1 menunjukkan bahwa data berada dalam cluster yang tepat dan terpisah dengan baik dari cluster lain.

Berdasarkan hasil yang diperoleh, jumlah cluster terbaik adalah **3 cluster** dengan nilai silhouette sebesar **0.459**. Hal ini menunjukkan bahwa hasil pengelompokan cukup baik, meskipun masih terdapat beberapa data yang berada di batas antar cluster.

Dengan demikian, dapat disimpulkan bahwa penggunaan 3 cluster sudah cukup optimal untuk merepresentasikan pola dalam data yang digunakan.

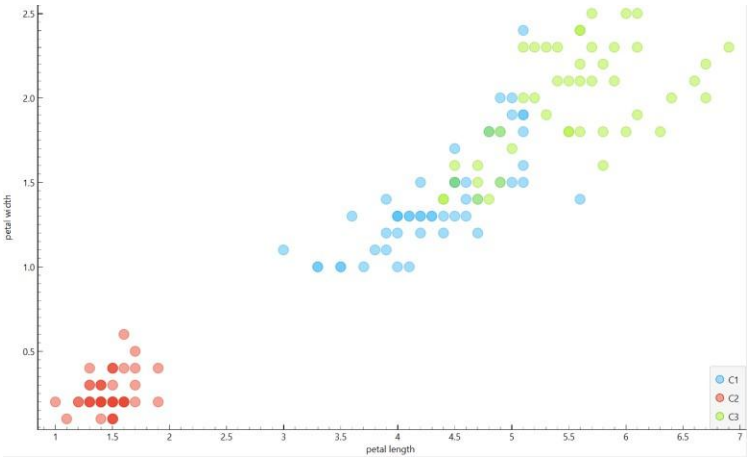

Scatter Plot digunakan untuk memvisualisasikan hasil clustering dari algoritma K-Means dalam bentuk sebaran titik. Setiap titik merepresentasikan satu data, sedangkan warna yang berbeda menunjukkan cluster yang berbeda.

Berdasarkan hasil visualisasi, data telah terbagi ke dalam beberapa kelompok (cluster) yang dapat dibedakan berdasarkan warna. Sebagian besar titik dalam satu cluster terlihat berdekatan, yang menunjukkan bahwa data dalam cluster tersebut memiliki kemiripan karakteristik.

Namun, terdapat beberapa titik yang berada dekat dengan batas antar cluster, yang menunjukkan adanya kemungkinan overlap atau kemiripan antar kelompok.

Secara keseluruhan, Scatter Plot menunjukkan bahwa proses clustering berhasil mengelompokkan data dengan cukup baik sesuai dengan hasil evaluasi pada Silhouette Plot.

Hasil visualisasi dan evaluasi menunjukkan bahwa metode K-Means cukup efektif dalam mengelompokkan data berdasarkan kemiripan fitur yang dimiliki.